Estadística para Ciencias Sociales

Julián Cruz

Table of contents

1 Estadistica para Ciencias sociales **7**

I preliminares **8**

2 Intención y propósito **9**
2.1 Presentación . . . 9
2.2 Orientación . . . 9

3 Los datos y su preparación **11**
3.1 Definiciones . . . 11
3.1.1 ¿Qué son los datos? . . . 11
3.1.2 ¿Qué son las variables? . . . 12
3.1.3 ¿Qué son los individuos? . . . 14
3.2 Limpieza . . . 15
3.2.1 Corrección de errores . . . 15
3.2.2 Codificación y decodificación . . . 16
3.3 Estandarización . . . 16
3.3.1 Identificación de atípicos . . . 16
3.3.2 Imputación de datos . . . 18
3.3.3 Escalamiento univariado . . . 19
3.4 Estructura . . . 20
3.4.1 Cambio de tipo de variable . . . 20
3.4.2 Muestras de entrenamieto y de prueba . . . 23
3.4.3 Anonimización . . . 24
3.4.4 Estructurar data no estructurada . . . 24

4 Uso de inteligencia artificial **26**
4.1 Consideraciones . . . 26
4.1.1 el proceso creativo en investigacion . . . 26
4.1.2 problemas éticos . . . 26
4.1.3 consentimientos informados, protocolos . . . 26
4.1.4 trazabilidad y reproducibilidad . . . 27
4.2 Uso y apropiación . . . 27
4.2.1 prompt engineering . . . 27

4.2.2 procesos de datos con inteligencia artificial (código python) 27
4.2.3 subir datos, qué datos subir 27

5 Un breve ensayo sobre distribuciones **28**
5.1 qUÉ SON 28
5.2 Distribuciones discretas 28
5.3 Distribuciones continuas SIMÉTRICAS 28
5.4 Distribuciones continuas ASIMÉTRICAS Y SESGADAS 28
5.5 supuestos distribucionales 28
5.6 estadística paramétrica 28
5.7 estadística no paramétrica 29
5.8 métodos computacionales 29

II Estadística inferencial **30**

6 Epistemología de la inferencia estadística **31**
6.1 Los antiguos griegos y la deducción 31
6.1.1 Sócrates y la mayeutica 31
6.1.2 Platón y la dialéctica 31
6.1.3 Aristóteles y la lógica 32
6.1.4 El silogismo 32
6.1.5 Pensamiento deductivo 32
6.2 El Novum Organum de Bacon 33
6.2.1 La deducción contra la inducción 33
6.2.2 El cisne negro 33
6.3 Fisher, Neyman, Pearson 33
6.3.1 Las reglas para hacer inducción 34
6.3.2 Inferencia estadística 34
6.4 El concepto de medición 35
6.4.1 Medición 35

7 Muestreo **36**
7.1 Contexto 36
7.1.1 Tendencias 36
7.1.2 Individuos 36
7.1.3 Población 36
7.1.4 Muestra 37
7.1.5 Representatividad 37
7.2 Conceptos 37
7.2.1 Marco muestral 37
7.2.2 Diseño muestral 37
7.2.3 Error muestral 37

7.2.4 Tamaño muestral . . . 38
7.2.5 Muestreo no probabilístico . . . 38
7.2.6 Muestreo probabilístico . . . 38
7.3 Muestreo no probabilístico . . . 39
7.3.1 Muestreo por cuotas . . . 39
7.3.2 Bola de nieve . . . 39
7.3.3 Muestreo direccional . . . 40
7.3.4 Muestreo por convivencia . . . 40
7.3.5 Muestreo accidental . . . 40
7.4 Muestreo probabilístico . . . 41
7.4.1 Muestreo aleatorio simple . . . 41
7.4.2 Muestreo por etapas . . . 41
7.4.3 Muestreo por conglomerados . . . 42
7.4.4 Muestreo estratificado . . . 42
7.4.5 Factores de expansión . . . 43

8 Estimación **44**
8.1 Conceptos iniciales . . . 44
8.1.1 Población . . . 44
8.1.2 Muestra . . . 45
8.1.3 Parámetro . . . 45
8.1.4 Estimador . . . 45
8.2 Estimación puntual . . . 46
8.2.1 Estimación puntual . . . 46
8.2.2 Estimadores y parámetros . . . 47
8.2.3 Ley de los grandes números . . . 47
8.2.4 Consistencia . . . 48
8.3 Estimación por intervalo . . . 49
8.3.1 Precisión y exactitud . . . 49
8.3.2 Construccion de los intervalos de confianza . . . 50

9 Tamaño muestral **53**
9.1 Error muestral . . . 53
9.2 Empate técnico . . . 53
9.3 Tamaño del efecto . . . 53
9.4 Tamaño de muestra . . . 53
9.4.1 Tamaño de muestra óptimo . . . 53
9.5 Formulas para estimación . . . 53
9.5.1 Estimación de una proporción con tamaño poblacional conocido . . . 53
9.5.2 Estimación de una proporción con tamaño poblacional desconocido . . . 54
9.5.3 Estimación de una media con tamaño poblacional conocido . . . 54
9.5.4 Estimación de una media con tamaño poblacional desconocido . . . 54
9.6 Aplicación interactiva . . . 54

10 Pruebas de hipótesis **55**
10.1 La hipótesis en el contexto del desarrollo científico . . . 55
10.1.1 Reproducibilidad . . . 56
10.1.2 Objetivo . . . 57
10.2 Marco conceptual . . . 57
10.2.1 El sistema de hipótesis . . . 57
10.2.2 Tipos de error . . . 59
10.2.3 Nivel de significancia . . . 60
10.3 Evaluación de la evidencia . . . 60
10.3.1 Estadístico de la prueba . . . 60
10.3.2 Valor p . . . 61
10.3.3 Rechazar la hipótesis nula . . . 61
10.3.4 El procedimiento completo . . . 62
10.4 Pruebas y tipos de pruebas . . . 62
10.4.1 Pruebas paramétricas y no paramétricas . . . 62
10.4.2 Pruebas analíticas y computacionales . . . 63
10.4.3 Cuando usar cada tipo de prueba . . . 63

11 Descriptivos univariados **64**
11.1 Medidas de frecuencia . . . 64
11.1.1 Frecuencia . . . 64
11.1.2 Proporción . . . 64
11.1.3 Moda . . . 64
11.1.4 Nota sobre variables continuas . . . 64
11.2 Medidas de tendencia central . . . 64
11.2.1 Media aritmética . . . 64
11.2.2 Mediana . . . 65
11.3 Medidas de localización . . . 65
11.3.1 Mínimo y máximo . . . 65
11.3.2 Cuantiles . . . 65
11.3.3 Percentiles . . . 65
11.3.4 Cuartiles . . . 65
11.4 Medidas de dispersión . . . 65
11.4.1 Varianza . . . 65
11.4.2 Desviación estandar . . . 65
11.4.3 Rango intercuartílico (IQR) . . . 66
11.4.4 Rango . . . 66

12 Inferencia univariada **67**
12.1 Intervalos de confianza . . . 67
12.1.1 Intervalo de confianza para la media . . . 67
12.1.2 Intervalo de confianza para una proporción . . . 68
12.1.3 Intervalo de confianza para la varianza . . . 69

12.2 Pruebas de hipótesis . . . 69
12.2.1 Test t de Student para una muestra . . . 69
12.2.2 Test de signos para una muestra . . . 70
12.2.3 Test t de Student para dos muestras independientes . . . 70
12.2.4 Test Wilcoxon - Mann - Whitney . . . 70
12.2.5 Test t de Student para dos muestras pareadas . . . 70
12.2.6 Prueba de una sola proporción . . . 70
12.2.7 Prueba de dos proporciones . . . 70
12.2.8 Pruebas de permutaciones para la media . . . 70
12.2.9 Pruebas de permutaciones para la proporción . . . 70
12.2.10 Pruebas de permutaciones otra . . . 70
12.3 Ejercicios y actividades . . . 71
12.3.1 Hablemos bien . . . 71
12.3.2 Actividad . . . 71

13 Análisis correlacional **72**
13.1 Dos variables numéricas . . . 72
13.1.1 Covarianza . . . 72
13.1.2 Correlación de Pearson . . . 73
13.1.3 Correlación de Spearman . . . 73
13.1.4 Prueba de permutaciones . . . 73
13.2 Una variable numérica y otra categórica . . . 74
13.2.1 Elementos gráficos . . . 74
13.2.2 Anova . . . 74
13.2.3 Test Kruskal-Wallis . . . 75
13.3 Asociación categórica - categórica . . . 75
13.3.1 Tablas de contingencia . . . 75

1 Estadistica para Ciencias sociales

Part I

preliminares

2 Intención y propósito

2.1 Presentación

El Laboratorio Interdisciplinar de Medición Social (LABMEDISOCIAL) de la Facultad de Ciencias Sociales y Humanas de la Universidad Externado de Colombia se complace en presentar estas notas de clase sobre estadística en ciencias sociales.

La estadística, en su esencia, constituye un puente entre la observación empírica y la construcción de conocimiento científico.. Este libro se concibe como una contribución a ese esfuerzo, ofreciendo una integración rigurosa con las ciencias sociales

En investigación social, el uso adecuado de métodos estadísticos , constituye una ventaja del investigador en un entorno competitio de alto desempaño.

dado el crecimiento exponencial de las fuentes de información y el desarrollo acelerado de las herramientas tecnológicas, es apropiado disponer de una sólida fundamentación conceptual y práctica que le permita transformar y comprender grandes cantidades de información.

2.2 Orientación

Las ciencias sociales requieren muchas veces de los métodos cuantitativos para poder resolver sus preguntas. La cuantificación plana, saber cuánto es el promedio y la varianza es un alcance corto. Hoy se estudia la relación entre diferentes variables, sean estas concretas o abstractas.

La estadística generalmente tiene cuatro componentes. Se trata de un componente matemático que nos habla de funciones, sumas e integrales. El componente teórico propio de la estadística, que nos dice qué es una hipótesis, una muestra aleatoria etc; el componente computacional que generalmente se trabaja con software abierto como R o Python y el componente contextual, que se trata de los pormenores disciplinares, del contexto en el que ocurren los datos.

Este manuscrito está orientado a resolver las dudas de un científico social con respecto a los temas estadísticos. Mucha de su presentaciño en prosa es más parecida a un libro de filosofía que un texto matemático. Con el fin de facilitar el acercamiento del científico social se proponen tres características.

Una persona que utiliz a un horno microondas no necesita saber qué son las miicroondas para poderlo utilizar. El diseño de los objetos que tenemos a nuestro alcance toma como punto

de partida la noción de usuario. Un usurio no es un experto, sino alguien que resuelve una necesidad inmediata por medio de una herramienta. Para el científico social, la experiencia de hacer uso de métodos estadísticos puede ser más parecida a usar un horno microondas, resolviendo sus requerimientos sin saber como funciona realmente. El objetivo de estas notas no es formar estadísticos sino usuarios de la estadística. Por consiguiente, muchas veces no necesitamos saber a profundidad cómo funciona una máquina para poderla usar. Este es el mismo caso y el manuscrito se orienta en este sentido en la formación de usuarios.

El componente matemático de la estadística es retirado tanto como se pueda. El lenguaje matemático no es necesariamente universal. Muchos lo aprendimos pero otros muchos no. En general, pra el científico social, las demostraciones llenas de sómbolos abstractos pueden en ocasiones resultar inaccesibles. Este es un muro invisible que se ha levantado mucho tiempo entre lo social y los métodos cuantitativos. En estas notas vamos a retirarlo y generar un lenguaje común. Claro que habrá fórmulas y argumentos técnicos, pero no son el centro de la discusión.

El componente tecnológico se resuelve con herramientas de inteligencia artificial. Desde la concepción del libro y su escritura, como los cálculos requeridos en los ejercicios son resueltos con modelos de lenguaje y arquitecturas de este estilo. La programación en R y en python no ha sido el camino favorito de los científicos sociales. El uso de otro tipo de software, tampoco se facilita, sobre todo si es privativo y require licencias. El uso de modelos de inteligenci artificial solo requiere la comprensión de los textos de instrucciones. Esto constituye una ventaja importante en el momento de la implementaciń.

Estas directrices generales reconfiguran el diseño del texto. Por una parte, concediéndole un caracter menos matemático y por otra dándole un orden diferente. Ya que estamos concentrados en la comprensiño de la teoría estadística.

La nueva estructura nos lleva de primera mano por el problema central de la estadística, que es la inferencia. El estudio de los pormenores epistemológicos y metodológicos de la inferencia estadística le da un sentido completo al cálculo de cantidades.

3 Los datos y su preparación

La preparación de los datos es importante. Abrimos este ejemplar con unas consideración respecto a la prepareación de los datos.

3.1 Definiciones

3.1.1 ¿Qué son los datos?

En 1948 apareció la teoría de la información de Shanon. Cualquier tipo de mensaje, sin importar su formato se puede convertir en bits. Esto permite unificar la información y computarla. En el mismo disco duro conviven canciones, videos, fotos, textos y cifras.

La información que se encuentra con una estructura tabular o anidada estándar se denomina información estructurada. Se trata de tablas de datos, o estructuras anidadas como JSON.

Por el contrario la información no estructurada está constituida por videos, fotos, audios y textos que no presentan una estructura tabular o anidada.

En este sentido, cuando hablamos de datos, nos referimos a "Características o información, generalmente numérica, que se recopilan mediante la observación." [@OECD(2008)], [@OECDGlossaryofStatisticalTerms], [@OECDPublishing], [@Paris], [@https://doi.org/10.1787/9789264055087-en.]

Es una definición amplia, que nos permite abordar la información estructurada y no estructurada. Esto se debe, en parte, a que es posible darle estructura a la información. Estos procedimientos corresponden a la ciencia de datos. Para el alcance de este manuscrito, vamos a tomar en consideración únicamente la información estructurada, dejando de lado los procesos mediante los cuales esta información adquirió su estructura.

Principios de la información estructurada. Atomicidad. Encontrabilidad y coherencia.

3.1.2 ¿Qué son las variables?

En ciencias sociales las variables pueden verse de distintas maneras. Pero siempre se tratan de características asociadas a comunidades o individuos. Estas características muchas veces tienen implicaciones políticas importantes.

En todos los discursos políticos actuales se mencionan variables que se relacionan unas con otras. Cuando un político dice "la riqueza viene de la inversión extranjera" o "solo la inclusión y la disminución de la desigualdad nos pueden llevar a una mayor competitividad" están hablando de variables.

Podría decisrse, de manera un poco intuitiva, que las variables constituyen la materialización de conceptos correspondientes al discurso. Sin embargo, para el quehacer estadístico, es necsario examinarlas con mayor profundidad.

Siguiendo con el tema, la información estructurada presenta un formato tabular o jerárquico. Cuando tenemos tablas, es posible identificar las variables (columnas) al interior de las tablas. Estas variables corresponden a aspectos que pueden variar entre individuos.

> Ejemplo
>
> Sea una población de personas, una variable puede ser el nombre, que varía de persona a persona. Pero la variable "ser mortal" que se responde con Sí/No, no es una variable sino una constante.

las variables adquieren distintos valores. Una variable que solamente recorre un mismo valor se denomina constante. Las constantes generalmente son de menor utilidad en el análisis de datos.

Las variables se clasifican de diversas maneras. La principal forma de clasificarlas es de acuerdo a los valores que la componen.

- VarIables categóricas
- variables nominales
- variables ordinales
- variables numéricas
- de intervalo
- de razón

otros tipos de variables también han sido estudiados. Como las variables circulares o cíclicas. Las variables temporales. Etc

Un tipo de variable muy utilizado en ciencias sociales son las escalas tipo likert. Se trata de variables categóricas ordinales, cuyos niveles permiten la adjudicación de valores numéricos a priori para su operación.

Ejemplo

Un ejemplo de una variable categórica es el estado civil de una persona o el nivel educativo

Ejemplo

Un ejemplo de una variable nominal es el estado civil de una persona

Ejemplo

Un ejemplo de una variable categórica es el nivel educativo de una persona

Ejemplo

Un ejemplo de una variable numérica es la edad de una persona o su estatura o su índice de masa corporal

Ejemplo

Un ejemplo de una variable numérica de intervalo es el índice de masa corporal de una persona

Ejemplo

Un ejemplo de una variable numérica de razón es la edad de una persona o su estatura

Ejemplo

Un ejemplo de una variable en escala tipo likert es “me siento seguro en el transporte público, siempre/casi siempre/ casi nunca/nunca” que puede tener valores numéricos a priori del 1 al 4 para su operación.

Es importante conocer los tipos de variable porque de ello se derivan los procedimientos estadísticos, de visualización y reporte que se generan.

Entre los métodos para variables categóricas podemos encontrar la recategorización, reagrupación y la conformación de variables binarias tipo dummie. Con esto se pueden aplicar distancias de jaccard y de manhattan, tablas de contingencia y análisis de correspondencias

simple y múltiple.

Con variables tipo likert es posible construir escalas de medición para trazos latentes. Son importantes en validación de instrumentos y creación de índices unidimensionales y multidimensionales.

Las variables numéricas por otro lado, son los elementos de mayor estudio en la estadística, sus propiedades se pueden establecer en distintos estadísticos como el promedio, varianza, correlación y demás. Con ellas se calculan distintos modelos estadísticos explicativos y predictivos.

Las variables son un detalle importante de la información estructurada. Todos los modelos y proecedimientos en adelante se apoyan en las variables y en su tipología. Otro elemento esencial para el desarrollo estadístico son los individuos.

3.1.3 ¿Qué son los individuos?

Cuando investigamos un proceso social o humano, nos damos a la tarea de encontrar cuáles son los hechos y comportamientos que conforman este fenómeno. Sin embargo, esto no ocurre en el vacio sino al interior de una comunidad o de un entrono determinado. Para recolectar la información del proceso que estudiamos, debemos acercarnos a los individuos que conforman este entorno.

Entonces, los individuos son las unidades básicas de observación o análisis dentro de una población. Pueden ser personas, objetos, organismos, eventos o entidades, dependiendo del contexto del estudio.

La elección de los individuos y su caracterización es clave, ya que determina la validez y generalizabilidad de los resultados. Este concepto está íntimamente ligado al diseño del muestreo que veremos más adelante.

en el análisis de una población no se estudian los individuos por separado y al máximo detalle, sino que se pretende identificar tendencias que representen comportamientos agregados que emergen de las características individuales de una población. A diferencia de una afirmación puntual o específica sobre un individuo, las tendencias buscan capturar patrones generalizables que describen cómo un grupo, en promedio, se comporta respecto a una variable o conjunto de variables.

En este sentido, las variables que antes explicamos, adquieren sus valores en los individuos. Es decir, cada variable con cada individuo genera un valor.

> Ejemplo
>
> Si estamos analizando el rol de la mujer en la cultura por medio de sus apariciones en películas de super héroes, la población puede ser Películas de super heroes en cine holiwoodense entre los años 2000 y 2025. Los individuos en este caso son películas.

Ejemplo

si estamos analizando temas de migración en Medellín, es posible que nuestra población sea algo parecido a Personas mayores de edad residentes en Medellín llegados entre 2000 y 2025. Los individuos son personas, en este caso.

Los individuos que se consultan durante la recolección de información se denominan la muestra. Esta muestra tiene unas propiedades matemáticas que analizaremos más adelante. La conformación correcta de una muestra requiere u diseño muestral, un tamaño muestra, en ocasiones un marco muestral y en este proceso se genera un error muestral.

3.2 Limpieza

Los datos presentan muchas veces problemas de calidad. El proceso de recolección puede generar errores que se reflejan en la información recolectada.

3.2.1 Corrección de errores

Los datos atípicos que son imposibles o indválidos deben ser corregidos en la base de datos. Generalmente, buscanos que las herramientas tecnológicas de recolección de datos tengan algo de validación para no tener que realizar estas correcciones. Revisemos los errores más frecuentes y cómo se solucionan.

En una ocasión, en un trabjo de grado, la encuesta tenía una batería de varios ítems en escala likert. Eran frases con las que una persona podía estar desde totalmente de acuerdo hst totalmente en desacuerdo. Esta escala tenía 5 niveles lo que en el momento de procesar los datos nos traía una escala de puntajes de 1 a 5. Pero en la prueba piloto nos percatmos de que las preguntas eran de informacioń sensible, esto generaba que las personas no quisieran estar muy de acuerdo ni muy en desacuerdo con los ítems y la mayoría respondía “ini de acuerdo ni en desacuerdo”. Esto nos llevó a replantear la escal likert en solo cuatro opciones, que no hubiera una opción intermedia. Pero eso significaba que los datos recolectados en la prueba piloto se perderían.

Toda esa historia es para ilustrar algunas ocasiones en las que hay datos que no se ajustan a la naturaleza de la variable. En nuestro ejemplo, la nueva variable likert de 4 valores no admitía el valor central indiferente. Cuando esto sucede, lo que hacemos es borrar estos valores que no hacen sentido con la naturalesza de las variables y luego los imputamos con alguna técnica de imputación. Cuando tenemos edades imposibles, ingresos negativos o cualquier variable mal diligenciada, podemos suprimir ese valor para que sea imputado en el paso de imputación. En nuestr ejemplo, nosotros borramos la categoría intermedia, dejando nuestros datos del piloto con 4 categorías, y luego, todos esos datos los imputamos. Y quedó bien.

En un estudio que estábamos con personas de varios países simultáneamente, en el momento de preguntar la ciudad, no podíamos poner la lista de todas las ciudades posibles de los 4 países que participaban. cada país tiene más de mil lugares donde pueden vivir las personas. Entonces lo dejamos como una pregunta abierta que se respondía con un texto corto. El resultado, una base de datos con muy buena informacioń, pero con una columna de ciudad que tenía varias versiones de cada ciudad, Santiago, Santiago de Chile, Bogotá, Bogotá D.C., bta, Ciudad de México, DF, etcétera. Una cantidad de formas distintas para decir lo mismo.

Para solucionar esto debemos seguir los siguiente pasos. 1. Generar un diccionario. en una nueva hoj de mi archivo excel puedo tomar los valores únicos de la variable en cuestión, en nuestro caso, ciudad.

Arreglar datos es complicado, porque muchas veces vienen con errores. Otra tarea abrumadora para los investigadores es codificar o decodificar bases de datos.

3.2.2 Codificación y decodificación

Qué hacer cuando el sexo es 1 - hombre y 2- mujer, o el nivel educativo es 1 -primaria incompleta, 2 - primaria completa… como en spss, Muchas veces las bases de datos tienen este tipo de codificación que fue estándar en un momento del mundo, para ahorrar espacio en el disco. Pero el almacenamiento se ha abaratado y ahora no es neceario hacer eso.

Para estos casos se necesita un diccionario especial, parecido al anterior, que nos permita entender qué toca reemplazar en donde. Los pasos son los siguientes

3.3 Estandarización

3.3.1 Identificación de atípicos

Cuando tenemos un marco de referencia definido, podemos hablar de datos atípicos. O sea, la mención de lo atípico exige de manera obligatoria la concepción de lo típico. Vamos a estructurar los datos atípicos en dos tipos: valores imposibles o inválidos y valores infrecuentes o sospechosos.

Los datos imposibles o inválidos son aquellos que se encuentran en rangos que no corresponden con la naturaleza de la variable. El dominio de la variable proviene de su naturaleza, pero también del marco de referencia.

Los datos sospechosos o poco frecuentes se encuentran en el recorrido de la variable, pero, se encuentran fuera del comportamiento usual según el marco de referencia.

Ejemplo

Cuando tenemos una base de datos y encontramos una edad negativa estamos en presencia de un dato imposible o inválido. Lo mismo pasa si en la columna de país se presenta una ciudad, o si en la etapa del proceso alguien escribió "comenzó pero luego fue cancelado". Estos problemas se resuelven con procedimientos de validación en el momento de la recolección. La mayoría de herramientas virtuales de recolección de datos tienen mecanismos de validación.

Ejemplo

En una base de datos nacional, de estudiantes de grado 11, que es el último de la educación media, podemos ver personas de 12 años y de 60 años. Estos son casos muy poco frecuentes y son sospechosos. Identificar este tipo de datos puede ser importante para revisar si realmente son datos verídicos o si hubo algún tipo de error en el momento de la recolección de información.

Ejemplo

Un ejemplo más difícil de identificar es a nivel multivatiado. Cuando el dato atípico es un dato infrecuente por combinación de variables es más difícil de identificarl. Por ejemplo, en un banco hay un formulario para pedir préstamos. Una persona conociendo las políticas de inclusión del banco, pero teniendo en cuenta la solvencia requerida, puso que vive en el estrato 1 y sus ingresos son de 10 salarios mínimos. ¿Cómo identificaríamos estos casos?

Ya contando con definiciones formales de los datos atípicos, es neresario revisar cuáles son las herramientas con las que contamos para su identificación. Vamos a centrarnos en identificar los poco frecuentes, porque los imposibles su identificación es inmediata. Vamos a presentar las herramientas estadísticas desarrolladas para la identificación de atípicos en variables numéricas, trabajando una variable (caja y bigotes) y varias variables (Mahalanobis). Los datos atípicos categóricos son mucho más fáciles de identificar, toda vez que es posible conocer sus frecuencias relativas y absolutas.

Como una primera herramienta para identificar datos atípicos inusuales, podemos utilizar el gráfico de caja y bigotes inventada por Pearson en 1985.

Este gráfico muestra los cuartiles y la mediana, formando con ellos una caja, luego extiende unos bigotes en ambas direcciónes que subtienden 0,85 del rango total, lo que les da una extensión específica. Los datos que salen de los bigotes son datos poco frecuentes, candidatos a revisón.

grafico de caja y bigotes

El gráfico de caja y bigotes funciona menos en presencia de variables sesgadas o de colas pesadas.

Para la identificación de atípicos a nivel multivariado es posible utilizar la distancia de mahalanobis al vecino más cercano. Imaginemos los datos como una nube de puntos en el plano o en el espacio. Estos puntos se distribuyen demaneras particulares, pero en todo caso, es posible ver patrones y tendencias. si a cada punto le medimos su distancia al vecino más cercano podremos identificar los puntos que se encuentran aislados.

El concepto de distancia lo trabajaremos más adelante. En este momento podemos hacer un examen sucinto. Se trata de un concepto matemático bien definido, pero bastante intuitivo. Dos datos son más lejanos cuando son menos parecidos, su distancia es mayor. De la misma manera cuando son parecidos su distancia es menor.

La distancia usual, que utilizamos todos los días, se llama la distancia euclidiana. La distancia de Mahalanobis es una modificación de esta euclidiana para incorporar la correlación de los datos. Con esto, podemos identificar de manera más rigurosa los datos que se alejan de los demás.

Con estos dos métodos es posible encontrar los datos atípicos numéricos de manera univariada y multivariada, para someterlos a revisio´n.

3.3.2 Imputación de datos

En ocasiones en una base de datos hay faltantes. Datos que no fue posible ser recolectados, esto sucede por muchas razones. Los datos senibles generalmente las personas no los responden, o porque se cansan de responder la encuesta y se van, o por muchas otras razones. Tengamos en cuenta que no vale la pena hacer imputación de datos para sacar el promedio o la varianza, sino para generar modelos estadísticos. Vamos a examinar qué hacer con estos datos, qué tipo de datos faltantes hay y como proceder con ellos.

Los datos sensibles son aquellos que

La forma en la que los datos se pierden es importante también

Datos faltantes MNAR

Datos faltantes MAR

Datos faltantes MCAR

> Ejemplo
>
> Por ejemplo, cuando hicimos una encuesta con jóvenes y en una pregunta indagamos por el consumo de sustancias psicotrópicas, la pregunta no era obligatoria, entonces muchos no la respondieron. Esto es un dato perdido MNAR.

Una noticia buena y una mala, primero la mala. En el caso de los datos MNAR, no es posible generarlos de manera rigurosa. Por consiguiente, es necesario revisar, si son pocos, retirar los individuos que faltan de esta información en los procedimientos que esta información se requiera. Si son muchos, ya toca es retirar la variable como tal. Pero la buena es que los datos MAR y MCAR sí se pueden imputar. Como su pérdida no responde a un proceso propio del contexto, podemos hacer pronósticos utilizando algún modelo.

El método recomendado para imputación de datos se llama MICE. Una de las propuestas mejor comportadas en este tema es la imputación multivariada por ecuaciones concatenadas (MICE, por su sigla en inglés) [@AZUR_MICE] que plantea la posibilidad de realizar modelos de pronóstico de manera iterativa para reemplazar los vacíos por su pronóstico.

En detalle, MICE toma cada una de las variables dentro de la base de datos como variable respuesta y mediante una regresión pronostica los valores faltantes a partir de las demás variables. Esto realizado de manera iterativa produce valores que si bien no corresponden de manera precisa a los no observados, sí resultan ser cercanos en términos de pronóstico.

como hacer imputacion de datos con inteligencia artificial.

La imputación de datos es importante realizarla de manera responsable.

3.3.3 Escalamiento univariado

En algunos de los algoritmos que vamos a usar tenemos problemas si las variables no se encuentran en la misma escala. Para poner un ejemplo, si sumamos 1 a variables ditintas el cambio es muy diferente. Para una persona pasar de 50 kilos de peso a 51 kilos es algo normal, pero pasar de 1.6 metros de estatura a 2.6 metros es un cambio un poco drástico. Muchos algorimos requieren que las variables se encuentren en la misma escala. Con el fin de que todas las variables se encuentren en la misma escala, es posible realizar algunos procedimientos que nos ayudan a esta tarea. estos procedimientos tienen sentido en variables numéricas.

Normalizar es restar la media y dividir por la desgiación estándar

Fórmula

$$z = \frac{x - \bar{x}}{S_x}$$

Estandarizar es llevar la variable al intervalo [0,1] o a un intervalo conocido.

Fórmula

$$z = \frac{x - x_{min}}{x_{max} - x_{min}}$$

El trabajo con rangos tiene varias utilidades importantes. Uniformizar es cambiar la variable por su cuantil.

Fórmula

$$u = \frac{n(x_i < x)}{n()}$$

Cada uno de estos procedimientos tiene sus partícularidades, pero funcionan correctamente a la hora de mostrar las variables en una sola escala.

3.4 Estructura

Intervenir la estructura de los datos es un proceso normal en la conformacio´n de modelos estadísticos. Muchas veces la información no de encuentra en el formato que el modelo recibe. A contonuación vamos a tocar brevemente las modificaciones más frecuentes a la estructura de la información. Por ser herramientas un poco más avanzadas, algunas no tienen una implementación usando inteligencia artificial.

3.4.1 Cambio de tipo de variable

Si un modelo o algoritmo solo recibe variables numéricas y la información es mayoritariamente categórica se presenta un pronblema. Es necesario encontrar la manera de codificar numéricamente las categorías conservando su identidad y significado de una forma matemáticamente válida.

Las variables tipo likert tienen valores categóricos como siempre, casi siempre, casi nunca y nunca. Estos, generalmente admiten otorgarles unos puntajes a priori, que van de acuerdo al sentido de la pregunta. En este caso, de variables likert, su transformación en variables numéricas es natural y no genera ruido.

Para las variables categóricas que no tienen unos valores numéricos estandarizados, se suele utilizar el método de variables dummies o método hotkey. Este consiste en transformar una columna categórica en varias columnas numéricas, dependiendo de la cantidad de categorías. Cada columna nueva marca 1 o 0 dependiendo si la variable adquiere esa categoría o no. Esto amplía de forma notoria la cantidad de variables, pero permite capturar la información completa de nuestra variable categórica. Claramente, los límites computacionales nos pueden indicar hasta cuántas categorías diferentes podemos procesar.

Ejemplo

En una base de datos teníamos la variable de nivel educativo. Se había preguntado a las personas cuál es el último nivel educativo que ud finalizó exitosamente. Ninguno, primaria, secundaria técnico, universitario y postgrado. Estas son las opcioones. En el estudio, un científico social propuso que les diéramos valores: Ninguno = 0, primaria = 1, secundaria = 2, técnico = 3, universitario = 4 y postgrado = 5. Le explicamos que estos valores no se pueden colocar así y que la manera correcta es hacer una tabla con 5 columnas: Ninguno, primaria, secundaria técnico, universitario y postgrado, cada columna es binaria y marca 1 solamente para las personas que se encuentren en esa categoría.

Ejemplo

En una base de datos una vez teníamos la columna de los municipios. Cuando hicimos el hot encoding, nos dimos cuenta de que el resultado era una tabla de 1120 columnas. Tuvimos que analizar si eso era realmente lo que queríamos. Por fortuna, los datos se concentraban mayoritariamente en 10 municipios, y pudimos recategorizar todos los otros municipios en una categoría nueva llamada “Otros”. Funcionó muy bien.

Ejemplo

A veces tenemos columnas que denominamos de opción múltiple con múltiple respuesta. Por ejemplo, una plataforma de streaming como netflix o youtube ppuede tener la información de los videos que hemos visto. Se trata de una columna categórica donde cada individuo presenta muchos datos. Esto incumple el principio de atomicidad de la informacióin. En estos casos es muy útil separar la información en columnas. Entonces tendríamos una columna por cada película y una fila por cada persona. Mostrando inicialmente si vio la plícula o no la vio. So además tuviéramos en cada caso el puntaje que le dio la persona a la película, con esto podríamos construir un modelo de recomendación! Todas las plataformas tienen distintos modelos de recomendación. El modelo de recomendación de netflix cuesta un millón de dólares.

Ejemplo

El análisis de estas bases de datos que tienen muchas columnas de unos y ceros es una rama importante de la ciencia de datos, podemos imaginar un caso muy parecido con productos y compradores, una base de datos de facturas tendría una columna para cada producto y una fila para cada factura, indicando si el producto pertenece a la factura o no.

Ejemplo

En análisis cualitativo tenemos este mismo caso. Si tenemos piezas de informacion que pueden ser imágenes, texto y otras piezas; y por otro lado tenemos categorías inductivas y deductivas y emergentes que surgen de un ejercicio de codificacion abierta, Podemos generar una tabla donde cada categoría es una columna, codificando 1 o 0 dependiendo si la categoría se encuentra presente en la pieza de información. Esto lo retomaremos más adelante.

El caso contrario es menos frecuente. Sucede casi siempre en procesos de medición que contienen índices e indicadores y se maneja usualmente a nivel univariado y bivariado.

A nivel univariado, puedo tener una culumna que me indique una propiedad de mi muestra. Esto puede ser un índice, una métrica, una escala o un indicador. Y en ese caso yo puedo dar unos umbrales y generar unos niveles para mi indicador. Usualmente se distribuyen en alto, medio y bajo; pero también puede ser Alto, medio alto, medio bajo y bajo. El cálculod e los umbrales se puede realizar de varias formas, de acuerdo a la distribución de los datos, buscando que todos los niveles queden con la misma cantidad de registros, o según el diseño mismo del indicador. ESto difiere en cada caso que se administra.

Cuando quiero conformar una variable categórica a partir de dos o más variabels numéricas, podemos hablar de un cuadrante. La confomración de cuadrantes es una herramienta muy poderosa para la interpretación de resultados. Un cuadrante se conforma cuando pongo uno o varios umbrales a cada uno de mis indicadores y esto me genera nuevas categorías. Cada categoría debo ponerle un nombre.

Ejemplo

En una encuesta de niñez obtuvimos métricas para la vulnerabilidad de los niños y la proteccio´n de los padres. Luego generamos un umbral para cada métrica y lo codificamos como alto y bajo. Teníamos entonces nuestras variables categóricas que decían alta y baja protección y alta y baja vulnerabilidad. Este es un ejemplo de discretización de la variable a nivel univariado.

Ejemplo

En la misma encuestra generamos un cuadrante con nuestros valores y los combinamos así: alta vulnerabilibad y alta protección = hogar comprometido, baja vulnerabilidad y baja protección = hogar autónomo, alta vulnerabilidad y baja protección = hogar abandonado y baja vulnerabilidad y alta proteccio´n = hogar sobreprotegido. Esto es un ejemplo de como funcionan los cuadrantes para combinar dos variables numéricas en una sola variable categórica.

3.4.2 Muestras de entrenamieto y de prueba

Cuando queremos generar modelos estadísticos y de ciencia de datos, normalmente nos preocupa que estos modelos y algoritmos sigan funcionando con datos más allá de la muestra. Esto se llama inferencia y es de lo que trata el siguiente capítulo. Todos nuestros métodos y modelos son calculados con datos presentes en algún archivo. No puede ser de otra manera, no podemos incluir en el cálculo datos que no tenemos. Pero entonces cómo podemos asegurarnos de que nuestro desarrollo estadístico sea robusto frente a datos que nos están en la muestra? Esta pregunta se resuelve de dos maneras.

La solución matemática nos indica que podemos confiar en nuestras estimaciones si siguen unas reglas predefinidas, algunas veces es normalidad, heterocedasticidad y muchas otras reglas. La solución práctica no requiere estas reglas, se llama validación cruzada. Consiste en ajustar los modelos utilizando solamente una parte de nuestros datos, esta se llama muestra de entrenamiento, y luego, poniéndolos a prueba con otra parte de la información, esto se denimina muestra de prueba.

Si nuestros métodos son confiables, podemos establecer que los errores muestrales que son reportados por el modelo usando la muestra de entrenamiento, coinciden con los errores muestrales reportados sobre la muestra de prueba.

La validacio´n cruzadas no se detiene allí, existe toda una teoría de cómo generar validaciones cruzadas de manera efectiva. Una de ellas es el bootstrapping o remuestreo. En bootstrapping generamos muchas submuestras aleatoriascon reemplazo del mismo tamaño que la muestra original y para cada una de estas muestras calculamos el modelo. Normalmente esto se realiza muchas veces, es usual encontrar que un bootstrapping se cacula sobre mil muestras.

Imagínate, calcular el mismo modelo miles de veces. Obviamente resulta computacionalmente pesado. En cuanto tenemos todos esos modelos podemos revisar cómo se comportan sus parámetros, cuál es el error muestral de cada uno, cómo es su estructura general y de allí tomar decisiones.

La validacio´n cruzada también se complica un poco cuando queremos ir más allá. Podemos hacer particiones. Partir nuestra meustra en cinco subconjuntos iguales, de manera aleatorio y calcular cinco modelos retirando cada parte. Esto es, retiramos la primera muestra y calculamos el modelo, retiramos la segunda y calculamos el modelo, retiramos la tercera y así sucesivamente. Al final tenemos cinco modelos que podemos compribar contra los datos de prueba de cada uno. Esto nos tiene que dar luces sobre la precisio´n y certeza correspondiente a los métodos aplicados.

Entonces, una manera importante de preparar los datos es tomar en consideración la validacion cruzada y agregar la columna correspondiente para que sepamos cuáles observaciones perteneceen a la muestra de entrenamiento y a la de prueba.

3.4.3 Anonimización

El tratamiento de los datos recolectados muchas veces tiene un componente ético que debemos revisar. Los datos sensibles, de salud, de ingresos, el género y las preferencias sexuales, las opiniones sobre temas controversiales y las aciones que conllevan escarnio social, son datos que las personas nos confían bajo un estandar ético de investigación.

Los datos de identificación deben ser retirados de las bases de datos en la etapa de limpieza, de manera que no sea posible saber de qué persona son cuales datos.

Sin embargo esto no es suficiente, al retirar la identificación subsiste muchas veces la identificabilidad. Datos que son únicos y reconocibles de un individuo específico. Estos deben ser recategorizados. Es un problema crítico, porque suele evidenciar a las minorías.

> Ejemplo
>
> En una ocasión, una científica social quería hacer un estudio para su tesis para su maestría en el extranjero. Eligió el tema de la poesía y como pervive en las comunidades. Fue al territorio y entrevistó varias personas. Ellos, en la entrevista, además de hablar sobre la poesía, en medio de su relato mencionaban algunos actores al margen de la ley. Esto es muy grave, porque estas personas no podían hablar de esto, en el territorio se sabía que hablar sobre estos temas tenía consecuencias graves. La investigadora recolectó la información y construyó su tesis, que fue laureada. Ella inclyó como anexo en su tesis las entrevistas, pero olvidó anonimizarlas. Este documento, con estos anexos, llegó al repositorio institucional. De manera que, cuando ella se percató, ya todo el documento estaba público. Hoy en día, si cualquier actor armado busca en ese repositorio puede encontrar con nombre propio el relato de las personas. Esto es muy grave.

Es muy importante este punto, sobretodo si trabajamos con inteligencia artificial y queremos cargar una tabla de datos en una interfaz conversacional interactiva.

3.4.4 Estructurar data no estructurada

Estructurar data no estructurada requiere un poco más de trabajo. Al respecto vamos a hablar brevemente de dos maneras distintas que producen resultados parecidos.

Dentro de la teoría fundamentada existe este paso que se llama codificacion axial, que consiste en relacionar unas categorías inductivas y deductivas con un conjunto de peizas de información. Esta tarea arroja una data estructurada, que me permite entender cuáles categorías están presentes en cada peiza de informacio´n. Como se dijo anteriormente, es posible obtener una tabla que nos indica si dentro de este audio, imagen, o texto se encuentra una categoría. En esta tabla cada categoría es una variable binaria.

Otrra manera de lograr lo mismo, pero solamente para texto, es la técnica de bag of words. Que consiste en generar una columna por ccada término o palabras presentes en el discruso. Para ello es necesario realizar acciones de limpieza de texto y tokenización. Ahora, con esto se obtienen tablas muy grandes, de miles de columnas porque las palabras distintas en un corpus textual pueden ser mucahs.

Cuando tenemos datos de otros formatos, como audio, video o imagen, es posible también generar una tabla de datos binarios con categorías, etiquetas u objetos utilizando inteligencia artificial. Estas matrices binarias terminan siendo el insumo para un análisis cualitativo riguroso.

4 Uso de inteligencia artificial

4.1 Consideraciones

4.1.1 el proceso creativo en investigacion

NA

NA

NA

NA

4.1.2 problemas éticos

NA

NA

NA

NA

4.1.3 consentimientos informados, protocolos

NA

NA

NA

NA

4.1.4 trazabilidad y reproducibilidad

NA

NA

NA

NA

4.2 Uso y apropiación

4.2.1 prompt engineering

NA

NA

NA

NA

4.2.2 procesos de datos con inteligencia artificial (código python)

NA

NA

NA

NA

4.2.3 subir datos, qué datos subir

NA

NA

NA

NA

5 Un breve ensayo sobre distribuciones

5.1 qUÉ SON

NA

5.2 Distribuciones discretas

NA

5.3 Distribuciones continuas SIMÉTRICAS

NA

5.4 Distribuciones continuas ASIMÉTRICAS Y SESGADAS

NA

5.5 supuestos distribucionales

NA

5.6 estadística paramétrica

NA

5.7 estadística no paramétrica

NA

5.8 métodos computacionales

NA

Part II

Estadística inferencial

6 Epistemología de la inferencia estadística

El objetivo de la ciencia es el descubrimiento de verdades generales. Los hechos particulares, por supuesto, son fundamentales, pero una simple recopilación de hechos no constituye una ciencia. Al terminar esta sección, podremos reconocer que gran parte de la estadística está orientada a reconciliar dos mundos. Lo que se ve y lo que no se ve. Los casos individuales como parte de un sistema. Las apreciaciones basadas en evidencia que se reconocen como reglas del entonro. Es importante plantearlo así, porque este es el centro de la estadística.

Uno de los métodos de razonamiento empleados hoy en día en estadística y en las ciencias en general es la inferencia, y sus raíces se hallan profundamente en la filosofía clásica y en el desarrollo del método científico moderno. Por ello, para comprender cómo surgió la inferencia estadística y en qué se fundamenta, es necesario entender primero sus bases epistemológicas.

6.1 Los antiguos griegos y la deducción

6.1.1 Sócrates y la mayeutica

Sócrates fue de los primeros en cuenstionar los métodos implementados para la búsqueda de la verdad. El método mayéutico consistía en formular preguntas para ayudar a su interlocutor a descubrir conocimientos por sí mismo, partiendo de sus propias creencias y explorando las inconsistencias en sus respuestas.

El ejercicio de definir el tema, indagar al respecto, construir lo esencial y lo accidental, y llegar a la contradicción partiendo de la ignorancia, es un método preliminar al que hopy tenemios y sienta las bases para el trabajo posterior.

6.1.2 Platón y la dialéctica

Alumno de Sócrates, Platón crea el método dialéctico.

Con este método construye la república y muchos otros de los grandes tomos en los que se fundamenta la filosofía actual.

6.1.3 Aristóteles y la lógica

La sistematización del conocimiento en forma de premisas y conclusiones genera el método deductivo que Aristóteles deniminó Lógica.

Pasamos de indagar al rededor de un concepto a generar nuevo conocimiento sobre el mismo a partir de sus propiedades más básicas. Las reglas que permiten deducir las conclusiones a partir de las premisas esas reglas son la lógica. El objeto de estudio de la lógica es la validez del pensamiento,

6.1.4 El silogismo

Uno de los aportes más significativos de aristóteles es el silogismo. Se trata de una estructura de premisas que llevan a una conclusión. Esta estructura es el fundamento del pensamieno deductivo.

La deducción es, entonces, la generacioń de conclusiones a partir de premisas utilizando reglas lógicas.

> Ejemplo
>
> El ejemplo clásico, empleado por el mismo Aristóteles, está compuesto por las siguientes premisas: (a) Todos los hombres son mortales. (b) Sócrates es un hombre. Y supone, como conclusión, que: (c) Sócrates es mortal.

6.1.5 Pensamiento deductivo

De estas reglas generales del silogismo es posible extraer unas características propias de la deducción, a saber, que en este tipo de razonamiento la conclusión se deriva de las premisas y su conclusión no puede exceder la extensión o cantidad de ninguna de sus premisas. Este aspecto supone una enorme restricción en su uso dentro de la argumentación científica, a menos que se haga referencia a verdades formales, como en el caso de la matemática.

Un ejemplo del uso del método deductivo es el segundo libro más editado de la historia, *Los Elementos* de Euclides, que organiza el conocimiento geométrico mediante un sistema axiomático. En este texto, Euclides parte de unos pocos postulados y axiomas fundamentales, a partir de los cuales deduce rigurosamente una serie de teoremas y proposiciones.

Otros ejemplos son *Ética demostrada según el orden geométrico* de Spinoza y *Philosophiæ Naturalis Principia Mathematica* de Isaac Newton. En la *Ética*, Spinoza estructura su filosofía siguiendo el estilo geométrico de Euclides, utilizando definiciones, axiomas y proposiciones para desarrollar sus ideas sobre la naturaleza de Dios, la mente y la moralidad. Por su parte, en los *Principia Mathematica*, Newton aplica un razonamiento deductivo para establecer las leyes

del movimiento y la gravitación universal, partiendo de principios fundamentales y llegando a conclusiones que explican fenómenos físicos observables.

6.2 El Novum Organum de Bacon

En el siglo XVII, Francis Bacon introdujo un enfoque revolucionario en su obra *Novum Organum*, defiende la inducción como el método verdadero frente a la deducción. Los científicos deben construir reglas generales a partir de casos observados.

6.2.1 La deducción contra la inducción

Bacon se aleja de Aristóteles y del pensamiento deductivo porque lo encuentra estéril.

La verdad está ligada a los sentidos y de allí se extraen los principios que dan paso a la construcción científica. De las caracterísiticas comunes de muchos casos se generan unos principios generales que construyen poco a poco el cuerpo de una disciplina científica.

En su momento este pensamiento es una innovación radical en las formas que occidente desarrollaba para conocer el mundo. El contexo histórico nos muestra esto.

una revaloración del procedimiento inductivo y por un cuestionamiento radical del modelo deductivo propio del silogismo. No obstante, la observación de los casos particulares también debe ser depurada de los prejuicios que constantemente acechan al conocimiento y que Bacon describe minuciosamente en su doctrina de los ídolos.

6.2.2 El cisne negro

Los desarrollos de Bacon fueron integrados en un mundo que daba por cierto el conocimiento científico, de manera permanente e inamovible. La crítica al pensamiento inductivo era clara, es posible que las reglas concebidas a partir de casos sean falsas en el futuro si se descubren otros casos que no las sigan.

El descubrimiento de un cisne negro representa este riesgo. En el momento en que hay cisnes negros en australia, la afirmación todos los cisnes son blancos" pasa a ser falsa. ESto deja obsoletos los lobros de ciencia y genera discusión frente al método científico.

6.3 Fisher, Neyman, Pearson

El método inductivo genera riesgos que no son fáciles de contener. cConfomre pasa el tiempo, se hace más difícil abordar problemas que pueden tener variabilidad en sus casos.

6.3.1 Las reglas para hacer inducción

La inferencia estadística nace de un conjunto de buenas prácticas orientadas a garantizar que el conocimiento de muchos casos se pudiera resumir en unas cuantas reglas.

En la estadística moderna, Ronald A. Fisher, Jerzy Neyman y Egon Pearson fueron fundamentales para estructurar las **reglas para hacer inducción**. Su trabajo permitió la formalización de métodos inferenciales que ayudan a generalizar conclusiones a partir de muestras. Estas reglas establecen la estructura de las pruebas de hipótesis y la generación de intervalos de confianza, permitiendo a los científicos tomar decisiones con base en evidencia empírica.

Fisher, Neyman y Pearson desarrollaron metodologías para derivar conocimiento a partir de datos de manera rigurosa, incorporando conceptos como la probabilidad y el error estadístico. A través de la estadística inferencial, lograron definir un proceso sistemático para probar hipótesis, medir la incertidumbre y proporcionar intervalos de confianza, contribuyendo significativamente a las ciencias experimentales y sociales.

6.3.2 Inferencia estadística

Fisher introdujo conceptos fundamentales como el "p-valor" y la prueba de hipótesis, mientras que Neyman y Pearson formalizaron la teoría de pruebas con su trabajo sobre errores tipo I y II y la formulación de intervalos de confianza.

La inferencia estadística se basa en la comparación de dos hipótesis. Las hipótesis pertenecen al mundo teórico, son los ladrillos que construyen los modelos científicos. Se comparan doos hipótesis una hipótesis nula, que es imposible de probar, versus una hipótesis alterna, cuya demostracion recae en la evidencia. En general la tarea se trata de decidir si se rechaza o no la hipótesis nula.

Error tipo I (( )): falso positivo. Rechazas la hipótesis nula cuando es verdadera. Concluyes que existe un efecto o una diferencia que realmente no existe.

Error tipo II (( )): falso negativo. No rechazas la hipótesis nula cuando es falsa. No detectas un efecto o una diferencia que realmente existe.

La inferencia estadística se consolidó rápidamente en diversas áreas científicas, desde la biología y la medicina hasta las ciencias sociales y económicas, transformando la manera en que los investigadores validan teorías y estiman parámetros poblacionales. La inferencia estadística constituye la manera en la que hacemos inducción. Pasando de lo particular a lo general, o een otras palabras, de la muestra a la población.

6.4 El concepto de medición

6.4.1 Medición

En todo esto, la definición más difícil es la de medición. Medir constituye en esencia, relacionar lo teórico, los conceptos, las categorías, las características… con la realidad tangible, por medio de valores. Es necesario, para comprender esto, revisar las definiciones previas.

Norman R. Campbell, 1920 Campbell plantea una definición extraordinariamente temprana y fundamental: "Measurement is the process of assigning numbers to represent qualities." [@Campbell], [@N.R.(1920).Physics:TheElements.CambridgeUniversityPress.]

1938 Campbell "Measurement is the assignment of numerals to represent properties of material systems other than number, in virtue of the laws governing these properties." [@Campbell], [@N.R.(1938).AnAccountofthePrinciplesofMeasurementandCalculation.Longmans], [@GreenandCo.]

El cambio entre números y numerales es lo que le da sentido a una nueva forma de medir. Los números corresponden a variables numéricas, los numerales permiten incluir categorías y otras formas. Esto está más explícito en la definicio´n de stevens

S. S. Stevens, 1946 "Measurement, in the broadest sense, is defined as the assignment of numerals to objects or events according to rules." [@Stevens], [@S.S.(1946).Onthetheoryofscalesofmeasurement.Science], [@103(2684)], [@677–680.https://doi.org/10.1126/science.103.2684.677]

En el lenguaje actual, denominamos valores a lo que en estas definiciones denominan numerales. Una variable puede adquirir diferentes valores en diferentes individuos. De acuerdo a eso, los datos nos muestran los valores que toma una colección de variables en un grupo de individuos.

Entonces, para el presente manuscrito podemos tomar prestada la definición anterior y modificarla un poco, así: "Medir es asignar valores a carácter+isticas de sujetos, objetos o eventos en concordancia con un marco de referencia."

En otro lado tenemos el problema de observar. En general estas definiciones de medición se entienden como producto de la observación directa. Es decir, que los valores de las variables se observan directamente sobre los individuos. Sin embargo, las definiciones presentadas no presentan esta restricción, permitiendo definir medición directa e indirecta.

Medición direfta, entonces, es la que se produce por medio de la observación directa de las características en los individuos.

Medición indirecta, es aquella que se produce por medio de laconstrucción de instrumentos que componen distintas medicinoes directas para producir valores que reflejan una característica que difícilmente se puede medir de manera directa.

7 Muestreo

El muestreo tiene un problema, y es que cuando alguien quiere repetir la tarea, si elige otra muestra diferente, de la misma población, probablemente tenga resultados distintos.

¿Qué hacemos para probar la sopa? Sacamos una cucharada, la probamos y obtenemos una conclusión sobre toda la sopa sin haberla probado toda. Si la muestra ha sido tomada sin trampas, sin escoger lo que más conviene, podemos tener una idea del sabor de la sopa. Este es el principio subyacente de la inferencia estadística.

Los investigadores quieren averiguar algo sobre una población, pero no tienen tiempo o dinero para estudiarla toda. ¿qué hacen? Seleccionan una cantidad pequeña de unidades de la población , estudian esas unidades, generalmente individuos, y utilizan esa información para sacar conclusiones sobre toda de la población.

7.1 Contexto

7.1.1 Tendencias

No buscamos genera afirmaciones individuales. comportamientos globales en torno a un proceso que no corresponden al comportamiento de los individuos de manera puntual. Las tendencias son comportamientos globales, que los individuos acatan probablemente.

7.1.2 Individuos

Los individuos Son unidades de análisis sobre las cuales vamos a generar un modelo. Son el sujeto de nuestra teoría.

7.1.3 Población

Para cualquier pregunta que interese responder, primero es necesario dirigir la atención a un grupo particular de individuos: personas, ciudades, animales, televisores, discos rígidos, tornillos o lamparitas.

7.1.4 Muestra

Es un subconjunto de la población.

7.1.5 Representatividad

Una muestra es representativa de la población cuando todas las características importantes de la población tienen que estar en la muestra en la misma proporción que en la población.

7.2 Conceptos

7.2.1 Marco muestral

El marco muestral es el conjunto de todos los elementos o unidades de la población que son accesibles para ser seleccionados en la muestra.

Este marco debe ser representativo de (preferiblemente contener toda) la población objetivo para garantizar la validez de los resultados. Un marco muestral bien definido es crucial para evitar sesgos en la selección de la muestra.

7.2.2 Diseño muestral

El diseño muestral es el plan que describe cómo se selecciona la muestra a partir del marco muestral. Puede incluir diferentes técnicas de muestreo, como el muestreo aleatorio simple, el muestreo estratificado, el muestreo por conglomerados, entre otros.

La elección del diseño depende de los objetivos del estudio, las características de la población y los recursos disponibles.

Es el diseño muestral lo que le da representatividad a la muestra.

7.2.3 Error muestral

El error muestral es la diferencia entre el valor estimado a partir de la muestra y el valor real en la población. Este error surge debido a que la muestra es solo una parte de la población y no refleja completamente su variabilidad.

El tamaño de la muestra, el diseño muestral y el método de estimación influyen en la magnitud del error muestral.

7.2.4 Tamaño muestral

El tamaño muestral es la cantidad de unidades que se seleccionarán del marco muestral para ser incluidas en el estudio. Un tamaño muestral adecuado es fundamental para asegurar la precisión y confiabilidad de los resultados.

La determinación del tamaño muestral depende del nivel de confianza deseado, el margen de error aceptable y la variabilidad esperada en la población.

Es el tamaño muestral lo que le da significancia a las estimaciones. No hay muestras significativas.

7.2.5 Muestreo no probabilístico

No todos los elementos tienen probabilidad de ser seleccionados

- La muestra no es representativa (rigurosamente)
- No es posible calcular el error muestral
- Requiere menos recursos

Algunas de las técnicas de este tipo de muestreo son

- Por cuotas
- Bola de nieve
- Discrecional
- Conveniencia
- Accidental

7.2.6 Muestreo probabilístico

Todos los individuos en la población tienen una probabilidad específica de ser seleccionados para la muestra.

- Aleatorio simple
- Por etapas
- Por conglomerados
- Por estratos

7.3 Muestreo no probabilístico

Aclarando que el muestreo no probabilístico no produce muestras necesriamente representativas, incluso aumentando sustancialmente el tamaño muestral, se presentan algunas écnicas

7.3.1 Muestreo por cuotas

Consiste en dividir la población en segmentos y obtener una cuota de cada segmento.

Se utiliza cuando se tienen segmentos relevantes pero no se tiene acceso al marco muestral.

> Ejemplo
>
> Se utiliza cuando se tienen segmentos relevantes pero no se tiene acceso al marco muestral. En un estudio sobre preferencias de compra de automóviles, se decide utilizar el muestreo por cuotas para asegurar que la muestra sea representativa en términos de género y edad. El investigador establece cuotas basadas en la distribución de la población: - **Género**: 50% hombres, 50% mujeres. - **Edad**: 25% de 18-29 años, 25% de 30-39 años, 25% de 40-49 años, 25% de 50 años o más. El investigador luego selecciona participantes hasta que se cumplan las cuotas establecidas, por ejemplo, 100 hombres y 100 mujeres, distribuidos equitativamente entre los diferentes grupos de edad.

Este método asegura que todas las categorías importantes estén adecuadamente representadas en la muestra.

7.3.2 Bola de nieve

Cada individuo refiere nuevos individuos.

Se utiliza con poblaciones sensibles.

> Ejemplo
>
> En un estudio sobre los hábitos de ahorro entre migrantes de un país específico, se utiliza el muestreo bola de nieve debido a la dificultad de acceder a esta población. El investigador comienza con un pequeño grupo de migrantes conocidos que participan en el estudio. Luego, estos participantes refieren a otros migrantes que también podrían estar interesados en participar.

A medida que más personas son entrevistadas, se continúa pidiendo referencias, lo que permite que la muestra "crezca como una bola de nieve". Este método es especialmente útil para poblaciones difíciles de alcanzar o cuando no existe un marco muestral claro.

7.3.3 Muestreo direccional

Consiste en tomar de la población los individuos que resulten representativos bajo el jucio de un experto

Se utiliza cuando hay un experto que ha realizado estudios previos.

> Ejemplo
>
> En un estudio exploratorio sobre las opiniones de expertos en inteligencia artificial, se decide utilizar el muestreo discrecional. El investigador selecciona intencionadamente a un grupo de 10 expertos reconocidos en el campo, basándose en su conocimiento y reputación en la industria.

La selección no es aleatoria, sino que se realiza según el criterio del investigador, quien elige a estos expertos por considerarlos los más apropiados para proporcionar información valiosa y relevante para el estudio.

7.3.4 Muestreo por convivencia

Consiste en estudiar los individuos más cercanos o voluntarios, ya que estos son más accesibles.

Se utiliza en estudios cuyas poblaciones no son accesibles.

> Ejemplo
>
> En un estudio piloto sobre las preferencias de snacks saludables entre estudiantes universitarios, el investigador utiliza el muestreo por conveniencia debido a limitaciones de tiempo y recursos.

El investigador selecciona a los estudiantes del curso de muestreo para que respondan a una breve encuesta. Este método se elige porque los participantes son fácilmente accesibles, aunque no necesariamente representan a toda la población estudiantil.

7.3.5 Muestreo accidental

Se selecciona un mecanismo de selección o acceso a los individuos encontrándolos por casualidad en un espacio definido sin ningún juicio previo.

Se utiliza en poblaciones particularmente grandes con fines descriptivos y prácticos.

Ejemplo

En un estudio sobre las tendencias de la moda un investigador utiliza el muestreo accidental. Se aborda a los primeros 30 clientes que ingresan en una tienda de ropa durante una mañana para que respondan a una encuesta de satisfacción

Este método es accidental porque se seleccionan a los participantes en el lugar y momento de recolección.

7.4 Muestreo probabilístico

7.4.1 Muestreo aleatorio simple

El muestreo aleatorio simple es el más básico, consiste en la selección completamente aleatoria de la muestra.

Definir la población Obtener el marco muestral Definir un tamaño muestral n Elegir aleatoriamente n ondividuos de la población

Ejemplo

En un estudio sobre los hábitos de lectura de la población adulta en una ciudad, se decide utilizar el muestreo aleatorio simple. A partir de un listado completo de los 10,000 residentes adultos de la ciudad, el investigador selecciona 500 personas utilizando un generador de números aleatorios.

Cada individuo tiene la misma probabilidad de ser seleccionado, lo que asegura que la muestra sea representativa de toda la población, minimizando sesgos en la selección.

7.4.2 Muestreo por etapas

Es un muestreo que se realiza en varias etapas. Está diseñado para casos en onde los individuos se distribuyen en grupos. Si no tenemos el marco mustral de todos los individuos, pero sabemos que se disttribuyen en grupos y tenemos el marco muestral de los grupos, pooemos obtener una muestra aleatoria de los grupos y seleccionar una muestra de individuos sobre los grupos slseleccionados.

Se denomina Bietápico (2 etapas) Polietápico (3 etapas o más) Es necesario calcular tamaño muestral en cada etapa

Ejemplo

En un estudio nacional sobre el nivel educativo en zonas rurales, se utiliza el muestreo por etapas para facilitar la selección de la muestra. 1. **Primera etapa**: Se seleccionan al azar 10 estados de un total de 32 en el país.2 . **Segunda etapa**: Dentro de cada estado seleccionado, se eligen aleatoriamente 3 municipios rurales. 3. **Tercera etapa**: En cada municipio, se seleccionan aleatoriamente 5 escuelas primarias. 4. **Cuarta etapa**: Dentro de cada escuela seleccionada, se eligen al azar 30 estudiantes para participar en el estudio.

Este método permite una selección eficiente y representativa en poblaciones grandes y dispersas, utilizando un enfoque jerárquico y secuencial.

7.4.3 Muestreo por conglomerados

Es un tipo especial del muestreo por etapas, en este caso, hay una etapa que no es necesario incluir todos los grupos. Con solo una muestra es suficiente.

Son heterogéneos en su interior. Son homogéneos entre sí Se selecciona una muestra primaria Se selecciona una muestra secundaria Ejemplo: ciudades, salones, centros comerciales

Ejemplo

En un estudio sobre el impacto de programas educativos en escuelas primarias, se utiliza el muestreo por conglomerados para simplificar el proceso de recolección de datos. 1. **Primera etapa**: Se seleccionan al azar 20 escuelas primarias de un listado completo de 200 en una región determinada. 2. **Segunda etapa**: Dentro de cada escuela seleccionada, se eligen al azar 3 clases para participar en el estudio. 3. **Tercera etapa**: Se recopilan datos de todos los estudiantes de las clases seleccionadas.

Este método es útil cuando la población está agrupada en unidades naturales, como escuelas o barrios, y facilita la logística y los costos al reducir el número de unidades primarias que se deben tratar.

7.4.4 Muestreo estratificado

Es un tipo especial del muestreo por etapas, en este caso, hay una etapa que es necesarioincluir todos los grupos.

Los estratos: Son homogéneos en su interior Son heterogéneos entre sí Se selecciona una censo de estratos Se selecciona una muestra de unidades

Ejemplo

En un estudio sobre la satisfacción laboral en una empresa multinacional, se utiliza el muestreo estratificado para asegurar que todas las divisiones y niveles jerárquicos de la empresa estén representados. 1. **Primera etapa**: Se divide a los empleados en diferentes estratos según su departamento (por ejemplo, Finanzas, Recursos Humanos, Marketing, etc.). 2. **Segunda etapa**: Se selecciona una muestra aleatoria de empleados de cada estrato para participar en la encuesta de satisfacción.

Este método garantiza que cada subgrupo relevante dentro de la población esté representado en la muestra, permitiendo comparaciones más precisas entre diferentes departamentos y niveles jerárquicos.

7.4.5 Factores de expansión

Cuando tenemos un diseño muestral, es posible saber cuántos individuos de la población son representados por un individuo de la muestra. Esta cantidad se denomina *Factores de expansión*.

Los factores de expansión son particularmente útiles para calcular totales poblacionales.

8 Estimación

8.1 Conceptos iniciales

Iniciamos por los conceptos que son fundamentales para entender la estimación en inferencia estadística. Estos conceptos ayudan a diferenciar entre la población y la muestra, así como a identificar las características numéricas que se desea estimar.

8.1.1 Población

La **población** se refiere al conjunto completo de individuos, elementos o unidades que comparten una característica particular que se está estudiando. Es el conjunto completo sobre el que quermos conversar.

> Ejemplo
>
> Por ejemplo, si estamos interesados en el ingreso anual de todos los empleados de una empresa, la población sería todos los empleados.

En la inferencia estadística, es crucial definir claramente la población para poder aplicar métodos de muestreo adecuados y realizar estimaciones precisas. Delimitar la población es el primer paso que se realiza al diseñar un estudio.

Para definir claramente la población, muchas veces vamos a utilizar los criterios de inclusión. Se trata de una serie de condiciones que deben cumplir los individuos para pertenecer a la población.

También existen los criterios de eexclusión, son condiciones que identifican a los individuos que no deben pertenecer a la población.

Es importante tener en cuenta que los criterios de inclusioń y exclusión se aplican a la población, no a la muestra.

8.1.2 Muestra

Una **muestra** es un subconjunto de elementos extraídos de una población. La muestra se utiliza para realizar estimaciones sobre la población completa sin necesidad de medir a todos sus miembros

la calidad de la muestra son fundamentales para asegurar que las inferencias realizadas sean precisas y representativas.

como ya se vio Una muestra puede ser aleatoria, estratificada o por conveniencia, dependiendo del método utilizado para su selección. El diseño muestral es la herramienta para garantizar una muestra representativa.

Y esto no aplica solamente para métodos cuantitativos. En general, la información recolectada será representativa solamente con un buen diseño muestral. Incluso en un estudio cualitativo.

8.1.3 Parámetro

Un **parámetro** es un valor numérico que describe una característica específica de una población completa. Debe ser numérico, para que se pueda modelar mediante las herramientas matemáticas y debe corresponder a toda la población, sin excepción. El problema fundamental de la estadística es que no se conocen los parámetros. Dado que los parámetros se refieren a poblaciones enteras, son constantes, pero, en la práctica, generalmente son desconocidos. Por lo tanto, se necesita recurrir a métodos estadísticos para estimarlos a partir de muestras.

Ejemplos incluyen la media poblacional ( ), la varianza poblacional (^{2}) o la proporción poblacional (P). Cuando entramos en el terreno bivariado tenemos que el parámetro es la covarianza y la correlación. O en caso de un modelo, los coeficientes del mismo y los pesos de dlas variables son parámetros.

Cuando las variables son categóricas admiten parámetros como proporcion y porcentaje, cuando son numéricas admiten como parámetros el total, el promedio, la varianza la desviación estándar.

Los proceoss estadísticos en general tienen como norte la estimación de unos parámetros. Sea a nivel univariado, bivariado o multivariado o de modelamiento, siempre estamos esperando estimar parámetros.

8.1.4 Estimador

Un **estimador** es una regla o fórmula utilizada para aproximar un parámetro poblacional a partir de los datos muestrales.

Un estimador es una variable aleatoria y, por lo tanto, puede variar de una muestra a otra. Los estimadores se utilizan para hacer inferencias sobre la población. Es decir, la generalización

del valor del estimador desde la meustra hacia la población es la infereencia estadística. La pregunta es, qué tanto se diferencia el estimador del parámetro.

> Ejemplo
>
> ejemplos comunes incluyen la media muestral $\bar{x}$ y la proporción muestral $\hat{p}$.

Entonces, en nuestra lógica de inferencia, podemos decir que el esstimador es lo que se ve, lo tangible, lo accesible y el parámetro, aunque sabemos que existe, no lo podemos ver ni calcular; a menos que tengamos acceso a toda la poblacioń.

La calidad de un estimador se evalúa en función de sus propiedades, como la consistencia y la unbiasedness (inexistencia de sesgo).

8.2 Estimación puntual

8.2.1 Estimación puntual

La **estimación puntual** se refiere al uso de un solo valor, calculado a partir de la muestra, para estimar un parámetro desconocido de la población.

Este enfoque proporciona una respuesta única a la pregunta de interés, pero no informa sobre la precisión de la estimación.

> Ejemplo
>
> Por ejemplo, la media muestral $\bar{x}$ es una estimación puntual de la media poblacional ( ).

El concepto de precisión hace referencia a qué tan diferentes pueden ser los valores del estimador cuando son obtenidos de diferentes muestras.

> Ejemplo
>
> *Media muestral: **Se toma una muestra de los ingresos anuales de 100 hogares de una comunidad. La media de estos ingresos en la muestra es de $50,000. Este valor se utiliza como una** estimación puntual** de la media de los ingresos por hogar de toda la comunidad.

Ejemplo

Proporción muestral: En una encuesta realizada a 500 jóvenes de una universidad, 320 afirman que prefieren informarse a través de redes sociales. La proporción muestral es $\hat{p} = \frac{320}{500} = 0.64$, lo cual es una **estimación puntual** de la proporción real de personas que prefieren el trabajo remoto en la población de jóvenes de esta universidad.

Ejemplo

Desviación estándar: Una muestra de 50 estudiantes tiene una varianza de puntajes en un examen de 8 puntos. Este valor se utiliza como una **estimación puntual** de la varianza de los puntajes en la población completa de estudiantes.

8.2.2 Estimadores y parámetros

Entonces, podemos observar la relación entre la población y la muestra. La población es el total del universo que queremos investigar, pero no podemos acceder a ella, mientras que la muestra son los datos que recoelectamos, que tenemos a nuestro cuidado.

Así mismo, el parámetro es una cantidad que nos da información sobre los fenómenos que estudiamos, pero no podemos calcularlo. Mientras que el estimador es una aproximación al parámetro. Esta aproximacion mejora según varias condiciones que veremos a continuación.

El estimador persigue al parámetro, esa es la metáfora que tenemos en nuestar mente. Siempre debemos observar si el estimador es suficienremente cercano al parámetro.

Como no conocemos el parámetro, nunca podemos saber si el estimador es igual o diferente al parámetro, pero varias herramientas estadísticas nos ayudan a intuir la diferencia entre el parámetro y el estimador, aún sin conocer el primero. Esta diferencia entre el parámetro y el estimador la vamos a denominar error de estimación, y sobre este vamos a hablar más adelante, porque es uno de los temas más estudiadoes en la estadística.

Una forma de hacer inferencia es generalizar los estimadores y decir que son cercanos a los parámetros.

8.2.3 Ley de los grandes números

La **Ley de los Grandes Números** es un principio fundamental en la teoría de la probabilidad que establece que, a medida que aumenta el tamaño de una muestra, la media muestral $\bar{x}$ se acercará a la media poblacional ( ) de la población de la que se extrajo la muestra.

Esta ley se basa en la idea de que las fluctuaciones aleatorias tienden un equilibrio, dejando al descubierto las tendencias a medida que los tamaños poblacionales aumentan, lo que resulta en una estimación más precisa del parámetro poblacional.

Ley débil de los grandes números: Establece que, para cualquier valor positivo, la probabilidad de que la media muestral se desvíe de la media poblacional en más de tiende a cero a medida que el tamaño de la muestra (n) aumenta. Es decir, la media muestral se convierte en un estimador consistente de la media poblacional.

Ley fuerte de los grandes números: Afirmación más fuerte que la versión débil, establece que la media muestral converge casi seguramente a la media poblacional a medida que n tiende al infinito. Esto significa que, con una probabilidad de 1, la media muestral se aproximará a la media poblacional a medida que se tomen más y más muestras.

Salvo detalles muy técnicos, en ambos casos la conclusión es la misma. El estimador de la media persigue a su parámetro. Esto, de manera intuitiva, nos permite ver el trabajo de los matemáticos y los estadísticos: establecer cuáles son las condiciones para que un estimador persiga a su parámetro. También preguntarnos. Será que hay estimadores o parámetros que están desacoplados?

La Ley de los Grandes Números es fundamental en estadística y asegura que los resultados obtenidos de las muestras se volverán más representativos de la población a medida que se aumente el tamaño de la muestra, lo que permite realizar inferencias más confiables sobre la población completa.

8.2.4 Consistencia

Que la media muestral converge a la media poblacional está garantizado por la ley de los grandes números en sus versiones débil y fuerte. Pero qué pasa con otros estimadores? Sí tienen las mismas propiedades?

Resulta que no todos, pero sí algunos. Se llaman consistentes. Un **estimador puntual** es **consistente** si, a medida que el tamaño de la muestra aumenta, la estimación se aproxima cada vez más al verdadero parámetro poblacional. Es decir, hay una clase especial de estimadores que sí persiguen a los parámetros. Esto los estadísticos lo han estudiado por años y representa una de las dificultades más fuertes al momento de crear nuevos modelos y algoritmos.

Todos los estimadores presentados en este libro son consistentes, entonces no vamos a tener problemas de consistencia. Vamos a poder trabajar tranquilos sobre nuestras conclusiones, ya que los estimadores presentados han sido estudiados por estadísticos y matemáticos.

Esta propiedad es crucial porque asegura que con muestras más grandes, nuestras estimaciones se vuelven más precisas y confiables, reduciendo la variabilidad y el error de estimación.

8.3 Estimación por intervalo

8.3.1 Precisión y exactitud

En todo este viaje, hemos visto como una de las tareass mas importantes de la estadística es modelar lo que no observamos a partir de lo que observamos.

Dentro de esto, tenemos que pensar en el problema del muestreo.

Como vimos antes, el problema del muestreo es que al trabajar muestras distintas de la misma población, probablemente se obtengan resultados distintos. El estudio de este fenómeno nos va a llevar a dos conceptos adicionales, que nos ayudan a entender la inferencia.

La precisión, se pregunta por la diferencia que hay entre las muestras posibles. Si yo tomo miles de muestras de mi población, qué tan diferentes son los estadísticos que puedo obtener de ellas. Esta diferencia se puede medir.

La exactitud, por otro lado, hace referencia a que, entre todas las muesras que yo tomo, los resultados sí sean parecidos al parámetro, o sea al resultado de la poblacioń.

> Ejemplo
>
> Los dos conceptos suelen sucitar confusión entre los estudiantes. Pero muchas veces s epueden resolver fácil con un ejemplo. Una vez me encontré a Shakira en un avión, y le pedí una selfie. Ella, cansada de que le pidan estas cosas, me puso una condición; que tenía que adivinar la edad de su perro, si la edad que yo decía no correspondía con la realidad, no habría foto ni nada. Yo le dije que estaba bien, pero que en vez de darle un número le daba un rango. Ella no se opuso, acto seguido le dije que su perro tenía entre 0 y 25 años. Una señora que era testigo de la conversación, irrumpió, diciendo que yo era un tramposo. Pero le dije que ella pidió exactitud, no precisión. Al final me desperté, todo fue un suelño.

La **precisión** se refiere a la consistencia y reproducibilidad de las mediciones. Una medición es precisa si el rsultado con distintas muestras son cercanas entre sí, independientemente de si son correctas o no.

> Ejemplo
>
> Los diseñadores de máquinas dan las medidas en milímetros. Esto da una mayor precisión a los componentes. Los errores, cuando los hay son de milímetros. Si los componentes tuvieran las medidas en centímetros, habría menos precisión.

La **exactitud**, por otro lado, se refiere a cuán cerca está una medición del valor verdadero o del objetivo. Una medición es exacta si se aproxima al valor real. Lo que se evalúa es si está diciendo la verdad o no.

Ejemplo

Los abogados necesitan establecer los hechos verídicos en sus procesos. Incluso si no se tienen detalles, los hechos relatados deben ser verificables.

La precisión y exactitud son cruciales en la estadística y en el diseño de investigaciones. Una alta precisión en los resultados es deseable, pero no es suficiente por sí sola. Si los datos son precisos pero no exactos, las conclusiones extraídas pueden ser engañosas y llevar a decisiones erróneas.

Ejemplo

Imagina dos dos imágenes. En la primera imagen se muestra el dibujo de un niño sobre los animales de la granja. La segunda imagen se muestra una foto de unas plantas de la granja. Cada una de estas imágenes tiene un subtítulo que dice "Animales de la granja". Ahora dime, hay una imagen inexacta y otra imprecisa. Sabrías distingir cuál es cual?

8.3.2 Construccion de los intervalos de confianza

los intervalos de confianza son una herramienta estadística diseñada para expresar la incertidumbre en torno a una estimación puntual. Un intervalo de confianza proporciona un rango de valores dentro del cual se espera que se encuentre el parámetro poblacional verdadero,

De esta manera, un intervalo de confianza tiene mayor o menor amplitud dependiendo de el error de estimacioń, que tiene que ver directamente con el tamaño muestral e indirectamente con el diseño muestral. Recordemos que estamos partiendo de diseños muestrales probabilísticos.

Los conceptos de precisión y exactitud están intrínsecamente relacionados con los intervalos de confianza,

Un intervalo de confianza nos trae un nuevo problema. A veces el investigador necesita que el intervalo de confianza no contenga valores específicos como el cero o el uno para demostrar su teoría. Es decir, que puede suceder que un intervalo de confianza desmonte una teoría. Esto va a quedar más explícito cuando veamos pruebas de hipótesis.

Ejemplo

Imaginemos que estoy hablando de discrimionación en procesos penales, tengo un grupo discriminado A que generalmente le ponen más años por el mismo delito frente ao tro grupo no discriminado B. Y tengo la estadística de diferencia de los promedios, o sea, la resta, promedio de B menos promedio de A. Esta estadística la obtuve de una muestra probabilística. Entonces, para demostrar mi teoría de que hay discriminación penal, tengo

que demostrar que el parámetro (no el estimador) es positivo. Es decier, que la diferencia de los promedios es positiva para la poblacióni. Si calculamos un intervalo de confianza y todo el intervalo es mayor a cero, teniendo en cuenta que el parámetro se encuentra en el intervalo, puedo pensar que mi teoría se sostiene. Pero si el intervalo contiene al cero, significa que el parámetro puede ser positivo o negativo o cero. Entonces mi estudio no puede concluir que haya discriminación penal en la población. Es no concluyente.

Este razonamiento que nos permite enfrentar una hipótesis a un cálculo con los datos y establecer conexiones que me permiten demostrarlas es el principio actual del conocimiento científico. En ciencias de la salud, ciencias económicas, sociales, humanas, el razonamiento de conectar hipótesis con parámetros y estimadores es el estandar metodológico de investigacioń.

Pero hay malas noticias. El caracter matemático de los intervalos de confianza tiene un detalle que es neceario estudiar antes de continuar. Debido a sus características matemáticas, los parámetros no son fáciles de localizar. Pueden estar en cuanquier parte de la recra numérica, sí, literalmente en cualquier parte. Aunque no parezca, la probabilidad de que el parámetro se encuentre muy lejos del estimador puede ser muy baja, pero nunca es cero. esto significa que si yo quiero estar 100% seguro de que mi intervalo cubre mi estaimador, debo tener un intervalo gigante, que puede llegar a infinito. Esto no resulta útil.

Por esta razón, los intervalos de confianza no se calculan con una certeza del 100%. Las fórmulas matemáticas desarrolladas por los expertos y también las herramientas computacionales, han permitido construir intervalos de confianza que, con un un porcentaje de certeza menor al 100%, cubren el parámetro. Estos intervalos pueden tener 90%, 95% incluso 99% de confianza. El estándar en ciancias sociales es 95%.

Y entonces aquí ocurre algo que sucita controversia: existe la posibilidad de que yo piense que mi intervalo de confianza contiene el parámetro, pero en ralidad no lo hace. Esto sucede el 5% de las veces. Es decir, para un parámetro particular, si tomamos muchas muestras y de cada una de ellas generamos todos intervalos de confianza para este parámetro, el 5% de estos intervalos no contiene el parámetro.

Aquí estamos siendo muy claros en que el parámetro es fijo y los intervalos de confianza dependen de la meustra. Si realizamos muchas veces muchas muestras, podemos ver muchos intervalos de confianza para el mismo parámetro.

La construcción de intervalos de confianza puede realizarse de dos maneras. Construcción analítica y construcción computacional. La construcción analítica Utiliza fórmulas y propiedades matemáticas para calcular los intervalos de confianza. Este método es eficiente cuando se cumplen las condiciones necesarias, como la normalidad de los datos. Utiliza técnicas de remuestreo, como el bootstrapping, para estimar la distribución del estimador y generar intervalos de confianza sin necesidad de asumir una distribución específica. En este caso, un computador puede generar muchas muestras a partir de un conjunto de datos y calcular muchas veces el mismo estimador.

La construcción analítica de los intervalos de confianza presenta pros y contras. **Ventajas**: Menor costo computacional, ya que implica cálculos directos a partir de los datos. Resultados más rápidos si se cumplen los supuestos de normalidad.

Las Desventajas del uso de intervalos de confianza analiticos se encuentran, entre otras: Dependencia de supuestos que pueden no cumplirse en datos reales. Puede no ser adecuado para distribuciones no estándar o en situaciones de muestras pequeñas.

La construcción computacional de los intervalos de confianza presenta pros y contras **Ventajas**: Flexible, ya que no depende de supuestos sobre la distribución de los datos. Adecuado para cualquier tipo de muestra y variabilidad en los datos.

La construcción computacional de los intervalos de confianza presenta ***Desventajas**: Puede ser intensivo en recursos computacionales, especialmente para grandes volúmenes de datos. Mayor tiempo de procesamiento y necesidad de software especializado.

El **bootstrapping** es un método no paramétrico que se utiliza para estimar la distribución de un estimador y, por ende, sus intervalos de confianza. Este método genera múltiples muestras simuladas (con reemplazo) de la muestra original, permitiendo construir un intervalo de confianza sin depender de la distribución subyacente de los datos.

Un **intervalo de confianza** es considerado **consistente** si, al aumentar el tamaño de la muestra, la longitud del intervalo tiende a reducirse. Esto indica que la estimación se vuelve más precisa y refleja mejor el parámetro poblacional. En general, tanto los intervalos de confianza analíticos como los computacionales suelen ser consistentes.

9 Tamaño muestral

NA

9.1 Error muestral

NA

9.2 Empate técnico

NA

9.3 Tamaño del efecto

NA

9.4 Tamaño de muestra

9.4.1 Tamaño de muestra óptimo

NA

9.5 Formulas para estimación

9.5.1 Estimación de una proporción con tamaño poblacional conocido

NA

9.5.2 Estimación de una proporción con tamaño poblacional desconocido

NA

9.5.3 Estimación de una media con tamaño poblacional conocido

NA

9.5.4 Estimación de una media con tamaño poblacional desconocido

NA

9.6 Aplicación interactiva

NA

10 Pruebas de hipótesis

NA

10.1 La hipótesis en el contexto del desarrollo científico

Epistemológicamente, una **hipótesis** es una proposición que establece una propiedad verificable del proceso observado. La verificacio´n de la hipótesis es la actividad central en el desarrollo científico, ya que proporciona un puente entre la teoría y los datos. La capacidad de someter hipótesis a pruebas es lo que distingue el conocimiento científico de otras formas de conocimiento.

Las pruebas de hipótesis son fundamentales en este proceso, ya que permiten evaluar la validez de las afirmaciones mediante un enfoque sistemático y basado en evidencias. La capacidad de una hipótesis para ser refutada o confirmada es lo que la hace esencial para el avance del conocimiento científico

> Ejemplo
>
> En este sentido, es posible ver los modelos científicos como conjuntos lógicos y coherentes de hipótesis. Por ejemplo, el modelo del universo de Ptolomeo, desarrollado en la antigüedad, proponía que los cuerpos celestes giraban en esferas perfectas alrededor de la Tierra. Este modelo contenía implícitamente numerosas hipótesis sobre el movimiento y la disposición de los astros que, con el tiempo, fueron refutadas por observaciones empíricas y reemplazadas por el modelo heliocéntrico de Copérnico.

> Ejemplo
>
> Otros modelos más cercanos a las ciencias sociales incluyen el modelo histórico-materialista de Karl Marx, que se basa en la hipótesis de que los cambios sociales y económicos son impulsados por las contradicciones inherentes a los modos de producción.

Ejemplo

De manera similar, el modelo de Max Weber sobre la acción social postula que las acciones humanas están motivadas por un conjunto de significados subjetivos que pueden ser interpretados en función de diferentes tipos de racionalidad, como la racionalidad instrumental o valorativa.

Cada uno de estos modelos tiene sus hipótesis, que han sido comprobadas mediante estudios con información empírica, recopilada a través de métodos cuantitativos, cualitativos o mixtos.

. Ahora, la formulación de la hipótesis consiste en transformar la afirmación que se quiere examinar en un sistema estadístico. Se formula una hipótesis nula y una hipótesis alternativa, siendo cada una de ellas una proposición matemática comprobable.

El puente entre la aseveración teórica y la proposicio´n matemática es lo que permite a las pruebas de hipótesis ser herramientas estandarizadas para el desarrollo cient´fico.

10.1.1 Reproducibilidad

La **reproducibilidad** es un principio fundamental en la ciencia, que implica que los resultados de un experimento deben poder ser replicados por otros investigadores utilizando los mismos métodos. Esto permite que las personas puedan hacer parte de la comunidad científica sin importar sus condiciones de base.

La reproducibilidad es esencial para la credibilidad de la ciencia y se convierte en una medida del rigor y la fiabilidad de los estudios realizados. Sin reproducibilidad los hallaztos son anecdóticos.

La **crisis actual de la reproducibilidad** en la ciencia se refiere a la creciente preocupación sobre la capacidad de replicar resultados científicos. Estudios han demostrado que un número significativo de resultados en diversas disciplinas no puede ser replicado, lo que plantea interrogantes sobre la validez de esos hallazgos.

un artículo de la revista Nature encontro que tan solo para una treintena de 100 experimentos de psicología publicados en las mejores revistas científicas del campo se habían podido reproducir sus resultados. [@https://www.science.org/doi/10.1126/science.aac4716]

También es posible encontrar esta controversia en ciencias de la salud, económicas y otras disciplinas [@https://pmc.ncbi.nlm.nih.gov/articles/PMC1182327/], [@https://www.aeaweb.org/articles?id=10.1257/aer.p20171031], [@https://www.nature.com/articles/533452a]

10.1.2 Objetivo

La formulacio´n del sistema de hipótesis consiste en la generación de una hipótesis nula y una hipótesis alterna. Estas hipótesis son fórmulas matemáticas que pueden ser verdaderas o falsas y son contrarias entre sí. Al ser fórmulas matemáticas es posible obtener un veredicto evaluándolas con los datos de la muestra.

Por consiguiente, el objetivo de una prueba de hipótesis es stablecer si existe **suficiente evidencia** en una muestra aleatoria para **rechazar** o **no rechazar** la **hipótesis nula** a nivel poblacional

10.2 Marco conceptual

En estadística, realizar una prueba de hipótesis significa realizar un procedimiento estandarizado del que se obtiene un resultado interpretable.

10.2.1 El sistema de hipótesis

Un buen punto de partida para ilustrar la lógica subyacente en las pruebas de hipótesis es la famosa analogía de la *tetera de Russell*, que es un ejemplo del razonamiento lógico subyacente a las pruebas de hipótesis.

Bertrand Russell, filósofo y matemático británico, introdujo la analogía de una pequeña tetera de porcelana que orbita el Sol entre la Tierra y Marte, tan diminuta que ningún telescopio podría detectarla. ¿Cómo podríamos comprobar que esto es cierto? Para demostrar que es cierto basta con encontrar la tetera usando un telescopio y mostrársela a todos. Pero si quisiéramos demostrar que no es cierto, deberíamos buscar en nuestra nave espacial por todo el universo y establecer que no hay una tetera. Es decir, en un caso la demostración se logra con evidencia, en el otro caso, con un examen exhaustivo del universo.

Este ejemplo se introdujo originalmente para hablar de la existenci de dios. Pero nos viene muy bien para hablar del desarrollo científico actual, basado en pruebas de hipótesis. La idea subyacente es que cada conjetura que queremos demostrar tiene dos caras. Una demostracio´n por evidencia y la contraria mediante un examen exhaustivo del universo.

> Ejemplo
>
> Imaginemos que acusamos a un estudiante de hacer trampa en un examen. Para demostrar que el estudiante hizo trampa, basta con tener evidencia suficiente. Pero si pidiéramos al estudiante que de muestre que no hizo trampa, para él sería imposible. ¿Cómo podría? ¿Un registro de todas sus acciones sería suficiente?

Como vemos, una afirmacio´n genera dos casos, uno que se puede demostrar con evidencia y otro que únicamente con el examen del universo. Esto nos permite plantear el procedimiento de pruebas de hipótesis de manera formal.

En estadística, un sistema de hipótesis propone la conformación en cada caso de dos hipótesis principales: la **hipótesis nula (H)** y la **hipótesis alterna (H)**.

- **Hipótesis nula (H):** Es la suposición inicial que niega la existencia de un efecto, relación, asociación, etc, en la población de estudio. La hipótesis nula se formula de manera que, para rechazarla, se debe contar con evidencia suficiente que contradiga su planteamiento. No obstante, debido a su enunciado, su verificación requiere un esfuerzo muy alto.
- **Hipótesis alternativa (H):** Esta hipótesis propone la existencia de un efecto o relación y es la contraparte de la hipótesis nula. Si los datos recolectados ofrecen pruebas suficientes, se puede rechazar la hipótesis nula en favor de la hipótesis alternativa.

Ejemplo

Un ejemplo de esto es la fidelidad. Imagina que hay una pareja discutiendo y hay una acusación de infidelidad. Esta acusación puede ser cierta o falsa, pero tiene dos caminos. Si intentamos probar que una persona es infiel es suficiente encontrar la evidencia suficiente, que puede estar representada en distintos elementos. Pero si intentamos probar que la persona es fiel, qué podemos hacer? Deberíamos tener una vigilancia integral de sus acciones. En este caso la hipótesis nula es la fidelidad, es aquello que no podemos demostrar, y la hipótesis alterna es la infidelidad, es aquello que se puede conprobar mediante eviencia.

Este enfoque dual asegura que los investigadores se acerquen al análisis de manera objetiva, comenzando con la suposición de que no hay un efecto, una relación y buscando evidencia que justifique el rechazo de esta suposición. Determinar la cantidad cuándo la evidencia es suficiente es una tarea que requier unos pasos específicos, que se muestran en este capítulo.

El propósito de un sistema de hipótesis es analizar los datos recolectados en estudios experimentales u observacionales para determinar si hay suficiente evidencia empírica para rechazar la hipótesis nula y aceptar la hipótesis alternativa. Aquí, la prueba recae en la demostración de H : si hay suficiente evidencia de la hipótesis alterna se rechaza la hipótesis nula.

Ejemplo

Una discusión frecuente es que los videojuevos violentos causan violencia. Para materializarlo examinamos las familias y tenemos la afirmación “los casos de violencia en las familias que tienen videojuegos son la misma cantidad que los casos de violencia de las familias que no tienen videojuegos” Esta afirmación genera dos casos. Consultamos los

hogares, con videojuegos y sin videojuegos. Si conseguimos evidencia de que los casos de violencia son mucho mayores en alguno de los dos grupos la afirmación sea falsa. Pero para demostrar que es cierta, que la cantidad de casos es exactamente la misma, deberíamos tener la la cunenta de todos los casos de todos los hogares.

La analogía de la tetera de Russell es particularmente relevante al considerar la **evidencia necesaria para sostener o rechazar una hipótesis**. Así como Russell enfatizaba que es quien afirma la existencia de la tetera quien debe probar su existencia, en las pruebas de hipótesis, los investigadores deben demostrar que los datos apoyan la hipótesis alternativa y no asumir la verdad de H sin evidencia adecuada.

Este enfoque protege a la ciencias sociales de afirmaciones infundadas y promueve una práctica investigativa basada en pruebas y datos sólidos. Al entender la arquitectura de las pruebas de hipótesis, los investigadores pueden abordar preguntas complejas con un marco metodológico que garantiza que sus conclusiones estén respaldadas por evidencia empírica y análisis crítico.

10.2.2 Tipos de error

Ejemplo

Entonces tenemos nuestro estudiante acusado de hacer trampa en el examen. Viene la pregunta filosófica: entre pasar un estudiante tramposo o castigar un estudiante aplicado ¿Qué es más grave? Pensemos qué es peor, un falso negativo versus un falso positivo.

El tema de trabajar con muestras tiene un problema, es que de las diferentes muestras hay distntas cantidades de evidencia en contra de la hipótesis nula. Puede pasar que por casualidad una muestra tenga mucha evidencia en contra de una hipótesis nula cierta o que por casualidad una muestra tenga muy poca evidencia en contra de una hipótesis nula falsa. Por esa razón, en el proceso de tomar decisiones basadas en pruebas de hipótesis, es posible cometer errores. Estos errores se clasifican en dos tipos principales:

Error tipo I: Ocurre cuando se rechaza la hipótesis nula siendo esta verdadera. Es decir, se concluye incorrectamente que hay un efecto o diferencia cuando en realidad no lo hay. La probabilidad de cometer un error tipo I se denota por α, que también se conoce como el **nivel de significancia** de la prueba. Este es un parámetro que se establece de antemano y refleja el nivel de tolerancia al riesgo de rechazar una hipótesis verdadera.

Error tipo II: Se produce cuando no se rechaza la hipótesis nula cuando esta es falsa. En otras palabras, se falla en detectar un efecto o diferencia que realmente existe. La probabilidad de cometer un error tipo II se denota por β. El complemento de β se llama **potencia de la prueba** y representa la probabilidad de rechazar correctamente una hipótesis nula falsa.

Ejemplo

En el caso de la infidelidad, error tipo I consiste en calificar de infiel a un fiel. El error tipo II es el contrario, calificar de fiel a un infiel.

10.2.3 Nivel de significancia

El **nivel de significancia** (α) es un umbral predefinido que establece la probabilidad máxima aceptable de cometer un error tipo I. Comúnmente, los niveles de significancia utilizados son 0.05, 0.01, o 0.10. Este valor define el criterio para decidir si los resultados de una prueba son estadísticamente significativos.

El hecho de que en el procedimiento de pruebas de hipótesis se controle el error tipo I, nos muestra el lado más conservador de las ciencias. Están minimizando la probabilidad de un falso positivo, es decir, prefieren perder un descubrimiento, por falta de evidencia, que admitir un descubrimiento falso cuando la evidencia existe.

Si el valor p obtenido de la prueba es menor o igual a α, se rechaza la hipótesis nula en favor de la hipótesis alternativa, indicando que los resultados observados son lo suficientemente raros como para no atribuirse al azar.

La elección del nivel de significancia depende del contexto y las consecuencias de cometer un error tipo I. En estudios donde el costo de un error tipo I es alto, se elige un α más bajo (e.g., 0.01). En otros casos, donde la tolerancia al riesgo es mayor, se podría optar por un α más alto (e.g., 0.10).

10.3 Evaluación de la evidencia

Luego de plantear el sistema de hipótesis, tener claro los tipos de error y el nivel de significancia, procedemos a revisar los datos para obtener la evidencia y establecer si es suficiente para descartar la hipótesis nula.

10.3.1 Estadístico de la prueba

Las pruebas de hipótesis evalúan diferentes propiedades de los datos, normalidad, correlación, diferencias entre dos poblaciones, etc. Y lo hacen con una "medida de la evidencia", esta medida se llama el estadístico de la prueba. Este estadístico es único de cada prueba de hipótesis y establece qué tan lejos se encuentran los datos observados de la hipótesis nula.

Ejemplo

Nuestro estudiante sufriendo acusado de hacer trampa en el examen. Cuando indagamos qué evidencia hay, el profesor nos dice que lo vio susurrando cosas a una compañera en el examen. ¿Esta evidencia es suficiente? Y si no, ¿Cuál evidencia sería suficiente? Tenemos que crear un estándar que nos muestre los comportamientos que inequívocamente indican trampa. En otras palabras, tenemos que medir la evidencia. Podemos decir que hay comportamientos que no son normales, que son inusuales en un entorno sin trampa.

Entonces, podemos establecer la probabilidad de qué tran extremo es el estadístico de la prueba, sea por medios analíticos o computacionales. Con esto podemos ver si está muy lejos de donde debería estar si la hipótesis nula fuera cierta. Es decir, si la hipótesis nula fuera cierta, la probabilidad de que encontremos tantísima evidencia en su contra es mínima.

10.3.2 Valor p

El **valor** p es la probabilidad de observar un estadístico de prueba tan extremo o más extremo que el observado, bajo la suposición de que la hipótesis nula es cierta y teniendo en cuenta la muestra que tenemos.

El valor p depende de la muestra, significa que no es un valor fijo, es una variable aleatoria, pero no depende de cada individuo, sino de cuál es la muestra que se tomó. Muestras distintas producen valores p diferentes.

El valor p se calcula a partir del estadístico de la prueba, usando las técnicas analíticas o computacionales que tenemos para este fin. Generalmente, la prueba de hipótesis se rechaza si el p-valor es menor que la significancia. Esto significa que existe la posibilidad de haber seleccionado una muestra tan extrema que por casualidad rechacemos una hipótesis nula cierta. Para tomar esta decisión se compara el valor p con el nivel de significancia α.

Si $p < \alpha$, se **rechaza** H_0. En cambio **Si** $p \geq \alpha$, **no se rechaza** H_0. Esta decisión refleja si la evidencia contra H_0 es lo suficientemente fuerte para considerarla improbable bajo su supuesta veracidad.

10.3.3 Rechazar la hipótesis nula

Rechazar H_0 implica que se ha encontrado algo en la muestra tan improbable bajo la hipótesis nula, que lleva al investigador a favorecer la hipótesis alternativa H_1. Sin embargo, siempre existe la posibilidad de cometer un error tipo I al optar por este camino.

En estadística, se prefiere no rechazar H_0 erróneamente a rechazarla sin suficiente evidencia. Por esto, H_0 se mantiene a menos que haya **evidencia contundente** que obligue a revocarla.

Sin embargo, como la hipótesis nula no se puede demostrar, nunca podemos decir que la aceptamos como verdadera. Esto significa que nuestra investigación tiene dos opciones, o se comprueba la hipótesis alterna, o el estudio tiene resultados de carácter indeterminado. Sobre esto hay una gran discusión, porque las revistas científicas siempre van a preferir la publicacion de estudios que tengan resultados definidos a resultados indefinidos. No obstante, cuando la muestra es probabilísitica, y es muy grande y no se encuentra la evidencia, es un argumento fuerte a favor de H_0.

10.3.4 El procedimiento completo

El proceso para realizar una prueba de hipótesis incluye los siguientes pasos:

Establecer las hipótesis: Definir H_0 y H_a basándose en el problema de investigación.

Formular el sistema de hipótesis y seleccionar el nivel de significancia α.

Calcular el estadístico de la prueba y el valor p: Utilizar los datos muestrales para calcular el estadístico de prueba y el correspondiente valor p.

Tomar la decisión: Rechazar H_0 si $p < \alpha$ o no rechazar H_0 si $p \geq \alpha$.

Interpretar los resultados: Explicar el resultado en el contexto del problema de investigación, indicando si hay evidencia suficiente para apoyar H_1.

10.4 Pruebas y tipos de pruebas

Como se verá más adelante, existe una infinidad de pruebas de pruebas de hipótesis, pero es posible dividirlas en grandes grupos. Ya conociendo la estructura de las pruebas de hipótesis, podemos profundizar. Vamos a destinar unos renglones en dos temas: el cálculo del estadístico de la prueba, que es el que mide la cantidad de evidencia y el cálculo del p-valor, que nos muestra qué tan probable es obtener esta cantidad de evidencia o mayor según estos datos en el escenario en que H_0 es verdadera.

10.4.1 Pruebas paramétricas y no paramétricas

En el cálculo del estadístico de la prueba puede que se requiera la intervención de las propiedades distribucionales de los datos. Si las variables son normales o exponenciales, binomiales o Poisson, es algo que puede influir. Cuando esto sucede, se denominan pruebas de hipótesis paramétricas y solamente sirven para los casos en que se cumplen los supuestos distribucionales.

En el caso contrario, cuando la prueba de hipótesis tiene supuestos más amplios, que sean continuas, discretas, simétricas, se denominan pruebas no paramétricas y es posible usarlas en unamayor cantidad de casos.

10.4.2 Pruebas analíticas y computacionales

En el caso de las pruebas de hipótesis analíticas, el estadístico de la prueba tiene unas propiedades matemáticas conocidas. Las investigaciones han planteado con precisión cuál es su distribución y es posible conocer sus probabilidades.

En el caso de las pruebas de hipótesis computacionales, la distribución del estadístico de la prueba no es relevante, se puede obtener mediante remuestreo, permutaciones y otros métodos computacionales.

10.4.3 Cuando usar cada tipo de prueba

Las pruebas paramétricas requieren que se realice previamente la comprobación de los supuestos distribucionales. Si las variables cumplen los supuestos que la prueba exige, se puede proseguir con su cálculo. Por el contrario, si no se tiene el cumplimiento de los supuestos, o no se realiza la comprobación, es posible utilizar pruebas no paramétricas.

Por otro lado, si la muestra es grande, es recomendable utilizar pruebas analíticas. Pero cuando es más pequeña, es posible hacer el ajuste por pruebas de hipótesis computacionales. El tamaño sugerido a partir del cual fincionan mejor las últimas, depende decad prueba.

En general, cada problema en estadística posee su batería de pruebas de hipótesis, el estudio de estas pruebas es el primer paso para el dominio de la estadística. A continuación, nos adentraremos en los distintos problemas que nos ofrecen los datos, para poder entender mejor cada caso y cómo se usa.

11 Descriptivos univariados

NA

11.1 Medidas de frecuencia

NA

11.1.1 Frecuencia

NA

11.1.2 Proporción

NA

11.1.3 Moda

NA

11.1.4 Nota sobre variables continuas

NA

11.2 Medidas de tendencia central

11.2.1 Media aritmética

NA

11.2.2 Mediana

NA

Media armónica

Media geométrica

Comparación de las medidas

11.3 Medidas de localización

11.3.1 Mínimo y máximo

NA

11.3.2 Cuantiles

NA

11.3.3 Percentiles

NA

11.3.4 Cuartiles

NA

11.4 Medidas de dispersión

11.4.1 Varianza

NA

11.4.2 Desviación estandar

NA

11.4.3 Rango intercuartílico (IQR)

NA

11.4.4 Rango

NA

12 Inferencia univariada

12.1 Intervalos de confianza

12.1.1 Intervalo de confianza para la media

Como se mencionó anteriormente, es posible encontrar intervalos de confianza para la mayoría de los parámetros. Para la media poblacional se genera un intervalo de confianza analítico.

> Ejemplo
>
> Supongamos que un investigador quiere estimar la media de la altura de los estudiantes de una universidad. Toma una muestra aleatoria de 30 estudiantes y calcula que la media muestral es de 1.70 metros con una desviación estándar de 0.10 metros. Dado que el tamaño de la muestra es pequeño, se utiliza la distribución t de Student. Se quiere un nivel de confianza del 95%.

Para calcular un intervalo de confianza para la media de una población, se puede utilizar la distribución t de Student o la distribución normal, dependiendo del tamaño de la muestra y de si se conoce la varianza poblacional.

> Fórmula
>
> $$IC = \bar{x} \pm t_{\alpha/2} \left(\frac{s}{\sqrt{n}} \right)$$

Donde $t_{\alpha/2}$ es el valor crítico de t correspondiente al nivel de confianza del 95% y 29 grados de libertad (n-1), (s) es la desviación estándar muestral y (n) es el tamaño de la muestra.

> Ejemplo
>
> Siguiendo nuestro ejemplo, supongamos que $t_{0.025} \approx 2.045$ para este caso: $IC = 1.70 \pm 2.045 \left(\frac{0.10}{\sqrt{30}} \right) \approx 1.70 \pm 0.374$, El intervalo de confianza sería aproximadamente (1.63, 1.77). Esto significa que el investigador puede estar 95% seguro de que la media de altura de todos los estudiantes está entre 1.63 y 1.77 metros.

sacar el intervalo de confianza para la media con la IA

Para evaluar la **diferencia de medias** entre dos poblaciones, se construye un intervalo de confianza alrededor de la diferencia de medias muestrales. Dependiendo de si se asumen varianzas iguales o diferentes, se pueden aplicar diferentes métodos, como el método de bootstrapping.

Supongamos que queremos comparar las alturas promedio de hombres y mujeres en una población. Recogemos datos de 50 hombres y 50 mujeres y encontramos que la media de los hombres es 1.80 metros y la media de las mujeres es 1.65 metros. La diferencia de medias es 0.15 metros. Aplicando el bootstrapping, podemos crear múltiples muestras de nuestras muestras originales para estimar la distribución de la diferencia de medias y, así, construir un intervalo de confianza.

sacar el intervalo de confianza bootstrapping para la media con la IA

12.1.2 Intervalo de confianza para una proporción

para una proporción también es posible encontrar intervalos de confianza. Se genera un intervalo de confianza analítico

> **Ejemplo**
>
> Imaginemos que en una encuesta a 500 personas, 320 afirman que prefieren consumir licor a otras drogas. La proporción muestral es: $\hat{p} = \frac{320}{500} = 0.64$

El **intervalo de confianza para una proporción** se calcula utilizando la proporción muestral $\hat{p}$ y el error estándar de la proporción. Se utiliza la distribución normal, ya que se asume que la proporción muestral sigue una distribución normal cuando el tamaño de muestra es suficientemente grande. El intervalo de confianza se puede calcular de la siguiente manera:

> **Fórmula**
>
> $$IC = \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

siendo $z_{\alpha/2}$ el cuantil $\alpha/2$ de la distribución normal.

> **Ejemplo**
>
> Si elegimos un nivel de confianza del 95%, $z_{0.025} \approx 1.96$ tenemos $IC = 0.64 \pm 1.96\sqrt{\frac{0.64\times(1-0.64)}{500}} \approx 0.64 \pm 0.045$. Esto resulta en un intervalo de confianza de (0.595, 0.685). Por lo tanto, el investigador puede estar 95% seguro de que la proporción real de personas que prefieren trabajar desde casa en la población general está entre el 59.5% y el

68.5%.

sacar el intervalo de confianza para la proporción con la IA

12.1.3 Intervalo de confianza para la varianza

la varianza también tiene su intervalo de confianza. Tengamos en cuenta que este intervalo siempre es positivo porque la varianza es positiva.

Ejemplo

Supongamos que un investigador mide los tiempos de espera en una fila y obtiene una varianza muestral de (s^2 = 16) minutos² con una muestra de 15 observaciones. Para calcular un intervalo de confianza del 95% para la varianza poblacional

El **intervalo de confianza para la varianza** se calcula utilizando la distribución chi-cuadrado. La varianza muestral (s^2) es el estimador puntual, y el intervalo se ajusta de acuerdo con la distribución de esta varianza bajo el supuesto de normalidad.

Fórmula

$$IC = \left(\frac{(n-1)s^2}{\chi^2_{\alpha/2}}, \frac{(n-1)s^2}{\chi^2_{1-\alpha/2}} \right)$$

Donde (n) es el tamaño de la muestra y (^2) son los cuantiles de la distribución chi-cuadrado.

Ejemplo

Si (n=15) y con un nivel de confianza del 95%, se pueden encontrar el intervalo: $IC = \left(\frac{(15-1)\times 16}{\chi^2_{0.025,14}}, \frac{(15-1)\times 16}{\chi^2_{0.975,14}} \right)$. Si $\chi^2_{0.025,14} \approx 27.688$ y $\chi^2_{0.975,14} \approx 5.629$: por lo tanto $IC \approx \left(\frac{14\times 16}{27.688}, \frac{14\times 16}{5.629} \right) \approx (8.520, 39.658)$ Esto significa que el investigador puede estar 95% seguro de que la varianza del tiempo de espera en la población está entre 8.520 y 39.658 minutos².

sacar el intervalo de confianza para la varianza con la IA

12.2 Pruebas de hipótesis

12.2.1 Test t de Student para una muestra

NA

12.2.2 Test de signos para una muestra

NA

12.2.3 Test t de Student para dos muestras independientes

NA

NA

12.2.4 Test Wilcoxon - Mann - Whitney

NA

12.2.5 Test t de Student para dos muestras pareadas

NA

12.2.6 Prueba de una sola proporción

NA

12.2.7 Prueba de dos proporciones

NA

12.2.8 Pruebas de permutaciones para la media

NA

12.2.9 Pruebas de permutaciones para la proporción

NA

12.2.10 Pruebas de permutaciones otra

NA

12.3 Ejercicios y actividades

12.3.1 Hablemos bien

NA

12.3.2 Actividad

NA

13 Análisis correlacional

Es posible medir la relación entre dos variables, pero esto depende de qué tipo de variables son. Estas medidas incluyen valores p, que nos permiten generar inferencias.

- Dos variables numéricas; para esto existen eestadísticos que permiten establecer la correlación y darle un valor específico.
- Una cuantitativa y una cualitativa
- Dos cualitativas

13.1 Dos variables numéricas

La relación entre dos variables cuantitativas puede ser medida con los siguientes estadísticos.

- Covarianza
- Correlación de Pearson
- Correlación de Spearman

13.1.1 Covarianza

La covarianza entre dos variables cuantitativas es un número que crece cuando la relción lineaal entre ellas es mayor.

⚠ Fórmula

$$S_{xy} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})$$

13.1.2 Correlación de Pearson

Mide la fuerza y la dirección de la relación lineal entre dos variables continuas. Tiene un rango de -1 a 1, donde 1 indica una relación lineal positiva perfecta, -1 una relación lineal negativa perfecta y 0 ninguna relación lineal.

Se basa en la covarianza de las dos variables dividida por el producto de sus desviaciones estándar. Es posible encontrar un valor p para la correlación de pearson.

⚠ Fórmula

$$\rho_{xy} = \frac{\sum x_i y_i - n\overline{x}\overline{y}}{(n-1)S_x S_y}$$

Es fácil interpretar con una metáfora. Imaginemos que existen variables que son amigas, otras que son enemigas y otras que son indiferentes o desconocidas entre ellas. Cuando son amigas, las variables se mueven igual, cuando una aument, la otra también. Si son enemigas, se mueven al contrario, si una aumenta la otr disminuye.

13.1.3 Correlación de Spearman

Mide la fuerza y la dirección de la relación monótona (no necesariamente lineal) entre dos variables. Es más flexible que la correlación de Pearson y puede ser utilizada en casos donde la relación no es lineal pero aún sigue una tendencia consistente.

Con un rango de -1 a 1, donde 1 indica una relación monótona positiva perfecta, -1 una relación monótona negativa perfecta y 0 ninguna relación monótona.

⚠ Fórmula

$$\rho = 1 - \frac{6\sum D^2}{n(n^2-1)}$$

donde D es la diferencia entre los correspondientes estadísticos de orden de x - y. N es el número de parejas de datos.

13.1.4 Prueba de permutaciones

NA

NA

NA

NA

NA

NA

NA

NA

13.2 Una variable numérica y otra categórica

En ocasiones queremos encontra la correlación entre una variable numérica y una categórica.

13.2.1 Elementos gráficos

Para visualizar la correlación entre una variable numérica y una categórica, se pueden utilizar diversos elementos gráficos:

Diagramas de caja (boxplots): Muestran la distribución de la variable numérica para cada categoría de la variable categórica.

Gráficos de barras: Representan la media o mediana de la variable numérica para cada categoría de la variable categórica.

13.2.2 Anova

El análisis de la varianza es una técnica estadística utilizada para comparar las medias de tres o más grupos y determinar si al menos uno de los grupos es significativamente diferente.

ANOVA de una vía: Examina el efecto de una sola variable independiente (factores) sobre la variable dependiente.

ANOVA de más vías: Examina el efecto de dos variables independientes sobre la variable dependiente, y sus interacciones.

ANOVA es un procedimiento dentro del modelamiento estadístico. Tiene p-valores y es también una prueba de hipótesis.

13.2.3 Test Kruskal-Wallis

El test de Kruskal-Wallis es una prueba no paramétrica utilizada para comparar las medianas de tres o más grupos independientes. Es una alternativa al ANOVA cuando los supuestos de normalidad no se cumplen.

Ideal para datos ordinales o cuando la variable numérica no sigue una distribución normal. Esta prueb no está diseñada para admitir una o mś vías.

13.3 Asociación categórica - categórica

13.3.1 Tablas de contingencia

Tablas que muestran la frecuencia de las combinaciones de dos variables categóricas. Permiten observar la relación entre las variables categóricas. Ayudan a visualizar y analizar la dependencia entre variables categóricas. Los valores de una tabla de contingencia pueden ser objeto de análisis en una prueba de hip tesis, como la prueba chi cuadrado o la prueba exact de fisher

Prueba estadística que evalúa si existe una asociación significativa entre dos variables categóricas. Compara las frecuencias observadas en la tabla de contingencia con las frecuencias esperadas bajo la hipótesis nula de independencia. Determina si hay una relación significativa entre las variables categóricas.

Prueba estadística utilizada para determinar la asociación entre dos variables categóricas en tablas de contingencia de 2x2, especialmente cuando las frecuencias esperadas son pequeñas. Proporciona una alternativa más precisa a la prueba de chi cuadrado cuando los tamaños de muestra son pequeños.