

Estadística para Ciencias Sociales

Nestor Rojas Raquel Ortega Miguel Mendez Julián Cruz

Table of contents

Comencemos	14
Material	14
Recopilación	15
ToDo	16
Autores	18
Laboratorio Interdisciplinar de Medición de Dinámicas Sociales	18
Nestor Orlando Rojas Castillo	18
Raquel Soraya Ortega Bolaños	19
Miguel Ángel Méndez Marín	20
Julián Mauricio Cruz Pulido	21
I Estadística descriptiva	22
Introducción	23
Muestreo	23
Estadística descriptiva para una variable	23
Estadística descriptiva para dos o más variables	24
1 Preliminares	25
1.1 Definiciones	26
1.1.1 ¿Qué son los datos?	26
1.1.2 ¿Qué son las variables?	32
1.1.3 ¿Qué son los individuos?	33
1.1.4 Medición: Asignación de valores a las observaciones	34
2 Preparación de los datos	35
2.1 Limpieza	35
2.1.1 Identificación de atípicos	35
2.1.2 Corrección de errores	35
2.1.3 Codificación y decodificación	35
2.1.4 Imputación de datos	35
2.2 Modificaciones	35
2.2.1 De categórico a numérico	35
2.2.2 De numérico a categórico	35

2.2.3	Trabajo con fechas	35
2.3	Escalamiento univariado	35
2.3.1	Normalización	35
2.3.2	Estandarización	35
2.3.3	Uniformado	35
2.4	Procesamiento previo	36
2.5	Limpieza de datos	36
2.6	Transformación de datos	36
3	Estadística descriptiva para una variable	37
3.1	Medidas de frecuencia	37
3.1.1	Frecuencia	37
3.1.2	Proporción	38
3.1.3	Moda	39
3.1.4	Nota sobre variables continuas	39
3.2	Medidas de tendencia central	39
3.2.1	Media aritmética	40
3.2.2	Mediana	40
3.2.3	Otras medidas de tendencia central	41
3.3	Medidas de localización	42
3.3.1	Mínimo y máximo	42
3.3.2	Cuantiles	42
3.3.3	Percentiles	43
3.3.4	Cuartiles	43
3.4	Medidas de dispersión	43
3.4.1	Varianza	43
3.4.2	Desviación estándar	44
3.4.3	Rango intercuartílico (IQR)	44
3.4.4	Rango	44
3.5	Ejercicios y actividades	45
3.5.1	Hablemos bien	45
3.5.2	Actividad	45
4	Análisis correlacional	46
4.1	Dos variables cuantitativas	46
4.1.1	Covarianza	46
4.1.2	Correlación de Pearson	46
4.1.3	Correlación de Spearman	47
4.1.4	Kendall	47
4.2	Asociación numérica - categórica	47
4.2.1	Elementos gráficos	47
4.2.2	ANOVA	48
4.2.3	Tipos	48

4.2.4	Test Kruskal-Wallis	49
4.3	Asociación categórica - categórica	49
4.3.1	Tablas de contingencia	49
4.3.2	Prueba de chi cuadrado	50
4.3.3	Prueba exacta de Fisher	50
5	Distribuciones	51
6	Visualización	52
6.1	¿Por qué visualización?	52
6.2	Veamos ejemplos	52
6.3	Gráficos tradicionales	52
6.4	Escala de Cleveland y McGill	53
6.5	Buenas prácticas de visualización	53
6.6	Gráficos	53
II	Estadística inferencial	55
Contenido		56
Preliminares		56
Muestreo		56
Estimación		56
Tamaño muestral		56
Pruebas de hipótesis		56
Paramétricas analíticas		56
No paramétricas analíticas		56
Paramétricas computacionales		56
No paramétricas computacionales		56
7	Inferencia estadística	57
7.1	Los antiguos griegos y la deducción	57
7.1.1	Sócrates y la mayéutica	57
7.1.2	Platón y la dialéctica	57
7.1.3	Aristóteles y la lógica	58
7.1.4	El silogismo	58
7.2	El <i>Novum Organum</i> de Bacon	59
7.2.1	La deducción contra la inducción	59
7.2.2	Actividad: ¿Qué es un cisne negro?	59
7.3	Fisher, Neyman, Pearson	59
7.3.1	Las reglas para hacer inducción	59
7.3.2	Inferencia estadística	60

8 Muestreo	61
8.1 Contexto del muestreo	61
8.1.1 Tendencias	61
8.1.2 Individuos	61
8.1.3 Población	61
8.1.4 Muestra	62
8.1.5 Representatividad	62
8.2 Conceptos de muestreo	62
8.2.1 Marco muestral	62
8.2.2 Diseño muestral	62
8.2.3 Error muestral	63
8.2.4 Tamaño muestral	63
8.3 Distintos abordajes del muestreo	63
8.3.1 Muestreo no probabilístico	63
8.3.2 Muestreo probabilístico	63
8.4 Muestreo no probabilístico	64
8.4.1 Muestreo por cuotas	64
8.4.2 Bola de nieve	64
8.4.3 Muestreo discrecional	65
8.4.4 Muestreo por conveniencia	65
8.4.5 Muestreo accidental	65
8.5 Muestreo probabilístico	66
8.5.1 Muestreo aleatorio simple	66
8.5.2 Muestreo por etapas	66
8.5.3 Muestreo por conglomerados	67
8.5.4 Muestreo estratificado	67
8.5.5 Técnicas de muestreo	68
8.5.6 Factores de expansión	68
8.5.7 Actividad	68
9 Estimación	69
9.1 Conceptos iniciales	69
9.1.1 Parámetro	69
9.1.2 Estimador	69
9.1.3 Muestra	69
9.1.4 Población	70
9.2 Estimación puntual	70
9.2.1 Estimadores y parámetros	70
9.2.2 Aplicación interactiva	71
9.2.3 Ley de los Grandes Números	71
9.2.4 Consistencia	71
9.3 Estimación por intervalo	72
9.3.1 Precisión y Exactitud	72

9.4	Ejemplo: animales de granja	72
9.4.1	Precisión	73
9.4.2	Exactitud	73
9.4.3	Diferencias entre Precisión y Exactitud	73
9.4.4	Construcción de los intervalos de confianza	74
9.5	Intervalos de confianza analíticos	75
9.5.1	Intervalo de confianza para la media	75
9.5.2	Intervalo de confianza para una proporción	76
9.5.3	Intervalo de confianza para la varianza	76
9.5.4	Aplicación interactiva	77
9.5.5	Consistencia	77
9.6	Intervalos de confianza computacionales	77
9.6.1	Bootstrapping	78
9.6.2	Ejemplo: Diferencia de medias	78
9.6.3	Ejemplo: Diferencia de proporciones	78
9.6.4	Bootstrapping ejemplo	78
10	Tamaño muestral	79
10.1	Error muestral	79
10.2	Empate técnico	80
10.3	Tamaño del efecto	80
10.4	Tamaño de muestra	80
10.4.1	Tamaño de muestra óptimo	80
10.5	Fórmulas para Estimación	81
10.5.1	Estimación de una Proporción con Tamaño Poblacional Conocido	81
10.5.2	Estimación de una Proporción con Tamaño Poblacional Desconocido	81
10.5.3	Estimación de una Media con Tamaño Poblacional Conocido	82
10.5.4	Estimación de una Media con Tamaño Poblacional Desconocido	82
10.6	Aplicación Interactiva	83
11	Hipótesis	84
11.1	La hipótesis en el contexto del desarrollo científico	84
11.1.1	Reproducibilidad	85
11.2	Pruebas de hipótesis	85
11.2.1	Objetivo	85
11.2.2	Arquitectura de las pruebas de hipótesis	86
11.2.3	Reflexiones sobre la evidencia y la carga de la prueba	87
11.3	Terminología	87
11.3.1	Hipótesis estadística	88
11.3.2	Sistema de hipótesis	88
11.3.3	Tipos de error	89
11.3.4	effect sizes	89
11.3.5	Nivel de significancia	89

11.3.6 Integrando los conceptos en la práctica	89
11.4 Tipos de error	90
11.5 Nivel de significancia	90
11.6 Rechazar la hipótesis nula	90
11.7 Valor p	91
11.8 Decisión	91
11.9 Prueba	91
11.9.1 El papel de la significancia estadística y el error	92
12 Pruebas y tipos de pruebas	93
12.1 Pruebas paramétricas	93
12.2 Pruebas no paramétricas analíticas	94
12.3 Pruebas no paramétricas de simulación estocástica	94
12.4 Cuándo usar cada tipo de prueba	95
12.5 Pruebas de hipótesis más usadas	95
12.5.1 Test t de Student para una muestra	95
12.5.2 Test de signos para una muestra	95
12.5.3 Test t de Student para dos muestras independientes	95
12.5.4 Test t de Student para dos muestras independientes	96
12.5.5 Test Wilcoxon - Mann - Whitney	96
12.5.6 Test t de Student para dos muestras pareadas	96
12.5.7 Prueba de una sola proporción	97
12.5.8 Prueba de dos proporciones	97
12.5.9 Test de correlación de Pearson	97
12.5.10 Test de correlación de Spearman	97
III Modelamiento lineal	98
Introducción	99
Modelamiento	99
Correlaciones	99
Relación	99
Regresión lineal	99
Regresión logística	99
Medición	99
Componentes principales	99
Modelos de ecuaciones estructurales	99
13 Abordaje	100
13.1 Qué es un modelo estadístico	100
13.1.1 Se ve así	100
13.2 Actividad en clase	100
13.3 Justificación	100

13.4 Modelamiento	101
13.4.1 De la realidad a la teoría	101
13.4.2 Modelamiento estadístico	101
13.5 Tipos de modelos	101
13.5.1 Descripción	101
13.5.2 Explicación	101
13.5.3 Pronóstico	101
14 Modelamiento	102
14.1 Modelamiento descriptivo	102
14.2 Herramientas del modelamiento descriptivo	102
14.3 Ejemplos del modelamiento descriptivo	102
14.4 Modelamiento explicativo	102
14.5 Herramientas del modelamiento explicativo	103
14.6 Ejemplos del modelamiento explicativo	103
14.7 Modelamiento predictivo	103
14.8 Herramientas del modelamiento predictivo	103
14.9 Ejemplos del modelamiento predictivo	104
14.10 Diferencias clave entre describir, explicar y pronosticar	104
14.11 Etapas del modelamiento	104
14.11.1 Definición del problema	105
14.11.2 Recolección de datos	105
14.11.3 Preparación y exploración de los datos	105
14.12 Formulación del modelo	106
14.13 Estimación del modelo	106
14.14 Evaluación del modelo	107
14.15 Interpretación y presentación de resultados	107
14.16 Aplicación del modelo	107
14.17 Selección de datos	108
14.18 Análisis descriptivo	108
14.19 Análisis descriptivo univariado	108
14.20 Generación de visualizaciones	109
14.21 Análisis correlacional	109
14.22 Análisis de desagregación	109
15 Correlación, desagregación y causalidad	110
15.1 Correlación numérica - numérica	110
15.2 Dependencia e independencia lineal:	110
15.3 Regresión	110
15.3.1 Componentes:	110
15.4 Causalidad	111
15.5 Causalidad	111
15.5.1 Actividad en clase	111

16 Modelamiento estadístico	112
16.1 Qué es un modelo estadístico	112
16.2 Proceso de modelamiento estadístico	112
16.3 Formulación	112
16.3.1 Partes de un modelo	112
16.4 Formulación	113
16.4.1 Especificación matemática	113
16.5 Formulación	113
16.5.1 Supuestos teóricos	113
16.6 Estimación y ajuste	113
16.6.1 Parámetros y estimadores	113
16.7 Estimación y ajuste	114
16.8 Estimación y ajuste	114
16.8.1 Estimación puntual	114
16.9 Estimación y ajuste	114
16.9.1 Intervalos de confianza analíticos	114
16.9.2 Bootstrap	114
16.10 Estimación y ajuste	115
16.10.1 Procedimiento:	115
16.11 Validación y evaluación	115
16.11.1 Métricas de evaluación	115
16.12 Modelos	116
16.12.1 Regresión (aprendizaje supervisado)	116
16.12.2 Ejemplos	116
16.12.3 Métodos multivariados (aprendizaje no supervisado)	116
16.12.4 Ejemplos	116
16.13 Modelos de regresión explicativos	116
16.14 Modelos de regresión explicativos	116
16.14.1 Lineal normal	116
16.14.2 Logit	116
16.15 Modelos de regresión explicativos	117
16.15.1 Poisson	117
16.15.2 Series de tiempo, Datos panel	117
16.16 Modelos de regresión explicativos	117
16.16.1 Espaciales (krigging)	117
16.16.2 De efectos fijos y aleatorios	117
16.17 Modelos de regresión explicativos	117
16.17.1 Modelos de supervivencia	117
17 Modelo de regresión lineal	118
17.1 Modelo de regresión lineal	118
17.2 Formulación	118
17.2.1 Especificación matemática	118

17.2.2 Terminología	118
17.3 Formulación	118
17.3.1 Parámetros	118
17.3.2 Supuestos teóricos	119
17.4 Covariables	119
17.4.1 Covariables numéricas	119
17.4.2 Covariables categóricas	119
17.5 Respuesta	119
17.5.1 Respuesta numérica	119
17.5.2 Respuesta categórica	120
17.6 Comprobación de hipótesis	120
17.6.1 Planteamiento de hipótesis	120
17.7 Proceso de estimación	120
17.7.1 Intervalos de confianza analíticos	120
17.8 Proceso de estimación	121
17.8.1 Bootstrap	121
17.9 Inferencia del modelo	121
17.9.1 Significancia global	121
17.10 Inferencia del modelo	121
17.10.1 Significancia particular	122
17.11 Proceso de estimación	122
17.11.1 Valores ajustados/predichos	122
17.11.2 Residuales	122
17.12 Validación de supuestos	122
17.13 Validación de supuestos	123
17.14 Validación de supuestos	123
17.15 Métricas de evaluación	123
17.16 Coeficiente de determinación	124
17.16.1 Coeficiente de determinación	124
17.16.2 Coeficiente de determinación ajustado	124
17.17 Práctica	124
18 Modelo de regresión logit	125
18.1 Modelo de regresión logit	125
18.2 Formulación	125
18.2.1 Especificación matemática	125
18.3 Formulación	125
18.3.1 Terminología	125
18.4 Parámetros del modelo	126
18.4.1 Parámetros	126
18.4.2 Supuestos teóricos	126
18.5 Covariables	126
18.5.1 Covariables numéricas	126

18.5.2 Covariables categóricas	126
18.6 Respuesta	127
18.6.1 Respuesta categórica	127
18.7 Comprobación de hipótesis	127
18.7.1 Planteamiento de hipótesis	127
18.8 Proceso de estimación	127
18.8.1 Intervalos de confianza analíticos para los parámetros	127
18.8.2 Bootstrap	127
18.9 Inferencia del modelo	128
18.9.1 Significancia global	128
18.9.2 Significancia particular	128
18.10 Proceso de estimación	128
18.10.1 Probabilidades predichas	128
18.10.2 Valores predichos	128
18.10.3 Residuales	128
18.11 Validación de supuestos	129
18.11.1 Linealidad en el logit	129
18.11.2 Independencia de los errores	129
18.11.3 Ausencia de multicolinealidad	129
18.12 Métricas de evaluación	129
18.12.1 Curva ROC	129
18.12.2 AUC	129
18.13 Métricas de evaluación	129
18.14 Métricas de evaluación	130
18.14.1 Exactitud	130
18.14.2 Sensibilidad	130
18.14.3 Especificidad	130
19 Medición	131
19.1 Indicadores y métricas	131
19.2 Puedes medir usando un indicador: ¿pero quieres?	131
19.2.1 ¿Por qué no puedo ver a mi médico la otra semana?	131
19.2.2 Aquí las ambulancias no llegan	131
19.3 Constructos	132
19.3.1 Definición	132
19.4 Tipos de constructos	132
19.4.1 Constructos formativos	132
19.4.2 Constructos reflexivos	132
19.5 Medición de constructos	132
19.6 Validación	133
19.6.1 Validez	133
19.6.2 Confiabilidad	133
19.7 Validez de contenido	133

19.8 Validez convergente y discriminante	133
19.8.1 Convergente	134
19.8.2 Discriminante	134
19.9 Consistencia interna	134
19.9.1 Medidas	134
19.10 Consistencia externa	134
19.11 Alpha de Cronbach	135
19.11.1 Consistencia interna	135
19.12 Alpha de Cronbach	135
19.13 Alfa de Cronbach	135
19.14 Instrumentos	135
19.15 Cuestionarios	136
19.16 Construcción	136
19.17 La pregunta	136
19.18 Tipos de preguntas	136
19.18.1 Abiertas	136
19.18.2 Cerradas	136
19.19 Estructuras de preguntas	137
19.20 Votos múltiples	137
19.21 Ranking	137
19.22 Likert	137
19.23 Buenas prácticas	138
20 Referencias	139
21 Análisis de Componentes Principales	140
21.1 Reducción de dimensiones	140
21.2 ACP	140
21.2.1 Definición matemática	140
21.2.2 Significado matemático	140
21.3 ACP	141
21.3.1 Características	141
21.3.2 Ejemplo	141
21.4 ACP	141
21.4.1 Evaluación	141
IV Modelamiento de sistemas complejos	142
Introducción	143
Modelamiento	143
Redes	143
Asociaciones	143
Distancias	143

Algoritmos	143
Apriori	143
t-SNE	143
Cluster jerárquico	143
k-means	143
22 Enfoque	144
22.0.1 Linealidad	144
22.0.2 Complejidad	144
23 Estadística IV	145
24 Antecedentes	146
24.1 Introducción	146
24.2 Presentación	146
24.2.1 Descripción del Curso	146
24.2.2 Justificación	146
24.3 Consideraciones	147
24.4 Objetivo	147
24.5 Metodología	147
24.6 Docente	147
24.6.1 Julián Cruz	147
24.7 Material	147
24.8 Narrativa	148
24.8.1 Creadores	148
24.8.2 Usuarios	148
25 Acercamiento epistemológico	149
25.1 Cambio en el paradigma	149
25.1.1 Paradigma clásico	149
25.1.2 Paradigma emergente	149
25.2 Paradigma clásico	149
25.3 Paradigma emergente	150
25.4 Ejemplo	150
25.5 Tipo de estudio	150
25.6 Epistemología de la ciencia	150
25.7 Metodología	151
26 Taller	152
26.1 Taller	152
26.1.1 Contexto	152
26.1.2 Papers	153

Comencemos

El Laboratorio Interdisciplinar de Medición Social (LABMEDISOCIAL) se complace en presentar estas notas de clase sobre estadística en ciencias sociales.

La estadística, en su esencia, constituye un puente entre la observación empírica y la construcción de conocimiento científico. En el ámbito de las ciencias sociales, su aplicación trasciende el análisis de datos para convertirse en una herramienta indispensable en la formulación de teorías, la validación de hipótesis y la toma de decisiones fundamentadas. Este libro se concibe como una contribución a ese esfuerzo, ofreciendo una integración rigurosa de fundamentos teóricos y aplicaciones prácticas, sustentada en la investigación social.

En investigación social, el uso adecuado de métodos estadísticos para comprender la estructura y operatividad de un fenómeno determinado, constituye una ventaja del investigador en un entorno competitivo de alto desempeño. Una gran variedad de procesos de planeación y evaluación de actividades gubernamentales, administrativas, económicas y financieras, se basan en resultados obtenidos mediante el análisis estadístico de los fenómenos en ellos involucrados.

Además, dado el crecimiento exponencial de las fuentes de información y el desarrollo acelerado de las herramientas tecnológicas, es apropiado disponer de una sólida fundamentación conceptual y práctica que le permita transformar y comprender grandes cantidades de información.

Material

Los contenidos han sido generados utilizando modelos de generación de texto y consultando algunos materiales que se comparten a continuación. Es importante prever que **algunos de estos vínculos pueden caducar con el tiempo**, por lo cual no es raro que se pierda el acceso a los materiales.

[OpenIntro Statistics](#)

[Estadística para todos - Diana Kelmansky](#)

[Discourse of Objectivity](#)

[To explain or to predict](#)

[Escalas de medición - Jorge Coronado Padilla](#)

[Técnicas de Muestreo sobre una Población a Estudio - Tamara Otzen, Carlos Manterola](#)

OpenIntro Statistics - David Diez

Análisis bivariante - Jordi Mas Elias

Handbook on Constructing Composite Indicators: Methodology and User Guide

Diseño y validación de instrumentos de medición

Principal Component Analysis

Recopilación

La tarea de recopilar y organizar la información ha sido llevada a cabo por Julián Cruz.

Científico de datos, profesional en estadística y magíster en ciencias, con más de 15 años de experiencia demostrada en analítica y ciencia de datos. Su perfil contempla desde liderazgo de programas de capacitación y gestión del cambio, hasta ejecución proyectos de base tecnológica. A través de esta experiencia ha desarrollado diferentes competencias, como la orientación al valor en toma de decisiones, la conformación y desarrollo de equipos de alto desempeño y la negociación integradora.

ToDo

```
# Pruebas de hipótesis: analíticas paramétricas, analíticas no paramétricas, computacionales  
# Poner todas las fórmulas en cajas  
# Variables cualitativas, cómo se ven en un gráfico, cuáles son sus elementos visuales, cómo  
# Hacer capítulo de preparación de los datos.  
##### Completar la fórmula de las estadísticas descriptivas  
# Actualizar los covers para que coincidan con los capítulos  
# Organizar modelamiento supervisado  
# Organizar modelamiento no supervisado  
# Que todo salga en pdf  
# Poner una portada
```

Asignación de capítulos:

```
# C01_prelim: Juan Diego.  
# C01_prepara: Néstor  
# C01_corr: Miguel  
# C01_vis: Néstor  
# C01_dist: Miguel  
# C02_episteme: Juan Diego  
#  
# Asignación de tareas  
#  
# Portada: Néstor  
# Revisión global: Todos  
# Revisión bibliográfica: Raquel  
# Diagramas: Raquel  
# Revisión de publicación (tablas y gráficos): Raquel  
# Prólogo: ?  
#  
#  
#  
# Importante: Citación y bibliografía en cada capítulo en bibtex  
#  
#
```

 Ejemplo

Caja para escribir ejemplos

 Fórmula

Caja para escribir fórmulas

Autores

Laboratorio Interdisciplinario de Medición de Dinámicas Sociales

El Laboratorio Interdisciplinario de Medición de Dinámicas Sociales surge como respuesta a la necesidad de un espacio dedicado a organizar y gestionar la información producida en el Centro de Investigación sobre Dinámica Social – CIDS y en la Facultad de Ciencias Sociales y Humanas. Articula capacidades, impulsa proyectos que exploran las dinámicas sociales desde perspectivas estadísticas, matemáticas, comunicativas y tecnológicas, y produce conocimiento relevante y verificable. También unifica y estandariza la información institucional, orienta a la Facultad y a su comunidad en temas clave, fomenta la creación de repositorios y administra datos propios y externos para fortalecer el trabajo investigativo.

[Ver más](#)

Nestor Orlando Rojas Castillo



Docente investigador nestor.rojas@uexternado.edu.co

Contador Público de la Universidad Nacional de Colombia, Especialización en Métodos de Análisis Demográficos, Maestría en Estudios de Población de la Universidad Externado de Colombia.

Raquel Soraya Ortega Bolaños



Docente raquel.ortega@uexternado.edu.co

Ingeniera de sistemas de la Universidad Autónoma de Colombia, Maestría en Nuevas Tecnologías Enfocada a la Educación (TIC) de la Universidad Carlos III de Madrid, Universidad de Alicante, Universidad Autónoma de Barcelona. Maestría en Educación [...]

Miguel Ángel Méndez Marín



Docente investigador miguelm.mendez@uexternado.edu.co

Licenciado en Matemáticas de la Universidad Pedagógica de Colombia, Maestría en Educación modalidad en investigación de la Universidad Externado de Colombia.

Julián Mauricio Cruz Pulido



Docente investigador julian.cruz@uexternado.edu.co

Científico de datos, profesional en estadística y magíster en ciencias de la Universidad Nacional de Colombia. Cuenta con más de 15 años de experiencia demostrada en analítica y ciencia de datos.

Part I

Estadística descriptiva

En esta primera sección se examina la estadística descriptiva. El contenido ha sido seleccionado cuidadosamente con el fin de agregar valor a los análisis cuantitativos que se proponen al interior de las investigaciones en ciencias sociales.

Introducción

Este primer tema introduce a los estudiantes en los conceptos básicos de la estadística, comenzando por una definición de estadística y su relevancia en el análisis de datos. Se exploran los **tipos de variables**, que incluyen **variables cualitativas** (nominales y ordinales) y **cuantitativas** (discretas y continuas). A continuación, se aborda la **tipología de preguntas** en encuestas, diferenciando entre preguntas abiertas, cerradas y escalas, y cómo estas se relacionan con la medición de las variables. También se presentan los **tipos de encuestas**, clasificadas según el método de recolección (presencial, telefónica, online, etc.), su estructura (estructuradas, semi-estructuradas, no estructuradas) y los contextos en los que se aplican, lo cual es fundamental para la adecuada recolección de datos en cualquier estudio estadístico.

Muestreo

En este tema se abordan los fundamentos del **muestreo**, que es el proceso de seleccionar una parte representativa de una población para inferir conclusiones sobre el total. Se explican dos grandes tipos de muestreo: **probabilístico** y **no probabilístico**. En el muestreo probabilístico, cada elemento de la población tiene una probabilidad conocida y no nula de ser seleccionado, y se estudian técnicas como el **muestreo aleatorio simple**, el **muestreo multietápico**, el **muestreo estratificado** y el **muestreo por conglomerados**. En el muestreo no probabilístico, la selección no se basa en probabilidades, sino en criterios subjetivos o conveniencia, como el **muestreo por conveniencia**, **muestreo por cuotas** o **bola de nieve**. Este tema profundiza en las ventajas y limitaciones de cada enfoque, subrayando la importancia de la representatividad de la muestra y cómo esto afecta los resultados y su generalización.

Estadística descriptiva para una variable

La **estadística descriptiva para una variable** se centra en la síntesis y descripción de los datos mediante medidas numéricas y representaciones gráficas. Se examinan las **medidas de tendencia central** como la media, la mediana y la moda, que resumen el comportamiento típico de la variable. También se analizan las **medidas de dispersión** como el rango, la varianza y la desviación estándar, que describen la variabilidad en los datos. El tema incluye el uso de **gráficos** como histogramas, gráficos de barras y diagramas de caja para visualizar la distribución de los datos. Estas herramientas permiten una comprensión clara de cómo los datos están distribuidos y proporcionan una base sólida para la inferencia estadística.

Estadística descriptiva para dos o más variables

Este tema amplía el análisis de la estadística descriptiva a dos o más variables, abordando técnicas para analizar relaciones y asociaciones entre ellas. Se introducen las **tablas de contingencia** para estudiar la relación entre dos variables cualitativas, así como las **medidas de asociación** como el **coeficiente de correlación de Pearson** y **Spearman** para variables cuantitativas. También se discuten las **gráficas de dispersión** para visualizar relaciones entre dos variables cuantitativas y cómo se puede ajustar una **recta de regresión** para predecir una variable en función de otra. Además, se examinan los **coeficientes de correlación parcial** y **análisis multivariado** para explorar cómo varias variables se relacionan simultáneamente, lo que permite una comprensión más profunda de las interacciones dentro de los datos.

1 Preliminares

La estadística, en su concepción moderna, es el resultado de un extenso desarrollo histórico y epistemológico que refleja la evolución del pensamiento humano en su búsqueda de regularidades observables en los fenómenos naturales. Si bien su aparición como concepto se remonta hasta 1770, sus raíces como práctica se remontan a la antigüedad, cuando las civilizaciones de Babilonia y Egipto utilizaban métodos de conteo y registro para la administración de los recursos. Estas aplicaciones configuraron un acercamiento del concepto estadística con la actividad gubernamental que ha perdurado hasta la actualidad, a través de los orígenes etimológicos de la palabra, proveniente del latín *status* o estado.

Siglos después, el descubrimiento de las regularidades en los juegos de azar practicados en Grecia y Roma daría grandes aportes a la teoría estadística. Sin embargo, debido a las ideas religiosas y filosóficas del medievo, que suponían una explicación de la ocurrencia de los eventos gracias a la voluntad divina en lugar de operar según leyes de probabilidad, no sería hasta el Renacimiento cuando se formalizaría el pensamiento probabilístico, de la mano de figuras como Gerolamo Cardano y Pierre de Fermat, quienes cimentaron las bases matemáticas que darían forma a su carácter científico. Al mismo tiempo, en el campo de la astronomía se acrecentó la medición de los fenómenos celestes, gracias a científicos como Galileo, Pascal, Laplace y Gauss, que realizaron contribuciones como la distribución continua y la distribución normal.

Más adelante, a partir del siglo XVIII los métodos estadísticos se extendieron más allá de las ciencias naturales y se introdujeron fuertemente en las ciencias sociales, fundamentalmente, a través de la economía, la sociología y la demografía, lo que permitió el uso de sus postulados en el estudio de los mercados, de la organización social y de las poblaciones, respectivamente. En cuanto a su evolución como ciencia, la epistemología de la estadística comenzó a consolidarse con las contribuciones de pensadores como Thomas Bayes, quien introdujo un enfoque probabilístico basado en la actualización del conocimiento, y Carl Friedrich Gauss, cuya teoría de errores cimentó el papel de la estadística en la inferencia científica. Así, a medida que el método científico se institucionalizaba, la estadística se convirtió en un vehículo para traducir fenómenos observables en explicaciones cuantitativas, adoptando principios de objetividad, reproducibilidad y rigor.

El siglo XX marcó una transformación paradigmática en el campo de la estadística, impulsada por los avances en la teoría de conjuntos, el cálculo y la computación. La estadística inferencial y la probabilidad frecuentista, promovidas por Fisher, Neyman y Pearson, coexistieron con enfoques bayesianos, provocando debates epistemológicos sobre la naturaleza del azar y la inferencia. Esta diversidad metodológica enriqueció su aplicabilidad, desde el diseño de experimentos hasta el análisis de sistemas complejos en las ciencias sociales.

Hoy, la estadística es no solo un instrumento técnico, sino también un lenguaje epistemológico que da forma a cómo entendemos la realidad. Su desarrollo histórico subraya la tensión entre el dato y la interpretación, entre el caos del mundo empírico y la búsqueda de orden intelectual.

1.1 Definiciones

El lenguaje matemático es un subconjunto del lenguaje y, por tanto, su estudio debe partir por la comprensión de su morfología y sintaxis. La estadística, como disciplina, se basa en el análisis sistemático de información cuantitativa o cualitativa para describir, interpretar y predecir fenómenos. Tres conceptos clave estructuran este análisis: los datos, las variables y los individuos. Cada uno cumple un rol específico, interconectado y esencial en el proceso de generación de conocimiento.

1.1.1 ¿Qué son los datos?

Los datos son el registro de observaciones, medidas o respuestas recopiladas sobre un fenómeno o población de interés. Constituyen la materia prima del análisis estadístico y pueden ser numéricos (cuantitativos) o descriptivos (cualitativos). Los datos por sí mismos son neutros; adquieren significado solo cuando se contextualizan y se analizan en relación con una pregunta o hipótesis.

Por ejemplo, el registro de temperaturas diarias en una ciudad o las respuestas a una encuesta sobre hábitos de consumo son datos. Estos sirven como base para identificar patrones, realizar comparaciones y construir modelos que representen aspectos de la realidad.

El análisis de datos es la columna vertebral de la investigación científica y social, en la búsqueda de extraer patrones, relaciones y tendencias a partir de observaciones sistemáticas, por lo que comprender sus diferentes tipos y propiedades es esencial para elegir las metodologías y enfoques más adecuados. No obstante, esta labor presenta diversos obstáculos en el ámbito de las ciencias sociales, tanto en la brecha significativa entre las competencias cuantitativas necesarias para el análisis de datos y las herramientas empleadas por los investigadores, como en la resistencia hacia el aprendizaje de habilidades cuantitativas.

El uso de programación en el análisis de datos es frecuentemente percibido como un campo exclusivo de disciplinas STEM (ciencia, tecnología, ingeniería y matemáticas). Esta percepción puede desmotivar a los científicos sociales, quienes a menudo ven estas competencias como ajena a sus intereses y tradiciones. Aún así, a medida que las metodologías de análisis avanzan, la integración de enfoques cuantitativos se vuelve inevitable. La combinación de grandes volúmenes de datos (*big data*), tecnologías accesibles y herramientas estadísticas ha revolucionado la forma en que se abordan preguntas de investigación. Desde el análisis de redes sociales hasta el estudio de comportamientos colectivos, las ciencias sociales dependen cada vez más de métodos que requieren un manejo competente de datos y software especializado.

De cualquier modo, el primer paso para el desarrollo de estas habilidades cuantitativas consiste en cambiar de mentalidad respecto al uso de datos y reconstruir esta relación requiere un cambio de perspectiva en varios niveles. A nivel formativo, a través de la incorporación de competencias de programación, análisis de datos y estadística en la formación de los científicos sociales, con un enfoque interdisciplinario. A nivel técnico, en los currículos de las ciencias sociales deben integrarse herramientas como R, Python y software estadístico especializado (en especial, de código abierto) que permitan a los científicos sociales realizar análisis más complejos sin depender de costosos recursos. A nivel profesional, gracias a la aplicación del análisis de datos en sectores como el marketing, la planificación urbana y el desarrollo comunitario.

Un primer acercamiento a los datos puede verse de esta manera. Para nuestro ejemplo vamos a pensar en un conjunto de 100 personas que recién ingresan a una universidad en Bogotá en 1990, indagamos el género y la edad de cada una de ellas. Estos datos se pueden ver de esta forma.

19.1	16.1	17.9	15.9	18.1	18.3	18.5	19.4	17.9	15.3
18.6	18.8	17.5	19.4	20.5	18.4	16.8	19.1	18.6	18.8
15	15.7	16.9	17.3	19.7	14.7	19.1	17.7	15.8	17.7
19	19.3	16.6	17.9	16.2	19.4	18.6	15.8	19.5	15.5
19	14.9	19.3	19.7	20.5	19.7	16.4	16.8	15.7	18
18.2	17.4	14.5	18	16.2	19.1	17.4	16.6	15.7	14.7
15.8	16.6	15.9	17.9	18.5	15.9	17.4	19.7	18.5	17.7
18.2	17.1	15.3	16.8	19.6	19.8	18.2	16.5	16.6	17.9
17.8	19.3	17	18.5	16	17.8	16.8	15.8	18.3	15.5
17	18.1	15.5	16.9	18.7	17.7	17.6	16.8	21	18.1

Figure 1.1: Figura 1: Edades de 100 personas coloreadas por género, siendo femeninos los rojos y masculinos los azules. Fuente: elaboración propia a partir de simulación.

Esta forma de ver los datos no nos entrega una información fácil de comprender. Por esta razón, la **visualización de datos** es importante en el análisis estadístico. Para comprender mejor, abordemos primero la edad. Podemos ver los datos de la edad como puntos en el eje horizontal.

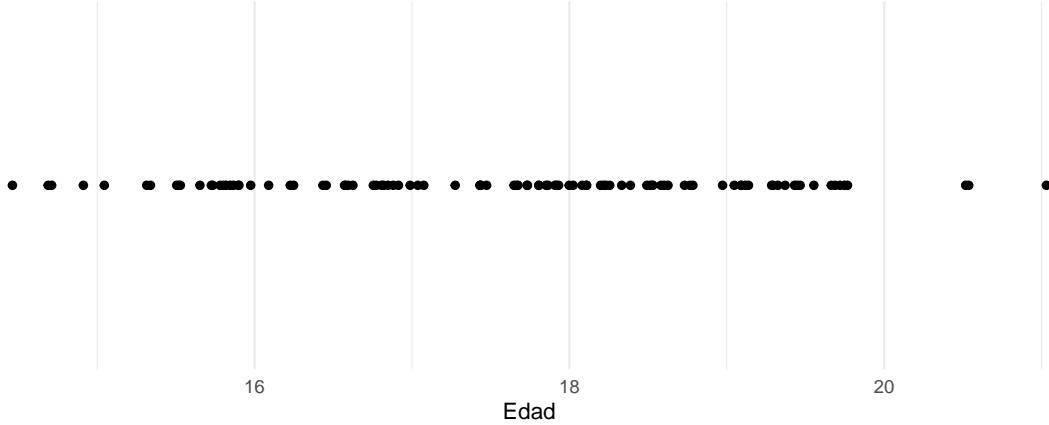


Figure 1.2: Figura 2: Edades de 100 personas en el eje horizontal. Fuente: elaboración propia a partir de simulación.

Esta visualización nos entrega un poco más de información, podemos entender el valor más alto, el más bajo, y en general el espacio que ocupan los datos en el eje horizontal. Los datos que ocupan mucho espacio se llaman **dispersos**, si el espacio es poco, se llaman **concentrados**. Más adelante veremos medidas para esta característica y profundizaremos al respecto. Para verlos mejor, podemos diseminarlos verticalmente. Este es un truco que ayuda a comprender mejor los datos, impidiendo que se sobrepongan los puntos. Para esto se agrega ruido en el eje vertical, pero este ruido no tiene significado.

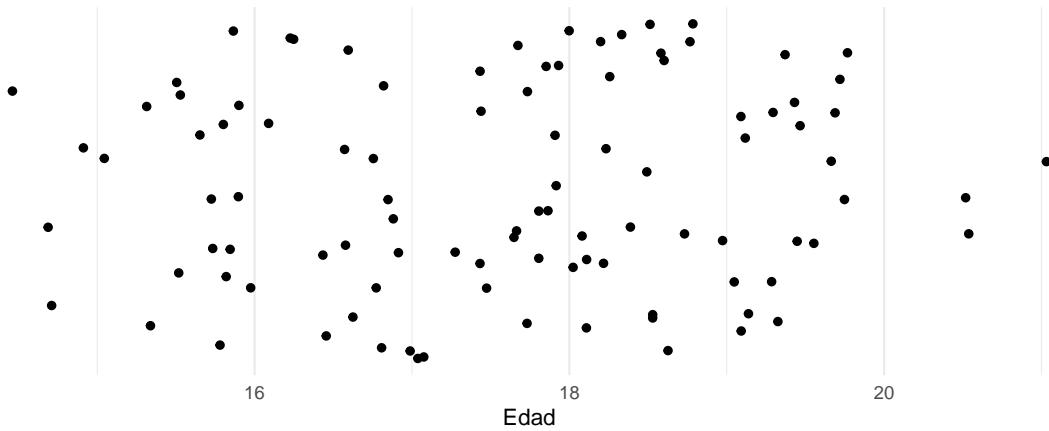


Figure 1.3: Figura 3: Edades de 100 personas en el eje horizontal con ruido vertical. Fuente: elaboración propia a partir de simulación.

Podemos trazar líneas imaginarias para entender mejor los datos. Las primeras líneas imaginarias son el máximo y el mínimo. Al trazar estas líneas podemos contener el 100% de los datos. Es

muy fácil.

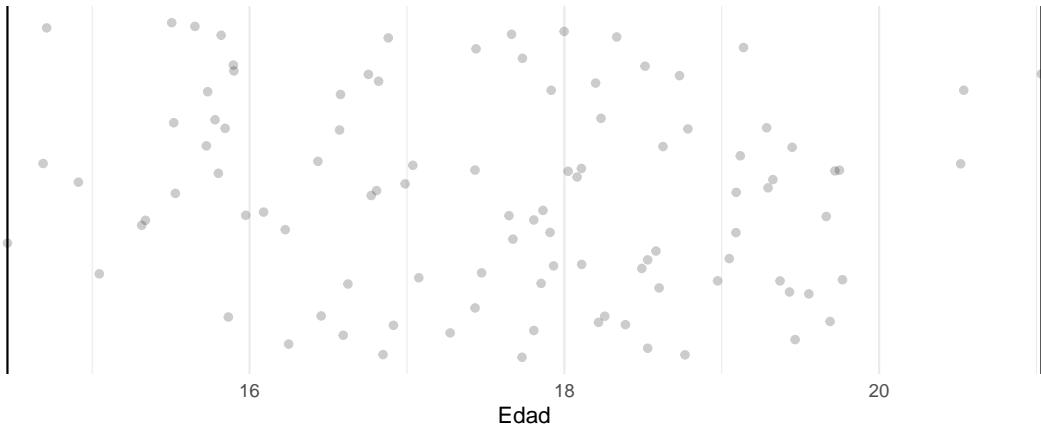


Figure 1.4: Figura 4: Edades de 100 personas en el eje horizontal con máximo y mínimo. Fuente: elaboración propia a partir de simulación.

Ahora trazamos una línea que divide los datos en dos conjuntos de igual magnitud. A la derecha de la línea se encuentra la misma cantidad de datos que a la izquierda. Esta línea se encuentra en un punto muy importante del eje horizontal, este valor se denomina la mediana. La mediana de un conjunto de datos es el valor que divide a los datos en dos conjuntos de igual magnitud.

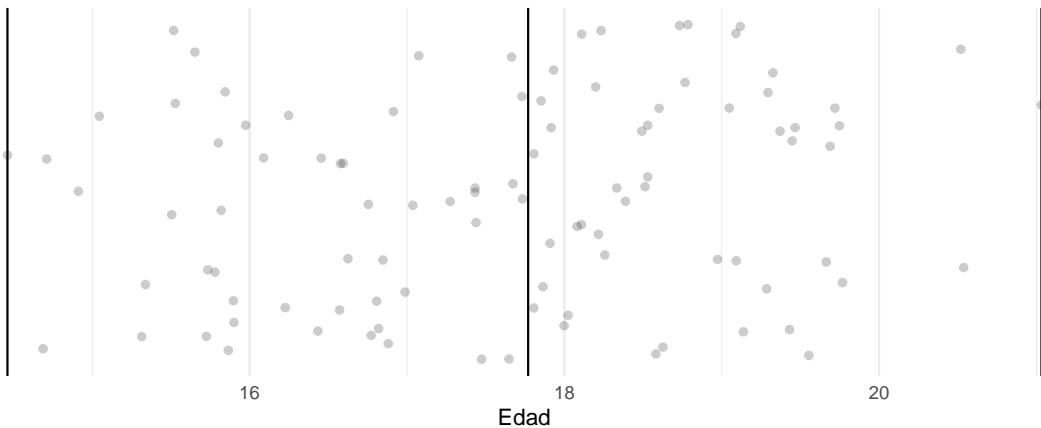


Figure 1.5: Figura 5: Edades de 100 personas en el eje horizontal con su mediana. Fuente: elaboración propia a partir de simulación.

Usando más líneas imaginarias podemos dividirlos en cuatro partes iguales. Estas líneas imaginarias distribuyen los datos de la edad en cuatro conjuntos de igual magnitud. Al igual

que la mediana, estos valores son importantes. Se denominan cuartiles. En cada uno de los conjuntos resultantes, se encuentra el 25% de los datos.

Entonces, funciona de la siguiente forma: el cuartil cero (Q_0) corresponde al valor mínimo; el primer cuartil (Q_1) separa el 25% de los datos; el segundo cuartil (Q_2) coincide con la mediana, porque separa el 50% de los datos; el tercer cuartil (Q_3) separa el 75% de los datos; y el cuarto cuartil (Q_4) coincide con el máximo de los datos.

Estos cuartiles en general no tienen la misma distancia entre ellos. Lo usual es que se ubiquen en distancias diferentes según los datos.

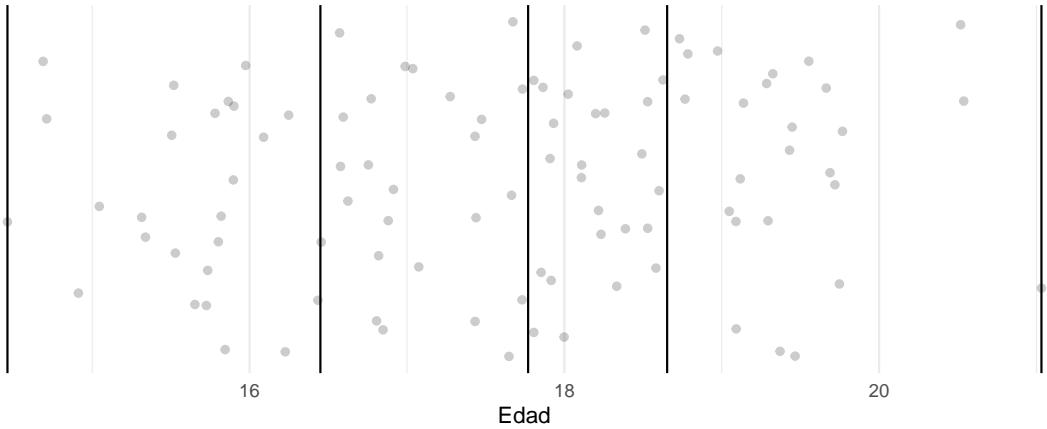


Figure 1.6: Figura 6: Edades de 100 personas en el eje horizontal con cuartiles. Fuente: elaboración propia a partir de simulación.

Estas líneas imaginarias se pueden consolidar en un solo gráfico, que se denomina gráfico de caja y bigotes, conformado por la mediana y los cuartiles. Este gráfico es esencial en el análisis de datos como veremos en muchas investigaciones.

Este gráfico tiene un cambio con respecto a la construcción anterior: aquí se utilizan un máximo teórico y un mínimo teórico. Esto se realiza con el fin de identificar visualmente los datos de los extremos.

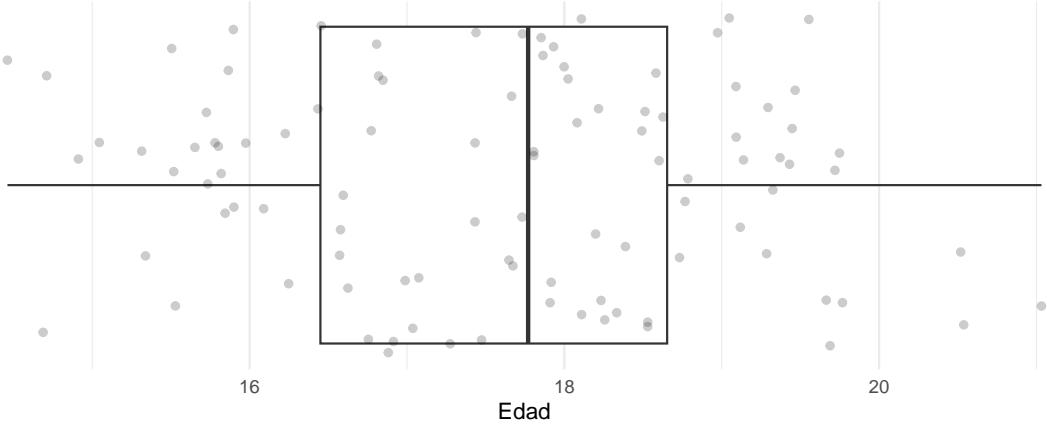
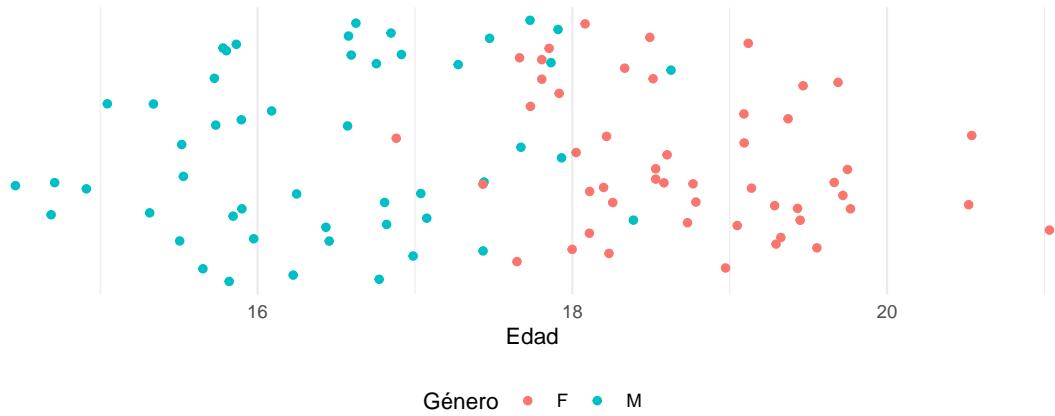
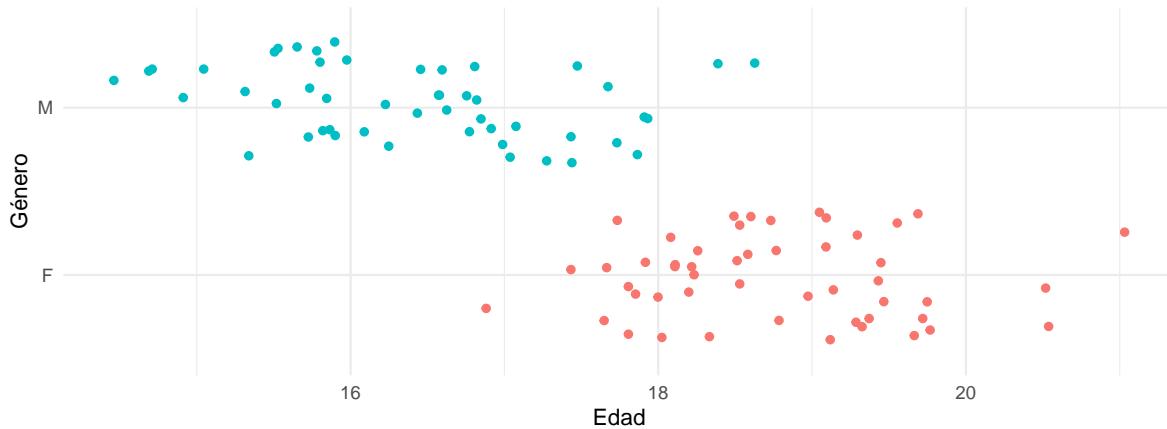


Figure 1.7: Figura 7: Edades de 100 personas, gráfico de caja y bigotes. Fuente: elaboración propia a partir de simulación.

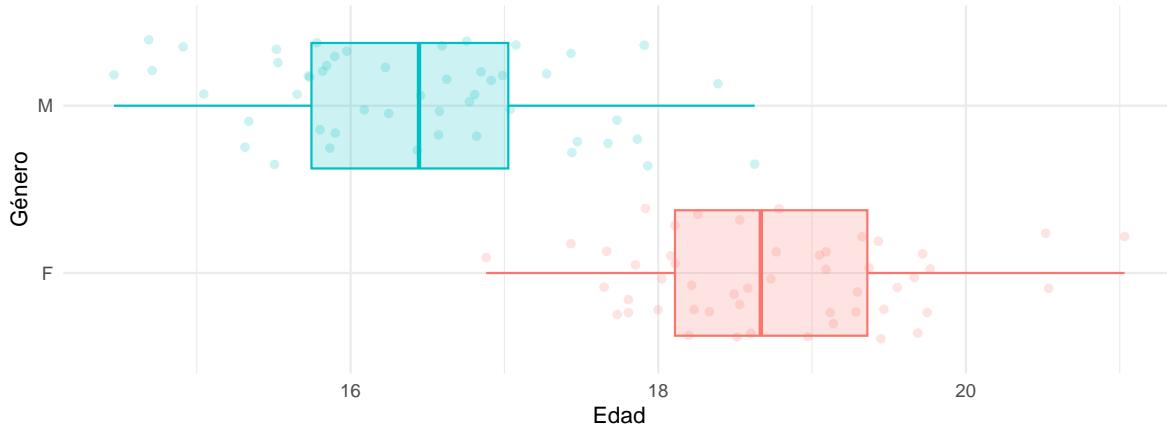
Abordemos el género ahora. Podemos usar el color para identificar el género en los datos. Realizamos el mismo procedimiento añadiendo el color del género. En este caso, ya podemos identificar la tendencia, de puntos rojos más a la derecha y azules más a la izquierda.



Organizamos los datos verticalmente por género. Esto nos permite tener dos nubes de puntos y facilita la interpretación, ahora es más notoria la tendencia hacia a la derecha y hacia la izquierda de los puntos rojos y azules respectivamente.



Al elaborar un gráfico de caja y bigotes para cada género es posible ver la tendencia. Esta característica que no resultaba fácil de identificar en el primer gráfico ahora es muy evidente. Las medianas y los cuartiles de los datos agrupados por género difieren. Esto nos permite obtener hipótesis que podremos comprobar más adelante.



1.1.2 ¿Qué son las variables?

Las variables son características o atributos que pueden tomar diferentes valores entre los individuos de un conjunto o población. Representan las dimensiones específicas que se desean observar en un estudio y funcionan como el puente entre las observaciones individuales y los análisis que buscan generalizar comportamientos.

Las variables se clasifican según su naturaleza en:

- 1. Numéricas:** Estas variables representan magnitudes numéricas que se pueden medir. Estas variables son esenciales en áreas como la economía y la biología, donde los fenómenos físicos y financieros se representan mediante medidas precisas.

- **Discretas:** Toman valores finitos o contables, como el número de hijos en una familia.
 - **Continuas:** Admiten infinitos valores dentro de un rango, como la temperatura medida en grados Celsius.
2. **Categóricas:** Representan atributos o categorías que no necesariamente poseen un valor numérico. Las variables categóricas agrupan a los individuos en categorías o clases. Este tipo de variable es fundamental en estudios demográficos y de percepción social, donde las características subjetivas y de identidad son el foco principal.
- **Nominales:** Categorías sin orden intrínseco, como el color de los ojos o el estado civil.
 - **Ordinales:** Categorías con un orden lógico, como los niveles educativos o el nivel de satisfacción.

Las variables permiten organizar y estructurar los datos para su análisis de acuerdo con los intereses de la investigación. Por ejemplo, en un estudio sobre la educación, “nivel educativo” podría ser una variable cualitativa ordinal, mientras que “puntaje en una prueba” sería una variable cuantitativa continua.

1.1.3 ¿Qué son los individuos?

Los individuos son las unidades básicas de observación o análisis dentro de una población. Pueden ser personas, objetos, organismos, eventos o entidades, dependiendo del contexto del estudio.

Por ejemplo:

- En un censo poblacional, los individuos son las personas encuestadas.
- En un experimento agrícola, los individuos podrían ser plantas o parcelas de tierra.
- En un análisis de mercado, los individuos son los productos o consumidores.

Cada individuo se caracteriza por tener valores específicos para las variables consideradas en el estudio. Por ejemplo, en una encuesta sobre hábitos alimenticios, un individuo (una persona) podría tener valores como edad = 30 años, género = femenino, y frecuencia de consumo de frutas = 5 veces por semana.

En términos analíticos, los individuos son la fuente de datos a partir de los cuales se construyen modelos, hipótesis y conclusiones. La elección de los individuos y su caracterización es clave, ya que determina la validez y generalizabilidad de los resultados. Por ejemplo, en un estudio sobre hábitos alimenticios, seleccionar individuos representativos de diferentes regiones y estratos socioeconómicos garantizará que las conclusiones puedan extrapolarse al resto de la población.

Este concepto está íntimamente ligado al diseño del muestreo y la operacionalización de las variables.

Cabe aclarar que en el análisis de una población no se estudian los individuos por separado y al máximo detalle, sino que se pretende identificar tendencias que representen comportamientos agregados que emergen de las características individuales de una población. A diferencia de una afirmación puntual o específica sobre un individuo, las tendencias buscan capturar patrones generalizables que describen cómo un grupo, en promedio, se comporta respecto a una variable o conjunto de variables. Este enfoque es crucial en disciplinas como la economía, la sociología y la epidemiología, donde los fenómenos globales informan decisiones de política pública o estrategias organizacionales.

Por ejemplo, al analizar los hábitos de consumo en un país, una tendencia podría revelar que el promedio de gasto en entretenimiento es más alto en grupos jóvenes que en mayores de 50 años. Sin embargo, esta tendencia no asegura que todos los jóvenes gasten más en entretenimiento, sino que describe un comportamiento predominante dentro de la población estudiada. Este desajuste entre las tendencias y los comportamientos individuales resalta la importancia de interpretar los datos globales como representativos, pero no absolutos.

1.1.4 Medición: Asignación de valores a las observaciones

Una vez se han comprendido los conceptos de dato, variable e individuo es de suma importancia recabar en el papel crucial que juega la medición en el análisis de datos. En este orden de ideas, cabe señalar que la medición es siempre una operación subjetiva, en la medida en que el mundo medido es el mundo visto desde la perspectiva de un sujeto. Luego, no hay medición si no hay sujeto que mide.

La medición es el proceso mediante el cual las características de los individuos se transforman en datos observables y cuantificables. Este proceso debe ser riguroso y consistente, basado en reglas preestablecidas que garanticen la comparabilidad y la reproducibilidad de los resultados.

Por ejemplo, en un estudio sobre bienestar subjetivo, es esencial que las escalas utilizadas para medir “felicidad” o “satisfacción” estén claramente definidas, estandarizadas y validadas. Una medición precisa y confiable no solo facilita el análisis estadístico, sino que también asegura que las conclusiones se basen en datos sólidos y significativos.

Los tipos de datos, las variables y las técnicas de medición constituyen los elementos centrales del análisis en cualquier disciplina. Entender cómo se relacionan las tendencias globales con las características individuales, cómo se seleccionan y clasifican las variables, y cómo se mide con precisión cada atributo son habilidades fundamentales para el análisis riguroso. Este marco integrado no solo es esencial para la investigación académica, sino también para la toma de decisiones informadas en contextos profesionales y sociales. La reconceptualización del trabajo con datos requiere, por tanto, no solo conocimiento técnico, sino también una reflexión crítica sobre las implicaciones de cómo estructuramos y utilizamos la información.

2 Preparación de los datos

2.1 Limpieza

2.1.1 Identificación de atípicos

2.1.2 Corrección de errores

2.1.3 Codificación y decodificación

Qué hacer cuando el sexo es 1 - hombre y 2- mujer, o el nivel educativo es 1 -primaria incompleta, 2 - primaria completa... como en spss

2.1.4 Imputación de datos

2.2 Modificaciones

2.2.1 De categórico a numérico

2.2.2 De numérico a categórico

2.2.3 Trabajo con fechas

2.3 Escalamiento univariado

2.3.1 Normalización

2.3.2 Estandarización

2.3.3 Uniformado

2.4 Procesamiento previo

La preparación de datos implica transformar los datos en un formato adecuado para su uso en el modelamiento.

2.5 Limpieza de datos

- **Imputación de valores faltantes:** Selección de técnicas para manejar datos faltantes, como eliminación de casos, imputación con la media o mediana, o el uso de modelos predictivos.
- **Eliminación de duplicados:** Identificación y eliminación de registros duplicados que podrían sesgar los resultados del modelo.
- **Corrección de errores:** Revisión de los datos para corregir errores como registros mal ingresados, incoherencias, o valores fuera de rango.

2.6 Transformación de datos

- **Normalización o estandarización:** Ajuste de las escalas de las variables para que tengan un rango comparable, lo cual es especialmente importante en técnicas como el análisis de componentes principales o modelos de machine learning.
- **Codificación de variables categóricas:** Conversión de variables categóricas en variables numéricas mediante técnicas como la codificación one-hot o el etiquetado ordinal.
- **Creación de nuevas variables:** Generación de nuevas variables que puedan capturar relaciones más complejas en los datos (por ejemplo, interacciones entre variables o variables derivadas).

3 Estadística descriptiva para una variable

3.1 Medidas de frecuencia

En el análisis de datos dentro de las ciencias sociales, las medidas de frecuencia permiten describir de manera precisa la distribución de variables **categóricas** y ayudan a comprender patrones generales en poblaciones o muestras. Estas medidas son esenciales para resumir y comunicar la información de forma efectiva, aportando una base sólida para el análisis estadístico posterior.

3.1.1 Frecuencia

La **frecuencia absoluta** es el conteo del número de veces que aparece una categoría específica en un conjunto de datos. Es la medida más básica de estadística descriptiva y es crucial para comprender la distribución de variables cualitativas. Las categorías en un conjunto de datos representan respuestas a preguntas de encuestas, atributos de los participantes o clasificaciones en estudios sociales.

💡 Tip

Ejemplo aplicado a las ciencias sociales: En un estudio sobre preferencias políticas, los encuestados pueden expresar su afinidad por diferentes partidos. Si en una muestra de 500 personas, 150 apoyan el partido A, 200 el partido B y 150 no apoyan a ningún partido, la frecuencia de cada categoría sería:

- **Partido A:** 150
- **Partido B:** 200
- **Ninguno:** 150

Este conteo ayuda a determinar cuál es el partido con mayor número de seguidores y, por ende, cuál tiene una posición predominante en la muestra.

3.1.2 Proporción

La **proporción** se utiliza para expresar la frecuencia relativa de una categoría con respecto al total de observaciones, facilitando la comparación entre diferentes grupos de datos. Se calcula dividiendo la frecuencia de una categoría por el total de observaciones.



Warning

Fórmula:

$$p_i = \frac{\#\text{freq}_i}{n}$$

Donde:

- p_i es la proporción.
- $\#\text{freq}_i$ es la frecuencia de la categoría específica (i -ésima).
- n es el número total de observaciones.



Tip

Ejemplo contextualizado: Supongamos que en una encuesta sobre el uso de redes sociales, se encontró que 320 de 800 personas utilizan redes sociales diariamente. La proporción de usuarios diarios es:

$$p_{rs} = \frac{320}{800} = 0.40 \text{ o } 40\%$$

Este resultado indica que el 40% de los encuestados son usuarios diarios de redes sociales, un hallazgo importante para estudios sobre comportamiento digital y hábitos de consumo en la sociedad.

Las frecuencias relativas suelen presentarse en porcentajes. Un **porcentaje** es una forma de expresar una fracción o proporción sobre un total de 100, facilitando la comparación y comprensión de datos en contextos variados. Se utiliza ampliamente en estadísticas, finanzas y análisis cuantitativo para representar partes de un todo. La palabra “porcentaje” proviene del latín “per centum,” que significa “por cada cien.” Su uso se remonta a la antigua Roma, donde los comerciantes y cobradores de impuestos empleaban fracciones y cálculos semejantes al porcentaje moderno para facilitar transacciones y registros contables. A lo largo de los siglos, el concepto se perfeccionó, especialmente durante el Renacimiento, con la expansión del comercio y la necesidad de representar proporciones de forma estandarizada, llevando al símbolo “%” que hoy es universal.

3.1.3 Moda

La **moda** es la categoría con mayor frecuencia en un conjunto de datos y representa el valor más común o frecuente. Esta medida es particularmente útil en estudios sociales cuando se analizan características como la ocupación, el nivel de estudios o las opiniones sobre políticas públicas. La moda permite identificar tendencias dominantes o respuestas mayoritarias en la población estudiada.



Tip

Ejemplo aplicado: Imaginemos un estudio que investiga la ocupación principal de los trabajadores en una ciudad. Si los datos muestran que, de 1,000 encuestados, 450 trabajan en el sector servicios, 300 en el sector manufacturero y 250 en el sector tecnológico. En este caso la moda es “Sector servicios”

Este dato resalta que la ocupación predominante en la muestra es el sector servicios, una observación relevante para estudios de desarrollo económico y planificación urbana.

3.1.4 Nota sobre variables continuas

La moda tiene aplicaciones limitadas en variables continuas, como el ingreso o la altura, ya que estas tienden a no repetir valores exactos con frecuencia significativa. Sin embargo, en ciertas investigaciones sociales, agrupar datos en rangos puede hacer que la moda sea más útil. Por ejemplo, si se clasifica el ingreso en intervalos como “menos de \$10,000”, “\$10,001-\$20,000”,..., etc., puede ser posible identificar una moda representativa del grupo con mayor frecuencia.



Tip

Ejemplo adaptado: Si se analizan los ingresos de 500 hogares y el intervalo “\$10,001-\$20,000” tiene la mayor cantidad de hogares (150), entonces la moda del ingreso agrupado es ese intervalo específico. Esta información puede ser crucial para entender el nivel socioeconómico predominante en un área geográfica y para la formulación de políticas de asistencia económica.

3.2 Medidas de tendencia central

Las **medidas de tendencia central** son estadísticas descriptivas que representan el valor típico o central de un conjunto de datos. Estas medidas permiten comprender dónde se encuentra el “centro” de una distribución y son fundamentales en la investigación cuantitativa en ciencias sociales, donde se estudian fenómenos como ingresos, opiniones o resultados de encuestas.

3.2.1 Media aritmética

La **media aritmética**, comúnmente conocida como promedio, es la medida de tendencia central más utilizada. Se obtiene sumando todos los valores de un conjunto de datos y dividiendo el resultado por el número total de observaciones. La media es ideal para describir conjuntos de datos simétricos y es especialmente útil en estudios de ciencias sociales cuando se necesita resumir características cuantitativas como la edad, el ingreso o la puntuación de una encuesta.



Warning

Fórmula de la media:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Donde:

- \bar{x} es la media,
- n es el número de observaciones,
- x_i representa cada valor individual del conjunto de datos.



Tip

Ejemplo en ciencias sociales: Supongamos que estamos estudiando los ingresos mensuales en una comunidad y los datos obtenidos en dólares son: 1,200, 1,500, 1,800, 2,000 y 20,000. La media de estos ingresos es:

$$\bar{x} = \frac{1,200 + 1,500 + 1,800 + 2,000 + 20,000}{5} = \frac{26,500}{5} = 5,300$$

Aunque la media es 5,300, este valor puede no representar adecuadamente la distribución, ya que un ingreso atípico de 20,000 distorsiona el promedio.

3.2.2 Mediana

La **mediana** es la medida de tendencia central que divide un conjunto de datos ordenados en dos partes iguales, es decir, la mitad de los datos está por debajo y la otra mitad por encima de la mediana. Esta medida es más resistente a los valores extremos que la media, por lo que es preferida en distribuciones sesgadas o con outliers.



Tip

Procedimiento para encontrar la mediana:

- Si el número de observaciones es impar, la mediana es el valor central.
- Si es par, la mediana es el promedio de los dos valores centrales.

💡 Tip

Ejemplo aplicado: Si analizamos el número de hijos en familias de una comunidad y los datos ordenados son: 1, 2, 2, 3 y 10, la mediana es 2, ya que es el valor del medio.

3.2.3 Otras medidas de tendencia central

3.2.3.1 Media armónica

La **media armónica** es útil para conjuntos de datos que representan tasas o razones, ya que pondera los valores de forma que las observaciones más pequeñas tengan un mayor impacto. Se define como el inverso del promedio de los inversos de los valores.

⚠ Warning

Fórmula de la media armónica:

$$\bar{x}_{\text{arm}} = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Donde:

💡 Tip

Ejemplo en ciencias sociales: Supongamos que estudiamos la eficiencia de diferentes métodos de transporte urbano en términos de tiempo por viaje. Si los tiempos por viaje (en minutos) son 10, 15 y 20, la media armónica es:

$$\bar{x}_{\text{arm}} = \frac{3}{\frac{1}{10} + \frac{1}{15} + \frac{1}{20}} \approx 13.04$$

Esta media pondera más los viajes cortos y es útil en análisis donde las tasas individuales son significativas.

3.2.3.2 Media geométrica

La **media geométrica** es apropiada para datos que representan crecimiento proporcional o tasas de cambio, como el crecimiento de la población o el rendimiento económico. Es el (n

)-ésimo raíz del producto de todos los valores.



Warning

Fórmula de la media geométrica:

$$\bar{x}_{\text{geo}} = \sqrt[n]{x_1 \cdot x_2 \cdot \dots \cdot x_n}$$



Tip

Ejemplo en ciencias sociales: Si una población crece anualmente a tasas de 1.05, 1.10 y 1.08, la media geométrica del crecimiento es:

$$\bar{x}_{\text{geo}} = \sqrt[3]{1.05 \times 1.10 \times 1.08} \approx 1.076$$

Lo que implica un crecimiento promedio anual del 7.6%.

3.2.3.3 Comparación de las medidas

En resumen, la **media aritmética** es ideal para datos simétricos y sin valores extremos, la **mediana** es preferible en distribuciones sesgadas o con valores atípicos, y las **medias armónica y geométrica** se utilizan en contextos específicos relacionados con tasas o datos multiplicativos. Estas medidas permiten a los investigadores de las ciencias sociales interpretar adecuadamente los datos y tomar decisiones basadas en análisis cuantitativos sólidos.

3.3 Medidas de localización

3.3.1 Mínimo y máximo

El mínimo es el valor más bajo en el conjunto de datos y el máximo es el valor más alto. En estudios sociales, pueden utilizarse para detectar posibles extremos en las variables, como el ingreso o la edad.

3.3.2 Cuantiles

Los cuantiles dividen los datos en partes iguales. En estudios sociales, los cuantiles son útiles para evaluar la distribución de ingresos o educación. Por ejemplo, el cuartil más bajo (25%) representa el grupo con los ingresos más bajos.

⚠ Warning

$$Q_\alpha(x) \sim X_{(\alpha)}$$

3.3.3 Percentiles

Los percentiles son un caso especial de cuantiles y se usan para ver la posición de un valor dentro de una distribución. En educación, el percentil 90 indica que un estudiante superó al 90% de sus compañeros en una prueba estandarizada.

3.3.4 Cuartiles

Los cuartiles dividen los datos en cuatro partes. El primer cuartil (Q1) es el 25% más bajo, y el tercer cuartil (Q3) es el 25% más alto. Estos son útiles para evaluar la dispersión de los ingresos dentro de una población.

3.4 Medidas de dispersión

3.4.1 Varianza

La varianza mide qué tan dispersos están los datos respecto a la media. En estudios de desigualdad de ingresos, una alta varianza indicaría grandes disparidades entre los ingresos de las personas.

⚠ Warning

$$S_x^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

💡 Tip

Ejemplo: En una muestra de ingresos de 2000, 2500, 3000, 3500 y 4000, la varianza nos indica cuánto se alejan estos valores de la media.

3.4.2 Desviación estándar

La desviación estándar es la raíz cuadrada de la varianza y nos proporciona una medida de dispersión en las mismas unidades que los datos originales. Por ejemplo, si la desviación estándar de los ingresos en una población es alta, indica que hay una gran variabilidad en los ingresos.



Warning

$$S_x = \sqrt{S_x^2}$$

3.4.3 Rango intercuartílico (IQR)

El rango intercuartílico es la diferencia entre el tercer cuartil (Q3) y el primer cuartil (Q1). Mide la dispersión central de los datos y es útil para evitar que los valores extremos influyan en la interpretación.



Warning

$$ran(x) = Q_3(x) - Q_1(x)$$

Ejemplo: En una encuesta de satisfacción con el gobierno, el IQR podría mostrar la variación en las respuestas del 50% central, ignorando los valores más extremos de descontento o satisfacción.

3.4.4 Rango

El rango es la diferencia entre el valor máximo y el mínimo. Aunque es fácil de calcular, puede verse afectado por valores atípicos. Por ejemplo, en el análisis de ingresos, el rango puede ser muy amplio si hay pocos individuos con ingresos extremadamente altos.



Warning

$$Rango = \max(x) - \min(x)$$

3.5 Ejercicios y actividades

3.5.1 Hablemos bien

No diga: la gente votó **en promedio** por el candidato X

Diga: la gente votó en **mayor proporción** por el candidato X

3.5.2 Actividad

No diga:

- Esta alternativa es muy buena, nos ahorra menos dolores de cabeza
- La edad promedio de los estudiantes está entre 15 y 20 años.
- En total, uno de cada tres estudiantes no sabe estadística.

Analice

- Más de la mitad de los estudiantes que presentaron la prueba saber están por debajo del promedio del puntaje de inglés.
- El 70% de los colombianos tienen ingresos por debajo de la media.

4 Análisis correlacional

Es posible medir la relación entre dos variables, pero esto depende de qué tipo de variables son.

- Dos cuantitativas
- Una cuantitativa y una cualitativa
- Dos cualitativas

4.1 Dos variables cuantitativas

La relación entre dos variables cuantitativas puede ser medida con los siguientes estadísticos.

- Covarianza
- Correlación de Pearson
- Correlación de Spearman

4.1.1 Covarianza

Covarianza entre dos variables

$$S_{xy} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})$$

4.1.2 Correlación de Pearson

- **Definición:** Mide la fuerza y la dirección de la relación lineal entre dos variables continuas.
- **Rango:** -1 a 1, donde 1 indica una relación lineal positiva perfecta, -1 una relación lineal negativa perfecta y 0 ninguna relación lineal.
- **Cálculo:** Se basa en la covarianza de las dos variables dividida por el producto de sus desviaciones estándar.

$$\rho_{xy} = \frac{\sum x_i y_i - n \bar{x} \bar{y}}{(n-1) S_x S_y}$$

4.1.3 Correlación de Spearman

- **Definición:** Mide la fuerza y la dirección de la relación monótona (no necesariamente lineal) entre dos variables.
- **Ventaja:** Es más flexible que la correlación de Pearson y puede ser utilizada en casos donde la relación no es lineal pero aún sigue una tendencia consistente.
- **Rango:** -1 a 1, donde 1 indica una relación monótona positiva perfecta, -1 una relación monótona negativa perfecta y 0 ninguna relación monótona.

$$\rho = 1 - \frac{6 \sum D^2}{n(n^2 - 1)}$$

donde D es la diferencia entre los correspondientes estadísticos de orden de x - y. N es el número de parejas de datos.

4.1.4 Kendall

- **Definición:** La correlación de Kendall, o tau de Kendall, es una medida de la asociación entre dos variables ordinales que evalúa la relación monótona. A diferencia de Spearman, que utiliza rangos para calcular la correlación, Kendall se basa en la concordancia y discordancia de pares de observaciones.
- **Cálculo:**
 - **Concordancia:** Dos pares de observaciones están en concordancia si el orden de las observaciones en ambos pares es el mismo.
 - **Discordancia:** Dos pares de observaciones están en discordancia si el orden de las observaciones en un par difiere del orden en el otro par.
- **Aplicación:** Útil en análisis de datos ordinales y cuando se desea evaluar la relación entre variables con distribución no normal.

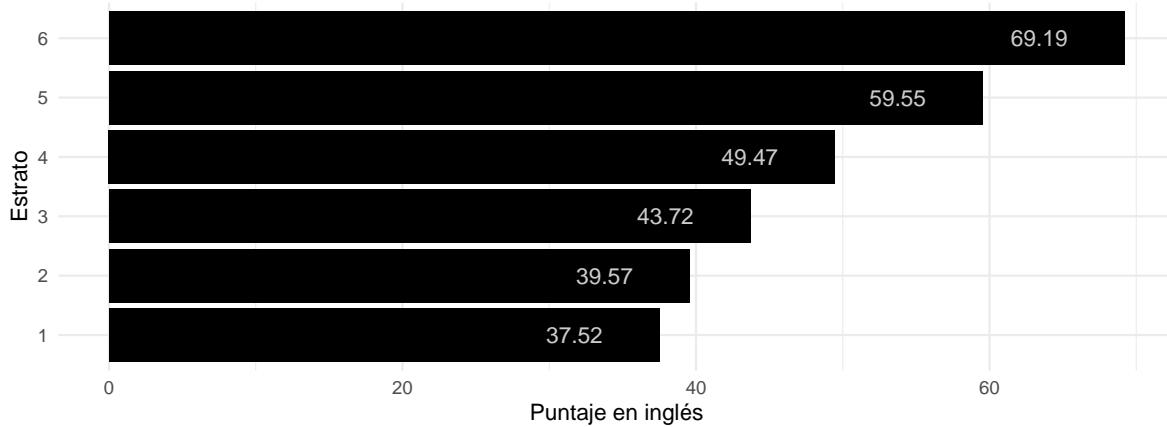
4.2 Asociación numérica - categórica

En ocasiones queremos encontrar la correlación entre una variable numérica y una categórica.

4.2.1 Elementos gráficos

Para visualizar la correlación entre una variable numérica y una categórica, se pueden utilizar diversos elementos gráficos:

- **Diagramas de caja (boxplots):** Muestran la distribución de la variable numérica para cada categoría de la variable categórica.
- **Gráficos de barras:** Representan la media o mediana de la variable numérica para cada categoría de la variable categórica.



4.2.2 ANOVA

El análisis de la varianza es una técnica estadística utilizada para comparar las medias de tres o más grupos y determinar si al menos uno de los grupos es significativamente diferente.

4.2.3 Tipos

- **ANOVA de una vía:** Examina el efecto de una sola variable independiente (factores) sobre la variable dependiente.
- **ANOVA de más vías:** Examina el efecto de dos variables independientes sobre la variable dependiente, y sus interacciones.

```
Df Sum Sq Mean Sq F value Pr(>F)
ESTRATO      5  46467    9293   117.9 <2e-16 ***
Residuals  2494 196594       79
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

4.2.4 Test Kruskal-Wallis

El test de Kruskal-Wallis es una prueba no paramétrica utilizada para comparar las medianas de tres o más grupos independientes. Es una alternativa al ANOVA cuando los supuestos de normalidad no se cumplen.

Ideal para datos ordinales o cuando la variable numérica no sigue una distribución normal.

Kruskal-Wallis rank sum test

```
data: INGLES_PUNT by ESTRATO
Kruskal-Wallis chi-squared = 259.95, df = 5, p-value < 2.2e-16
```

4.3 Asociación categórica - categórica

En ocasiones es necesario encontrar relaciones entre variables categóricas.

4.3.1 Tablas de contingencia

Tablas que muestran la frecuencia de las combinaciones de dos variables categóricas. Permiten observar la relación entre las variables categóricas.

Ayudan a visualizar y analizar la dependencia entre variables categóricas.



4.3.2 Prueba de chi cuadrado

Prueba estadística que evalúa si existe una asociación significativa entre dos variables categóricas. Compara las frecuencias observadas en la tabla de contingencia con las frecuencias esperadas bajo la hipótesis nula de independencia.

Determina si hay una relación significativa entre las variables categóricas.

```
Pearson's Chi-squared test
```

```
data: tb_example$COLE_INST_JORNADA and tb_example$ESTRATO
X-squared = 175.55, df = 20, p-value < 2.2e-16
```

4.3.3 Prueba exacta de Fisher

Prueba estadística utilizada para determinar la asociación entre dos variables categóricas en tablas de contingencia de 2x2, especialmente cuando las frecuencias esperadas son pequeñas.

Proporciona una alternativa más precisa a la prueba de chi cuadrado cuando los tamaños de muestra son pequeños.

```
Fisher's Exact Test for Count Data with simulated p-value (based on
2000 replicates)
```

```
data: tb_example$COLE_INST_JORNADA and tb_example$ESTRATO
p-value = 0.0004998
alternative hypothesis: two.sided
```

5 Distribuciones

La estadística, en su concepción más elevada como lenguaje epistemológico, surge históricamente de la búsqueda humana por imponer orden en el caos de los fenómenos observables. Desde la antigüedad, la identificación de patrones y regularidades observables en la naturaleza y en los eventos cotidianos ha sido fundamental, siendo esta práctica adoptada por las civilizaciones para fines administrativos y, posteriormente, en la base de la teoría estadística moderna, como ocurrió con el descubrimiento de regularidades en los juegos de azar practicados en Grecia y Roma. Estos patrones, una vez identificados, han sido utilizados por el ser humano en búsqueda de su comodidad y para la construcción de conocimiento científico.

No obstante, la naturaleza del conocimiento varía profundamente según la disciplina. Mientras que las ciencias exactas, como la física o la astronomía, históricamente han prosperado mediante la medición de fenómenos celestes con el objetivo de obtener mediciones estáticas de gran precisión y poca incertidumbre, el ámbito de las ciencias sociales presenta una realidad opuesta. Aquí, las unidades de análisis (los individuos) generan comportamientos globales o tendencias que son probabilísticas, lo que exige un enfoque distinto al que se basaba en la deducción estricta. La variabilidad, la subjetividad en la medición y la complejidad de las interacciones sociales imponen una alta incertidumbre, por lo que el análisis de datos en este campo se enfoca en gestionar esa varianza y el error estadístico inherente.

Es por esta razón que la representación de la realidad social no puede depender de afirmaciones determinísticas, sino que muchas de las variables sociales, tales como indicadores de salud, economía o fenómenos demográficos, presentan un desarrollo en densidades de probabilidad o distribuciones. Este marco probabilístico, que se sustenta en la formalización de conceptos como el p -valor y la distribución normal, se convierte en el modelo matemático que mejor se ajusta a estas realidades, permitiendo a los investigadores de las ciencias sociales transformar fenómenos observables en explicaciones cuantitativas y realizar inferencias que, aunque no garantizan la certeza absoluta, son rigurosas y se basan en evidencia empírica.

6 Visualización

Iniciamos el tema de visualización de datos con una lectura refrescante: [Gráficas para la ciencia y ciencia para las gráficas](#)

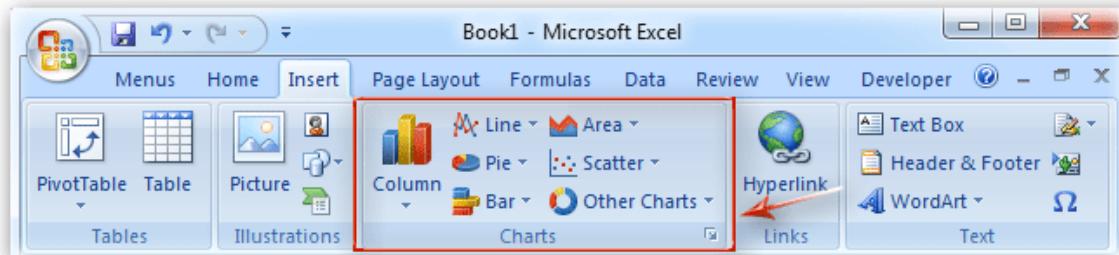
6.1 ¿Por qué visualización?

- [El cuarteto de Anscombe](#)
- [Seeing theory](#)

6.2 Veamos ejemplos

- [Information is beautiful](#)
- [gapminder](#)
- [shiny:](#)
- [plotly](#)
- [Beter Life Index OECD](#)
- [Top 10 Countries by Inflation Rate \(1980-2018\)](#)

6.3 Gráficos tradicionales



6.4 Escala de Cleveland y McGill



6.5 Buenas prácticas de visualización

Buenas prácticas de la visualización - Víctor Pascual

6.6 Gráficos

Los gráficos más comunes utilizados en datos son los siguientes.

1. **Gráfico de barras:** útil para comparar categorías. Variación: **gráfico de lollipop**, donde se usan puntos conectados por líneas en lugar de barras.
2. **Gráfico de torta (pastel):** muestra proporciones. Variación: **gráfico de dona**, que es similar pero con un espacio vacío en el centro.
3. **Histograma:** representa la distribución de frecuencias de una variable cuantitativa. Variación: **gráfico de densidad**, que suaviza las frecuencias en una curva continua para mostrar la distribución de los datos.
4. **Gráfico de dispersión:** muestra la relación entre dos variables cuantitativas. Variación: **gráfico de jitter**, que separa los puntos amontonados para revelar la densidad de los datos.

5. **Boxplot (diagrama de caja y bigotes)**: resume la distribución de una variable. Variación: **gráfico de violín**, que añade una visualización de la densidad en ambos lados del gráfico.
6. **Gráfico de líneas**: útil para visualizar tendencias a lo largo del tiempo. Variación: **gráfico de áreas**, donde el área bajo la línea está sombreada, destacando la magnitud.
7. **Mapa de calor (heatmap)**: visualiza patrones de datos a través de variaciones de color. Variación: **clustered heatmap**, que agrupa los datos por similitud, facilitando la interpretación de patrones.
8. **Gráfico de burbujas**: similar al gráfico de dispersión, pero con el tamaño de las burbujas que representa una tercera variable.
9. **Gráfico de radar (o de araña)**: muestra múltiples variables radiales. Variación: **gráfico de radar de área**, que sombra el área debajo de los valores para enfatizar la comparación entre categorías.

Part II

Estadística inferencial

Contenido

En esta primera sección se examina la estadística descriptiva. El contenido ha sido seleccionado cuidadosamente con el fin de agregar valor a los análisis cuantitativos que se proponen al interior de las investigaciones en ciencias sociales.

Preliminares

Este primer tema introduce a los estudiantes en los conceptos básicos de la estadística inferencial..

Muestreo

Estimación

Puntual y por intervalo

Tamaño muestral

Pruebas de hipótesis

Paramétricas analíticas

No paramétricas analíticas

Paramétricas computacionales

No paramétricas computacionales

7 Inferencia estadística

Para comprender cómo surgió la inferencia estadística y en qué se fundamenta, es necesario entender primero las bases epistemológicas de la ciencia. Los métodos que hoy empleamos en estadística, especialmente en inferencia, tienen raíces profundas en la filosofía clásica y el desarrollo del método científico. A través de la deducción, la inducción y otras formas de razonamiento, los científicos han perfeccionado métodos para obtener conocimientos que sean precisos y replicables.

7.1 Los antiguos griegos y la deducción

7.1.1 Sócrates y la mayéutica

Sócrates fue uno de los primeros filósofos en enfatizar la importancia del cuestionamiento como herramienta para alcanzar la verdad. Su método, la **mayéutica**, consistía en formular preguntas para ayudar a su interlocutor a descubrir conocimientos por sí mismo, partiendo de sus propias creencias y explorando las inconsistencias en sus respuestas. A través del diálogo y la introspección, Sócrates buscaba llevar a los demás hacia una mejor comprensión de conceptos abstractos como la justicia, la verdad y el bien. Esta metodología sentó las bases para el pensamiento crítico, un pilar fundamental en la ciencia moderna.

7.1.2 Platón y la dialéctica

Platón, discípulo de Sócrates, amplió la mayéutica y formuló la **dialéctica** como un método para alcanzar conocimientos más profundos mediante la confrontación de ideas opuestas. A través del diálogo y la tensión entre las tesis y antítesis, Platón creía que se podía llegar a la síntesis, es decir, a una comprensión superior y más completa de la realidad. Este método dialéctico influyó en el desarrollo de sistemas de lógica y pensamiento analítico que aún sustentan la base epistemológica de la ciencia.

7.1.3 Aristóteles y la lógica

Aristóteles sistematizó la lógica como un método de razonamiento para llegar a conclusiones válidas a partir de premisas establecidas. En sus obras, como el **Organon**, formalizó el uso de la lógica deductiva y desarrolló una metodología para analizar y entender los principios subyacentes de los fenómenos. La lógica aristotélica no solo sentó las bases para el razonamiento científico, sino que también proporcionó las herramientas para la creación de sistemas de clasificación y el desarrollo de conceptos abstractos en la ciencia y las matemáticas.

7.1.4 El silogismo

Uno de los aportes más significativos de Aristóteles a la epistemología es el **silogismo**, una forma de razonamiento deductivo que permite derivar conclusiones a partir de dos o más premisas. El silogismo establece que si las premisas son verdaderas, la conclusión necesariamente debe serlo. Este tipo de razonamiento deductivo es un modelo de inferencia lógica que ha servido de base para el desarrollo de sistemas matemáticos y estadísticos. Un ejemplo clásico sería:

- Todos los hombres son mortales.
- Sócrates es un hombre.
- Por lo tanto, Sócrates es mortal.

Un ejemplo del uso del mecanismo deductivo es el segundo libro más editado de la historia, *Los Elementos* de Euclides, que organiza el conocimiento geométrico mediante un sistema axiomático. En este texto, Euclides parte de unos pocos postulados y axiomas fundamentales, a partir de los cuales deduce rigurosamente una serie de teoremas y proposiciones. Este enfoque deductivo no solo demostró la efectividad de la lógica en las matemáticas, sino que también influyó profundamente en la metodología científica, sirviendo de modelo para estructurar el conocimiento de manera lógica y coherente.

Otros ejemplos son *Ética demostrada según el orden geométrico* de Spinoza y *Philosophiæ Naturalis Principia Mathematica* de Isaac Newton. En *Ética*, Spinoza estructura su filosofía siguiendo el estilo geométrico de Euclides, utilizando definiciones, axiomas y proposiciones para desarrollar sus ideas sobre la naturaleza de Dios, la mente y la moralidad. Por su parte, en *Principia Mathematica*, Newton aplica un razonamiento deductivo para establecer las leyes del movimiento y la gravitación universal, partiendo de principios fundamentales y llegando a conclusiones que explican fenómenos físicos observables. Estos textos muestran cómo el método deductivo ha sido un pilar para avanzar en diversas disciplinas, desde la filosofía hasta la física.

7.2 El *Novum Organum* de Bacon

7.2.1 La deducción contra la inducción

En el siglo XVII, Francis Bacon introdujo un enfoque revolucionario en su obra *Novum Organum*, en la que defendía la **inducción** como método para el conocimiento científico. Este enfoque rompió con la tradición aristotélica de deducción estricta, proponiendo que, en lugar de solo partir de premisas generales, los científicos deberían observar y analizar los fenómenos específicos para, a partir de ellos, generalizar leyes y principios.

- **La deducción:** es un proceso de razonamiento que va de lo general a lo particular. Parte de leyes o teorías ya establecidas y aplica esas premisas para llegar a conclusiones específicas. La deducción asegura conclusiones válidas si las premisas son verdaderas, pero no permite descubrir nuevas leyes o principios.
- **La inducción:** es el proceso de observación de casos particulares para generar conclusiones generales o teorías. En la inducción, el conocimiento se construye a partir de patrones observados en la realidad, permitiendo la creación de nuevas hipótesis y teorías. Sin embargo, este método no garantiza la certeza absoluta de sus conclusiones, ya que estas son probabilísticas y dependen de la representatividad de los datos.

El trabajo de Bacon es fundamental porque sentó las bases para una ciencia basada en la observación empírica, un enfoque que siglos más tarde sería crucial en la inferencia estadística.

7.2.2 Actividad: ¿Qué es un cisne negro?

El concepto de “cisne negro” se refiere a eventos altamente improbables e impredecibles, pero con un gran impacto cuando ocurren. La expresión fue popularizada por el filósofo Nassim Nicholas Taleb y subraya la limitación de los métodos inductivos, ya que una amplia observación de cisnes blancos no garantiza que no existan cisnes negros. Este concepto es clave para entender los límites de la inferencia estadística y la probabilidad, pues resalta la posibilidad de eventos fuera de nuestras expectativas basadas en observaciones pasadas.

7.3 Fisher, Neyman, Pearson

7.3.1 Las reglas para hacer inducción

Ronald A. Fisher, Jerzy Neyman y Egon Pearson fueron fundamentales para estructurar las **reglas para hacer inducción** en el contexto de la estadística moderna. Su trabajo permitió la formalización de métodos inferenciales que ayudan a generalizar conclusiones a partir de muestras. Estas reglas establecen la estructura de las pruebas de hipótesis y la generación de

intervalos de confianza, permitiendo a los científicos tomar decisiones con base en evidencia empírica.

Fisher, Neyman y Pearson desarrollaron metodologías para derivar conocimiento a partir de datos de manera rigurosa, incorporando conceptos como la probabilidad y el error estadístico. A través de la estadística inferencial, lograron definir un proceso sistemático para probar hipótesis, medir la incertidumbre y proporcionar intervalos de confianza, contribuyendo significativamente a las ciencias experimentales y sociales.

7.3.2 Inferencia estadística

La inferencia estadística surgió en el siglo XX como una disciplina clave en la estadística, impulsada por la necesidad de tomar decisiones informadas a partir de datos. Su desarrollo fue influenciado por figuras como Ronald A. Fisher, Jerzy Neyman y Egon Pearson, quienes sentaron las bases de los métodos inferenciales que permiten generalizar conclusiones de una muestra a una población más amplia. Fisher introdujo conceptos fundamentales como el “p-valor” y la prueba de hipótesis, mientras que Neyman y Pearson formalizaron la teoría de pruebas con su trabajo sobre errores tipo I y II y la formulación de intervalos de confianza. La inferencia estadística se consolidó rápidamente en diversas áreas científicas, desde la biología y la medicina hasta las ciencias sociales y económicas, transformando la manera en que los investigadores validan teorías y estiman parámetros poblacionales. A lo largo del tiempo, esta área ha evolucionado, incorporando herramientas computacionales y métodos bayesianos que amplían las posibilidades de análisis en contextos de datos complejos y grandes volúmenes de información.

8 Muestreo

¿Qué hacemos para probar la sopa? Revolvemos la olla con una cuchara, sacamos una porción -una muestra- la saboreamos y sacamos una conclusión sobre toda la sopa de la olla sin haber en realidad probado toda. Si la muestra ha sido tomada adecuadamente - sin elegir trámosamente la parte buena - tendremos una buena idea del sabor de la totalidad de la sopa. Esto se hace en estadística, más específicamente en inferencia estadística.

Los investigadores quieren averiguar algo sobre una población, pero no tienen tiempo o dinero para estudiar a todos los individuos que la conforman. Por lo tanto, ¿qué hacen? Seleccionan una cantidad pequeña de unidades muestrales de la población (esto se llama una muestra), estudian esas unidades, generalmente individuos, y utilizan esa información para sacar conclusiones sobre toda de la población.

8.1 Contexto del muestreo

8.1.1 Tendencias

El análisis de datos no genera afirmaciones individuales. Se identifican comportamientos globales en torno a un fenómeno, que no corresponden al comportamiento de los individuos de manera puntual. Las tendencias son comportamientos globales, que los individuos acatan probablemente.

8.1.2 Individuos

Son unidades de análisis sobre las cuales vamos a generar un modelo. Son el sujeto de nuestra teoría.

8.1.3 Población

Para cualquier pregunta que interese responder, primero es necesario dirigir la atención a un grupo particular de individuos: personas, ciudades, animales, televisores, discos rígidos, tornillos o lamparitas.

8.1.4 Muestra

Es un subconjunto de la población.

8.1.5 Representatividad

Una muestra es representativa de la población cuando todas las características importantes de la población tienen que estar en la muestra en la misma proporción que en la población.

8.2 Conceptos de muestreo

- Marco
- Diseño
- Error
- Tamaño

8.2.1 Marco muestral

El marco muestral es el conjunto de todos los elementos o unidades de la población que son accesibles para ser seleccionados en la muestra.

Este marco debe ser representativo de (preferiblemente contener toda) la población objetivo para garantizar la validez de los resultados. Un marco muestral bien definido es crucial para evitar sesgos en la selección de la muestra.

8.2.2 Diseño muestral

El diseño muestral es el plan que describe cómo se selecciona la muestra a partir del marco muestral. Puede incluir diferentes técnicas de muestreo, como el muestreo aleatorio simple, el muestreo estratificado, el muestreo por conglomerados, entre otros.

La elección del diseño depende de los objetivos del estudio, las características de la población y los recursos disponibles.

Es el diseño muestral lo que le da representatividad a la muestra.

8.2.3 Error muestral

El error muestral es la diferencia entre el valor estimado a partir de la muestra y el valor real en la población. Este error surge debido a que la muestra es solo una parte de la población y no refleja completamente su variabilidad.

El tamaño de la muestra, el diseño muestral y el método de estimación influyen en la magnitud del error muestral.

8.2.4 Tamaño muestral

El tamaño muestral es la cantidad de unidades que se seleccionarán del marco muestral para ser incluidas en el estudio. Un tamaño muestral adecuado es fundamental para asegurar la precisión y confiabilidad de los resultados.

La determinación del tamaño muestral depende del nivel de confianza deseado, el margen de error aceptable y la variabilidad esperada en la población.

Es el tamaño muestral lo que le da significancia a las estimaciones. No hay muestras significativas.

8.3 Distintos abordajes del muestreo

8.3.1 Muestreo no probabilístico

No todos los elementos tienen probabilidad de ser seleccionados

- La muestra no es representativa (rigurosamente)
- No es posible calcular el error muestral
- Requiere menos recursos

8.3.2 Muestreo probabilístico

Todos los individuos en la población tienen una probabilidad específica de ser seleccionados para la muestra.

8.4 Muestreo no probabilístico

- Por cuotas
- Bola de nieve
- Discrecional
- Conveniencia
- Accidental

8.4.1 Muestreo por cuotas

Consiste en dividir la población en segmentos y obtener una cuota de cada segmento.

Se utiliza cuando se tienen segmentos relevantes pero no se tiene acceso al marco muestral.

En un estudio sobre preferencias de compra de automóviles, se decide utilizar el muestreo por cuotas para asegurar que la muestra sea representativa en términos de género y edad. El investigador establece cuotas basadas en la distribución de la población:

- **Género:** 50% hombres, 50% mujeres.
- **Edad:** 25% de 18-29 años, 25% de 30-39 años, 25% de 40-49 años, 25% de 50 años o más.

El investigador luego selecciona participantes hasta que se cumplan las cuotas establecidas, por ejemplo, 100 hombres y 100 mujeres, distribuidos equitativamente entre los diferentes grupos de edad. Este método asegura que todas las categorías importantes estén adecuadamente representadas en la muestra.

8.4.2 Bola de nieve

Cada individuo refiere nuevos individuos.

Se utiliza con poblaciones sensibles.

En un estudio sobre los hábitos de ahorro entre migrantes de un país específico, se utiliza el muestreo bola de nieve debido a la dificultad de acceder a esta población. El investigador comienza con un pequeño grupo de migrantes conocidos que participan en el estudio. Luego, estos participantes refieren a otros migrantes que también podrían estar interesados en participar.

A medida que más personas son entrevistadas, se continúa pidiendo referencias, lo que permite que la muestra “crezca como una bola de nieve”. Este método es especialmente útil para poblaciones difíciles de alcanzar o cuando no existe un marco muestral claro.

8.4.3 Muestreo discrecional

Consiste en tomar de la población los individuos que resulten representativos bajo el juicio de un experto.

Se utiliza cuando hay un experto que ha realizado estudios previos.

En un estudio exploratorio sobre las opiniones de expertos en inteligencia artificial, se decide utilizar el muestreo discrecional. El investigador selecciona intencionadamente a un grupo de 10 expertos reconocidos en el campo, basándose en su conocimiento y reputación en la industria. La selección no es aleatoria, sino que se realiza según el criterio del investigador, quien elige a estos expertos por considerarlos los más apropiados para proporcionar información valiosa y relevante para el estudio.

8.4.4 Muestreo por conveniencia

Consiste en estudiar los individuos más cercanos o voluntarios, ya que estos son más accesibles.

Se utiliza en estudios cuyas poblaciones no son accesibles.

En un estudio piloto sobre las preferencias de snacks saludables entre estudiantes universitarios, el investigador utiliza el muestreo por conveniencia debido a limitaciones de tiempo y recursos.

El investigador selecciona a los estudiantes del curso de muestreo para que respondan a una breve encuesta. Este método se elige porque los participantes son fácilmente accesibles, aunque no necesariamente representan a toda la población estudiantil.

8.4.5 Muestreo accidental

Se selecciona un mecanismo de selección o acceso a los individuos encontrándolos por casualidad en un espacio definido sin ningún juicio previo.

Se utiliza en poblaciones particularmente grandes con fines descriptivos y prácticos.

En un estudio sobre las tendencias de la moda un investigador utiliza el muestreo accidental. Se aborda a los primeros 30 clientes que ingresan en una tienda de ropa durante una mañana para que respondan a una encuesta de satisfacción.

Este método es accidental porque se seleccionan a los participantes en el lugar y momento de recolección.

8.5 Muestreo probabilístico

- Aleatorio simple
- Por etapas
- Por conglomerados
- Por estratos

8.5.1 Muestreo aleatorio simple

- Definir la población
- Obtener el marco muestral
- Definir un tamaño muestral n
- Elegir aleatoriamente n individuos de la población

En un estudio sobre los hábitos de lectura de la población adulta en una ciudad, se decide utilizar el muestreo aleatorio simple. A partir de un listado completo de los 10,000 residentes adultos de la ciudad, el investigador selecciona 500 personas utilizando un generador de números aleatorios.

Cada individuo tiene la misma probabilidad de ser seleccionado, lo que asegura que la muestra sea representativa de toda la población, minimizando sesgos en la selección.

8.5.2 Muestreo por etapas

- Bietápico (2 etapas)
- Polietápico (3 etapas o más)
- Es necesario calcular tamaño muestral en cada etapa

En un estudio nacional sobre el nivel educativo en zonas rurales, se utiliza el muestreo por etapas para facilitar la selección de la muestra.

1. **Primera etapa:** Se seleccionan al azar 10 estados de un total de 32 en el país.
2. **Segunda etapa:** Dentro de cada estado seleccionado, se eligen aleatoriamente 3 municipios rurales.
3. **Tercera etapa:** En cada municipio, se seleccionan aleatoriamente 5 escuelas primarias.
4. **Cuarta etapa:** Dentro de cada escuela seleccionada, se eligen al azar 30 estudiantes para participar en el estudio.

Este método permite una selección eficiente y representativa en poblaciones grandes y dispersas, utilizando un enfoque jerárquico y secuencial.

8.5.3 Muestreo por conglomerados

- Son heterogéneos en su interior.
- Son homogéneos entre sí
- Se selecciona una muestra primaria
- Se selecciona una muestra secundaria
- Ejemplo: ciudades, salones, centros comerciales

En un estudio sobre el impacto de programas educativos en escuelas primarias, se utiliza el muestreo por conglomerados para simplificar el proceso de recolección de datos.

1. **Primera etapa:** Se seleccionan al azar 20 escuelas primarias de un listado completo de 200 en una región determinada.
2. **Segunda etapa:** Dentro de cada escuela seleccionada, se eligen al azar 3 clases para participar en el estudio.
3. **Tercera etapa:** Se recopilan datos de todos los estudiantes de las clases seleccionadas.

Este método es útil cuando la población está agrupada en unidades naturales, como escuelas o barrios, y facilita la logística y los costos al reducir el número de unidades primarias que se deben tratar.

8.5.4 Muestreo estratificado

- Son homogéneos en su interior
- Son heterogéneos entre sí
- Se selecciona una censo primario
- Se selecciona una muestra secundaria

En un estudio sobre la satisfacción laboral en una empresa multinacional, se utiliza el muestreo estratificado para asegurar que todas las divisiones y niveles jerárquicos de la empresa estén representados.

1. **Primera etapa:** Se divide a los empleados en diferentes estratos según su departamento (por ejemplo, Finanzas, Recursos Humanos, Marketing, etc.).
2. **Segunda etapa:** Se selecciona una muestra aleatoria de empleados de cada estrato para participar en la encuesta de satisfacción.

Este método garantiza que cada subgrupo relevante dentro de la población esté representado en la muestra, permitiendo comparaciones más precisas entre diferentes departamentos y niveles jerárquicos.

8.5.5 Técnicas de muestreo

Técnicas de muestreo

8.5.6 Factores de expansión

Cuando tenemos un diseño muestral, es posible saber cuántos individuos de la población son representados por un individuo de la muestra. Esta cantidad se denomina *Factores de expansión*.

Los factores de expansión son particularmente útiles para calcular totales.

8.5.7 Actividad

En esta actividad vamos a analizar una encuesta.

1. Elija una encuesta de la lista.
2. Escudriñe la documentación. Busque el muestreo.
3. Lea el muestreo cuidadosamente.
4. Escriba cómo imagina los detalles de la ejecución: Obtención del marco muestral

Encuestas

- [Encuesta Nacional de Demografía y Salud \(ENDS\)/Ministerio de Salud y Protección Social](#)
- [Encuesta TIC Hogares](#)
- [Índice de brecha Digital](#)
- [Encuesta Nacional Agropecuaria](#)
- [Encuesta Multipropósito](#)

9 Estimación

9.1 Conceptos iniciales

Iniciamos por los conceptos que son fundamentales para entender la estimación en inferencia estadística. Estos conceptos ayudan a diferenciar entre la población y la muestra, así como a identificar las características numéricas que se desea estimar.

9.1.1 Parámetro

Un **parámetro** es un valor numérico que describe una característica específica de una población completa. Ejemplos incluyen la media poblacional (μ), la varianza poblacional (σ^2) o la proporción poblacional (P). Dado que los parámetros se refieren a poblaciones enteras, son constantes, pero, en la práctica, generalmente son desconocidos. Por lo tanto, se necesita recurrir a métodos estadísticos para estimarlos a partir de muestras.

9.1.2 Estimador

Un **estimador** es una regla o fórmula utilizada para aproximar un parámetro poblacional a partir de los datos muestrales. Un estimador es una variable aleatoria y , por lo tanto, puede variar de una muestra a otra. Los estimadores se utilizan para hacer inferencias sobre la población, y algunos ejemplos comunes incluyen la media muestral \bar{x} y la proporción muestral \hat{p} . La calidad de un estimador se evalúa en función de sus propiedades, como la consistencia y la unbiasedness (inexistencia de sesgo).

9.1.3 Muestra

Una **muestra** es un subconjunto de elementos extraídos de una población. La muestra se utiliza para realizar estimaciones sobre la población completa sin necesidad de medir a todos sus miembros. El tamaño y la calidad de la muestra son fundamentales para asegurar que las inferencias realizadas sean precisas y representativas. Una muestra puede ser aleatoria, estratificada o por conveniencia, dependiendo del método utilizado para su selección.

9.1.4 Población

La **población** se refiere al conjunto completo de individuos, elementos o unidades que comparten una característica particular que se está estudiando. Por ejemplo, si estamos interesados en el ingreso anual de todos los empleados de una empresa, la población sería todos los empleados. En la inferencia estadística, es crucial definir claramente la población para poder aplicar métodos de muestreo adecuados y realizar estimaciones precisas.

9.2 Estimación puntual

La **estimación puntual** se refiere al uso de un solo valor, calculado a partir de la muestra, para estimar un parámetro desconocido de la población. Este enfoque proporciona una respuesta única a la pregunta de interés, pero no informa sobre la precisión de la estimación. Por ejemplo, la media muestral \bar{x} es una estimación puntual de la media poblacional ().

- **Media muestral:** Se toma una muestra de los ingresos anuales de 100 empleados de una empresa. La media de estos ingresos en la muestra es de \$50,000. Este valor se utiliza como una **estimación puntual** de la media de los ingresos de toda la población de empleados.
- **Proporción muestral:** En una encuesta realizada a 500 personas, 320 afirman que prefieren trabajar desde casa. La proporción muestral es $\hat{p} = \frac{320}{500} = 0.64$, lo cual es una **estimación puntual** de la proporción real de personas que prefieren el trabajo remoto en la población general.
- **Varianza muestral:** Una muestra de 50 estudiantes tiene una varianza de puntajes en un examen de 16 puntos cuadrados. Este valor se utiliza como una **estimación puntual** de la varianza de los puntajes en la población completa de estudiantes.

9.2.1 Estimadores y parámetros

Los estimadores son utilizados para estimar parámetros poblacionales. Algunos ejemplos incluyen:

- **Media muestral \bar{x}** para estimar la media poblacional ().
- **Varianza muestral s^2** para estimar la varianza poblacional (2).
- **Proporción muestral \hat{p}** para estimar la proporción poblacional (P).
- **Correlación de Pearson $\hat{\rho}$** para estimar la correlación poblacional ρ .

9.2.2 Aplicación interactiva

Para ilustrar la idea de estimación puntual, podemos estimar el número utilizando simulaciones. Aquí tienes un recurso que permite interactuar con este concepto:

[Estimación puntual](#)

9.2.3 Ley de los Grandes Números

La **Ley de los Grandes Números** es un principio fundamental en la teoría de la probabilidad que establece que, a medida que aumenta el tamaño de una muestra, la media muestral \bar{x} se acercará a la media poblacional (μ) de la población de la que se extrajo la muestra. Esta ley se basa en la idea de que las fluctuaciones aleatorias tienden a cancelarse entre sí en muestras más grandes, lo que resulta en una estimación más precisa del parámetro poblacional.

Existen dos versiones de la Ley de los Grandes Números:

1. **Ley débil de los grandes números:** Establece que, para cualquier valor positivo, la probabilidad de que la media muestral se desvíe de la media poblacional en más de ϵ tiende a cero a medida que el tamaño de la muestra (n) aumenta. Es decir, la media muestral se convierte en un estimador consistente de la media poblacional.
2. **Ley fuerte de los grandes números:** Afirmación más fuerte que la versión débil, establece que la media muestral converge casi seguramente a la media poblacional a medida que n tiende al infinito. Esto significa que, con una probabilidad de 1, la media muestral se aproximará a la media poblacional a medida que se tomen más y más muestras.

La Ley de los Grandes Números es fundamental en estadística y asegura que los resultados obtenidos de las muestras se volverán más representativos de la población a medida que se aumente el tamaño de la muestra, lo que permite realizar inferencias más confiables sobre la población completa.

9.2.4 Consistencia

Un **estimador puntual** es **consistente** si, a medida que el tamaño de la muestra aumenta, la estimación se aproxima cada vez más al verdadero parámetro poblacional. En otras palabras, un estimador consistente converge en probabilidad al parámetro que se está estimando. Esta propiedad es crucial porque asegura que con muestras más grandes, nuestras estimaciones se vuelven más precisas y confiables, reduciendo la variabilidad y el error de estimación.

9.3 Estimación por intervalo

La **estimación por intervalo** proporciona un rango de valores dentro del cual se espera que se encuentre el parámetro poblacional con un cierto nivel de confianza. A diferencia de una estimación puntual, que ofrece un único valor, el intervalo de confianza incluye una medida de la incertidumbre asociada con la estimación. Esto permite a los investigadores entender no solo qué valor se estima, sino también la precisión y confiabilidad de dicha estimación.

9.3.1 Precisión y Exactitud

Precisión y **exactitud** son dos conceptos fundamentales en la estadística y la investigación que se utilizan para evaluar la calidad de las estimaciones y mediciones. Aunque a menudo se utilizan de manera intercambiable en el lenguaje cotidiano, tienen significados distintos en el contexto estadístico.

9.4 Ejemplo: animales de granja



(a) Animales de granja, representación imprecisa.



(a) Animales de granja, representación inexacta.

9.4.1 Precisión

La **precisión** se refiere a la consistencia y reproducibilidad de las mediciones. Un conjunto de datos es preciso si las mediciones son cercanas entre sí, independientemente de si son correctas o no. En otras palabras, la precisión indica cuán dispersos están los valores en relación con la media. Un alto grado de precisión significa que las mediciones tienden a agruparse en torno a un valor central.

- **Ejemplo de Precisión:** Los diseñadores de máquinas dan las medidas en milímetros. Esto da una mayor precisión a los componentes.

9.4.2 Exactitud

La **exactitud**, por otro lado, se refiere a cuán cerca está una medición del valor verdadero o del objetivo. Una medición es exacta si se aproxima al valor real. En este caso, la exactitud evalúa la validez de los datos en relación con la realidad.

- **Ejemplo de Exactitud:** Los abogados necesitan establecer los hechos verídicos en sus procesos. Incluso si no se tienen detalles, deben ser verificables.

9.4.3 Diferencias entre Precisión y Exactitud

Concepto	Definición	Enfoque	Ejemplo
Precisión	Consistencia y reproducibilidad de mediciones	Distribución de datos	Mediciones: 10.1, 10.0, 10.2 (altamente precisas pero no exactas si el valor verdadero es 11.0)
Exactitud	Cercanía de las mediciones al valor verdadero	Proximidad al valor verdadero	Mediciones: 11.0, 11.1, 11.2 (altamente exactas si el valor verdadero es 11.0, aunque pueden no ser precisas si los valores no son consistentes)

La precisión y exactitud son cruciales en la estadística y en el diseño de investigaciones. Una alta precisión en los resultados es deseable, pero no es suficiente por sí sola. Si los datos son precisos pero no exactos, las conclusiones extraídas pueden ser engañosas y llevar a decisiones erróneas.

1. **Diseño de Estudios:** Durante el diseño de estudios, los investigadores deben asegurarse de que las herramientas de medición sean tanto precisas como exactas para obtener datos confiables.

2. **Interpretación de Resultados:** La evaluación de la precisión y exactitud de los datos ayuda a los investigadores a entender la confiabilidad de sus estimaciones y a interpretar correctamente los resultados.
3. **Mejora de Métodos:** Comprender la diferencia entre estos conceptos permite a los investigadores identificar áreas de mejora en sus métodos de recopilación de datos, ajustando su enfoque para aumentar tanto la precisión como la exactitud.

Los conceptos de precisión y exactitud están intrínsecamente relacionados con los intervalos de confianza, ya que estos intervalos son una herramienta estadística diseñada para expresar la incertidumbre en torno a una estimación puntual. Un intervalo de confianza proporciona un rango de valores dentro del cual se espera que se encuentre el parámetro poblacional verdadero, lo que refleja la **exactitud** de la estimación. Si el intervalo es estrecho, indica una alta precisión en las mediciones, lo que sugiere que repetidas mediciones generarían resultados consistentes. Sin embargo, si el intervalo de confianza incluye valores muy alejados del verdadero parámetro, sugiere que la estimación puede no ser precisa. Por lo tanto, un intervalo de confianza bien construido no solo comunica la variabilidad de los datos, sino que también integra las nociones de precisión y exactitud en la evaluación de la validez de los resultados estadísticos.

9.4.4 Construcción de los intervalos de confianza

La construcción de intervalos de confianza puede realizarse de dos maneras:

1. **Método analítico:** Utiliza fórmulas y propiedades matemáticas para calcular los intervalos de confianza. Este método es eficiente cuando se cumplen las condiciones necesarias, como la normalidad de los datos.
2. **Método computacional:** Utiliza técnicas de remuestreo, como el bootstrapping, para estimar la distribución del estimador y generar intervalos de confianza sin necesidad de asumir una distribución específica.

9.4.4.1 Ventajas y desventajas de la construcción analítica

La construcción analítica de los intervalos de confianza presenta pros y contras

- **Ventajas:** - Menor costo computacional, ya que implica cálculos directos a partir de los datos. - Resultados más rápidos si se cumplen los supuestos de normalidad.
- **Desventajas:** - Dependencia de supuestos que pueden no cumplirse en datos reales. - Puede no ser adecuado para distribuciones no estándar o en situaciones de muestras pequeñas.

9.4.4.2 Ventajas y desventajas de la construcción computacional

La construcción computacional de los intervalos de confianza presenta pros y contras

- **Ventajas:** - Flexible, ya que no depende de supuestos sobre la distribución de los datos.
- Adecuado para cualquier tipo de muestra y variabilidad en los datos.
- **Desventajas:** - Puede ser intensivo en recursos computacionales, especialmente para grandes volúmenes de datos. - Mayor tiempo de procesamiento y necesidad de software especializado.

9.5 Intervalos de confianza analíticos

A continuación se examinan algunas fórmulas de ...

9.5.1 Intervalo de confianza para la media

Para calcular un intervalo de confianza para la media de una población, se puede utilizar la distribución t de Student o la distribución normal, dependiendo del tamaño de la muestra y de si se conoce la varianza poblacional.

- **Ejemplo:** Supongamos que un investigador quiere estimar la media de la altura de los estudiantes de una universidad. Toma una muestra aleatoria de 30 estudiantes y calcula que la media muestral es de 1.70 metros con una desviación estándar de 0.10 metros. Dado que el tamaño de la muestra es pequeño, se utiliza la distribución t de Student. Si se quiere un nivel de confianza del 95%, el intervalo de confianza se calcula de la siguiente manera:

$$IC = \bar{x} \pm t_{\alpha/2} \left(\frac{s}{\sqrt{n}} \right)$$

Donde $t_{\alpha/2}$ es el valor crítico de t correspondiente al nivel de confianza del 95% y 29 grados de libertad ($n-1$), (s) es la desviación estándar muestral y (n) es el tamaño de la muestra. Supongamos que $t_{0.025} \approx 2.045$ para este caso:

$$IC = 1.70 \pm 2.045 \left(\frac{0.10}{\sqrt{30}} \right) \approx 1.70 \pm 0.374$$

El intervalo de confianza sería aproximadamente (1.63, 1.77). Esto significa que el investigador puede estar 95% seguro de que la media de altura de todos los estudiantes está entre 1.63 y 1.77 metros.

9.5.2 Intervalo de confianza para una proporción

El **intervalo de confianza para una proporción** se calcula utilizando la proporción muestral \hat{p} y el error estándar de la proporción. Se utiliza la distribución normal, ya que se asume que la proporción muestral sigue una distribución normal cuando el tamaño de muestra es suficientemente grande.

- **Ejemplo:** Imaginemos que en una encuesta a 500 personas, 320 afirman que prefieren trabajar desde casa. La proporción muestral es:

$$\hat{p} = \frac{320}{500} = 0.64$$

El intervalo de confianza se puede calcular de la siguiente manera:

$$IC = \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Si elegimos un nivel de confianza del 95%, $z_{0.025} \approx 1.96$:

$$IC = 0.64 \pm 1.96 \sqrt{\frac{0.64 \times (1 - 0.64)}{500}} \approx 0.64 \pm 0.045$$

Esto resulta en un intervalo de confianza de (0.595, 0.685). Por lo tanto, el investigador puede estar 95% seguro de que la proporción real de personas que prefieren trabajar desde casa en la población general está entre el 59.5% y el 68.5%.

9.5.3 Intervalo de confianza para la varianza

El **intervalo de confianza para la varianza** se calcula utilizando la distribución chi-cuadrado. La varianza muestral (s^2) es el estimador puntual, y el intervalo se ajusta de acuerdo con la distribución de esta varianza bajo el supuesto de normalidad.

- **Ejemplo:** Supongamos que un investigador mide los tiempos de espera en una fila y obtiene una varianza muestral de ($s^2 = 16$) minutos² con una muestra de 15 observaciones. Para calcular un intervalo de confianza del 95% para la varianza poblacional, se utiliza la fórmula:

$$IC = \left(\frac{(n-1)s^2}{\chi_{\alpha/2}^2}, \frac{(n-1)s^2}{\chi_{1-\alpha/2}^2} \right)$$

Donde (n) es el tamaño de la muestra y (χ^2) son los valores críticos de la distribución chi-cuadrado. Si (n=15) y con un nivel de confianza del 95%, se pueden encontrar los valores críticos:

$$IC = \left(\frac{(15-1) \times 16}{\chi_{0.025,14}^2}, \frac{(15-1) \times 16}{\chi_{0.975,14}^2} \right)$$

Si $\chi_{0.025,14}^2 \approx 27.688$ y $\chi_{0.975,14}^2 \approx 5.629$:

$$IC \approx \left(\frac{14 \times 16}{27.688}, \frac{14 \times 16}{5.629} \right) \approx (8.520, 39.658)$$

Esto significa que el investigador puede estar 95% seguro de que la varianza del tiempo de espera en la población está entre 8.520 y 39.658 minutos².

9.5.4 Aplicación interactiva

Para ilustrar la idea de estimación por intervalo, puedes utilizar simulaciones interactivas que permiten explorar estos conceptos. Aquí tienes un recurso que permite interactuar con este concepto:

[Estimación por intervalo](#)

9.5.5 Consistencia

Un **intervalo de confianza** es considerado **consistente** si, al aumentar el tamaño de la muestra, la longitud del intervalo tiende a reducirse. Esto indica que la estimación se vuelve más precisa y refleja mejor el parámetro poblacional.

9.6 Intervalos de confianza computacionales

Los métodos de simulación de bootstrapping y...

9.6.1 Bootstrapping

El **bootstrapping** es un método no paramétrico que se utiliza para estimar la distribución de un estimador y, por ende, sus intervalos de confianza. Este método genera múltiples muestras simuladas (con reemplazo) de la muestra original, permitiendo construir un intervalo de confianza sin depender de la distribución subyacente de los datos.

9.6.2 Ejemplo: Diferencia de medias

Para evaluar la **diferencia de medias** entre dos poblaciones, se construye un intervalo de confianza alrededor de la diferencia de medias muestrales. Dependiendo de si se asumen varianzas iguales o diferentes, se pueden aplicar diferentes métodos, como el uso de la distribución t de Student o el método de bootstrapping.

- **Ejemplo:** Supongamos que queremos comparar las alturas promedio de hombres y mujeres en una población. Recogemos datos de 50 hombres y 50 mujeres y encontramos que la media de los hombres es 1.80 metros y la media de las mujeres es 1.65 metros. La diferencia de medias es 0.15 metros. Aplicando el bootstrapping, podemos crear múltiples muestras de nuestras muestras originales para estimar la distribución de la diferencia de medias y, así, construir un intervalo de confianza.

9.6.3 Ejemplo: Diferencia de proporciones

El **intervalo de confianza para la diferencia de proporciones** entre dos poblaciones se construye de manera similar al de una proporción, pero utilizando la diferencia entre las proporciones muestrales. Dependiendo de si se asume o no la homogeneidad de varianzas entre las dos proporciones, se pueden aplicar diferentes métodos.

- **Ejemplo:** Si en una encuesta a 300 hombres, el 70% responde que prefiere el trabajo remoto, y en una encuesta a 250 mujeres, el 60% responde lo mismo, la diferencia de proporciones es 0.10. Para construir un intervalo de confianza, podemos aplicar el bootstrapping para simular la diferencia de proporciones y calcular el intervalo.

9.6.4 Bootstrapping ejemplo

Para explorar el método de bootstrapping, puedes interactuar con simulaciones que permiten visualizar cómo funciona este proceso en la práctica. Aquí tienes un recurso que permite interactuar con este concepto:

[Bootstrapping](#)

10 Tamaño muestral

El **tamaño muestral** es un aspecto crucial en el diseño de estudios estadísticos, ya que influye directamente en la precisión y confiabilidad de las estimaciones. Comprender cómo determinar el tamaño de muestra adecuado es fundamental para obtener resultados válidos y aplicables a una población más amplia.

10.1 Error muestral

El **margen de error** es una medida que refleja la cantidad de incertidumbre asociada a una estimación puntual. Se define como la mitad de la longitud de un intervalo de confianza y representa la variabilidad esperada en una estimación debido al muestreo. Cuanto mayor sea el margen de error, menos confiable será la estimación.

Cálculo del margen de error:

El margen de error se puede calcular utilizando la siguiente fórmula:

$$\text{Margen de error} = Z \times \left(\frac{\sigma}{\sqrt{n}} \right)$$

Donde: - Z es el valor crítico de la distribución normal estándar (por ejemplo, 1.96 para un nivel de confianza del 95%). - σ es la desviación estándar de la población (o de la muestra si la desviación estándar de la población no está disponible). - n es el tamaño de la muestra.

Ejemplo

- **Encuesta electoral:** En una encuesta a 1,000 votantes, el 48% afirma que votará por el candidato A. Si el margen de error es de $\pm 3\%$, esto indica que el porcentaje real de votantes que apoyan al candidato A se estima que está entre el 45% y el 51%. Esto se puede expresar como un intervalo de confianza de (0.45, 0.51).
- **Estimación de ingresos:** Se estima que el ingreso promedio de una población es de \$50,000 con un margen de error de $\pm \$2,000$. Esto implica que el ingreso promedio real en la población se espera que esté entre \$48,000 y \$52,000. En este caso, el margen de error nos proporciona una indicación clara de la posible variabilidad en los ingresos de la población.

10.2 Empate técnico

El **empate técnico** ocurre cuando las diferencias entre dos estimaciones puntuales, como medias o proporciones, no son estadísticamente significativas debido al margen de error. En este caso, las diferencias observadas podrían ser el resultado de la variabilidad muestral y no reflejan una verdadera diferencia en la población.

Ejemplo

- **Encuesta electoral:** En una encuesta a 1,200 votantes, el candidato A obtiene el 46% de las intenciones de voto y el candidato B el 44%, con un margen de error de $\pm 3\%$. Dado que el margen de error abarca los porcentajes de ambos candidatos (43% a 49% para A y 41% a 47% para B), se considera un empate técnico. Esto sugiere que no hay suficiente evidencia para afirmar que uno de los candidatos es preferido sobre el otro.
- **Competencia de ventas entre productos:** En un análisis de ventas, el producto X alcanza el 35% de participación en el mercado y el producto Y el 33%, con un margen de error de $\pm 2\%$. Aquí, el margen de error (33% a 37% para X y 31% a 35% para Y) se superpone, lo que lleva a declarar un empate técnico entre los productos. Este tipo de análisis es crucial en la investigación de mercados, donde decisiones de marketing deben basarse en resultados estadísticamente significativos.

10.3 Tamaño del efecto

...

10.4 Tamaño de muestra

El **tamaño de muestra** afecta directamente la precisión de las estimaciones. Un mayor tamaño de muestra generalmente reduce el error estándar, disminuye el margen de error y mejora la confiabilidad de las estimaciones. Sin embargo, también implica un aumento en los costos y el tiempo de recolección de datos.

10.4.1 Tamaño de muestra óptimo

El tamaño de muestra óptimo se calcula bajo el supuesto de que cada registro genera un costo. En este sentido, la optimización se realiza disminuyendo el tamaño muestral con la restricción de que las estimaciones sean estadísticamente distintas de cero.

Consideraciones para determinar el tamaño óptimo:

1. **Costos:** Es fundamental considerar los costos asociados a la recolección de datos. Un tamaño muestral mayor a lo necesario puede generar costos innecesarios, mientras que un tamaño menor puede resultar en una estimación menos útil.
2. **Variabilidad:** La variabilidad dentro de la población impacta la determinación del tamaño de la muestra. Si la población es altamente variable, se necesitará un tamaño de muestra mayor para capturar esta variabilidad.
3. **Nivel de confianza y margen de error deseados:** Un mayor nivel de confianza o un margen de error más pequeño requerirá un tamaño de muestra más grande. Por ejemplo, si deseamos un nivel de confianza del 99% en lugar del 95%, el tamaño de la muestra tendrá que aumentar.
4. **Tamaño poblacional:** En poblaciones muy grandes, la relación entre el tamaño de la muestra y el tamaño poblacional es menos crítica. Sin embargo, en poblaciones pequeñas, se debe considerar el efecto de la muestra sobre el total.

10.5 Fórmulas para Estimación

10.5.1 Estimación de una Proporción con Tamaño Poblacional Conocido

Cuando se conoce el tamaño de la población y se desea estimar una proporción, se puede utilizar la siguiente fórmula:

$$n = \frac{N \cdot Z^2 \cdot p(1-p)}{(N - 1) \cdot E^2 + Z^2 \cdot p(1-p)}$$

Donde: - n = tamaño de la muestra - N = tamaño de la población - Z = valor crítico de la distribución normal (por ejemplo, 1.96 para un nivel de confianza del 95%) - p = proporción estimada de la población (por ejemplo, 0.5 si no se conoce) - E = margen de error deseado

10.5.2 Estimación de una Proporción con Tamaño Poblacional Desconocido

Cuando el tamaño de la población es desconocido, se utiliza la siguiente fórmula simplificada:

$$n = \frac{Z^2 \cdot p(1-p)}{E^2}$$

Donde: - n = tamaño de la muestra - Z = valor crítico de la distribución normal (por ejemplo, 1.96 para un nivel de confianza del 95%) - p = proporción estimada de la población (puede ser 0.5 si se desea máxima variabilidad) - E = margen de error deseado

10.5.3 Estimación de una Media con Tamaño Poblacional Conocido

Si el tamaño de la población es conocido y se desea estimar la media, se utiliza la siguiente fórmula:

$$n = \frac{N \cdot Z^2 \cdot \sigma^2}{(N - 1) \cdot E^2 + Z^2 \cdot \sigma^2}$$

Donde: - n = tamaño de la muestra - N = tamaño de la población - Z = valor crítico de la distribución normal (por ejemplo, 1.96 para un nivel de confianza del 95%) - σ = desviación estándar de la población - E = margen de error deseado

10.5.4 Estimación de una Media con Tamaño Poblacional Desconocido

Cuando el tamaño de la población es desconocido, se utiliza la siguiente fórmula:

$$n = \frac{Z^2 \cdot \sigma^2}{E^2}$$

Donde:

- n = tamaño de la muestra
- Z = valor crítico de la distribución normal (por ejemplo, 1.96 para un nivel de confianza del 95%)
- σ = desviación estándar de la población (o de la muestra si es necesario)
- E = margen de error deseado

Es importante considerar que, al utilizar estas fórmulas, se deben tener en cuenta supuestos como la normalidad de la población y la aleatoriedad de la muestra. Además, los valores de p y σ deben ser estimados de forma adecuada para obtener resultados confiables. Para poblaciones pequeñas, es recomendable aplicar una corrección de población finita si se utiliza la fórmula con el tamaño poblacional conocido.

Estas fórmulas son herramientas esenciales en la investigación estadística y permiten a los investigadores diseñar estudios que produzcan estimaciones precisas y confiables.

Ejemplo

- En un estudio sobre hábitos de consumo, se determina que el costo de encuestar a un individuo es de \$10. Si se quiere estimar el gasto promedio mensual con un margen de error de $\pm \$5$ y un nivel de confianza del 95%, se puede calcular el tamaño de muestra necesario utilizando la fórmula del tamaño de muestra:

$$n = \left(\frac{Z^2 \cdot \sigma^2}{E^2} \right)$$

Donde:

- E es el margen de error deseado.

Al determinar que la desviación estándar de los gastos mensuales es \$50, se puede calcular el tamaño muestral óptimo para cumplir con los criterios de estudio.

- **Costo-beneficio:** Supongamos que al calcular el tamaño muestral óptimo se determina que es de 100 encuestas. Si se decide llevar a cabo 150 encuestas, aunque se logra una mayor precisión, el costo adicional debe justificarse por los beneficios esperados del estudio.

En resumen, un tamaño muestral mayor al óptimo produce estimaciones que son distintas de cero, pero incurre en costos innecesarios. Por otro lado, un tamaño muestral menor al óptimo produce estimaciones que son estadísticamente iguales a cero, disminuyendo la utilidad del ejercicio. Por lo tanto, encontrar un equilibrio entre precisión y costo es esencial en el diseño de estudios estadísticos.

10.6 Aplicación Interactiva

Para ayudar a comprender cómo calcular el tamaño de muestra, se puede utilizar la siguiente herramienta interactiva:

Cálculo del tamaño de muestra

Esta aplicación te permite ingresar parámetros como el nivel de confianza, el margen de error, y la proporción esperada o la desviación estándar, dependiendo de si deseas estimar una proporción o una media. La herramienta calculará automáticamente el tamaño de muestra necesario para tu estudio, facilitando así la planificación y diseño de investigaciones.

Instrucciones:

1. Accede al enlace proporcionado.
2. Selecciona el tipo de estimación que deseas realizar (proporción o media) y (si lo conoces) el temaño poblacional.
3. Ingresa el margen de error que necesitas.
4. Haz clic en “Calcular” para obtener el tamaño de muestra recomendado.

Esta aplicación es especialmente útil para investigadores y profesionales que desean asegurarse de que sus estimaciones sean precisas y confiables, optimizando así los recursos destinados a la recolección de datos.

11 Hipótesis

11.1 La hipótesis en el contexto del desarrollo científico

Epistemológicamente, una **hipótesis** es una proposición que establece una relación entre variables, formulada para ser sometida a prueba a través de la observación y la experimentación. Este proceso es esencial en el desarrollo científico, ya que proporciona un puente entre la teoría y los datos empíricos, permitiendo transformar ideas abstractas en afirmaciones que pueden ser verificadas o refutadas. La capacidad de someter hipótesis a pruebas rigurosas y sistemáticas es lo que distingue al conocimiento científico de otras formas de conocimiento. Al plantear una hipótesis, el investigador no solo está formulando una afirmación, sino que también está invitando a la crítica y la validación a través de experimentos y observaciones.

Las pruebas de hipótesis son fundamentales en este proceso, ya que permiten evaluar la validez de las afirmaciones mediante un enfoque sistemático y basado en evidencias. Este enfoque no solo fomenta la acumulación de conocimiento, sino que también contribuye a la evolución de teorías dentro de un campo determinado. La capacidad de una hipótesis para ser refutada o confirmada es lo que la hace esencial para el avance del conocimiento científico, manteniendo siempre un carácter provisional y sujeto a revisión. En términos metodológicos, este procedimiento implica formular una **hipótesis nula** (H_0), que representa una afirmación inicial de no asociación o ausencia de efecto, y una **hipótesis alternativa** (H_A), que propone una relación o efecto específico entre las variables. Estas hipótesis son sometidas a un análisis estadístico que permite determinar si los datos observados son consistentes con la hipótesis nula o si proporcionan evidencia suficiente para apoyar la hipótesis alternativa.

En este sentido, es posible ver los modelos científicos como conjuntos lógicos y coherentes de hipótesis. Por ejemplo, el modelo del universo de Ptolomeo, desarrollado en la antigüedad, proponía que los cuerpos celestes giraban en esferas perfectas alrededor de la Tierra. Este modelo contenía implícitamente numerosas hipótesis sobre el movimiento y la disposición de los astros que, con el tiempo, fueron refutadas por observaciones empíricas y reemplazadas por el modelo heliocéntrico de Copérnico.

Otros modelos más cercanos a las ciencias sociales incluyen el modelo histórico-materialista de Karl Marx, que se basa en la hipótesis de que los cambios sociales y económicos son impulsados por las contradicciones inherentes a los modos de producción. Este modelo se ha sometido a pruebas empíricas en diferentes contextos históricos, como los análisis de la transición del feudalismo al capitalismo. De manera similar, el modelo de Max Weber sobre la acción social postula que las acciones humanas están motivadas por un conjunto de significados subjetivos

que pueden ser interpretados en función de diferentes tipos de racionalidad, como la racionalidad instrumental o valorativa. Este modelo ha sido evaluado empíricamente en investigaciones sociológicas que analizan fenómenos como el comportamiento económico o la ética religiosa.

Cada uno de estos modelos tiene sus hipótesis, que han sido comprobadas mediante estudios con información empírica, recopilada a través de métodos cuantitativos, cualitativos o mixtos. Por ejemplo, el análisis de encuestas, los estudios históricos y los experimentos sociales han permitido evaluar la aplicabilidad de estas hipótesis en diferentes contextos.

En consecuencia, las hipótesis no solo son elementos centrales en la construcción y validación de teorías científicas, sino que también sirven como herramientas para estructurar la investigación empírica. La subjetividad del conocimiento se minimiza cuando las hipótesis son verificables independientemente del investigador. Esta propiedad en el ámbito científico se denomina reproducibilidad.

11.1.1 Reproducibilidad

La **reproducibilidad** es un principio fundamental en la ciencia, que implica que los resultados de un experimento deben poder ser replicados por otros investigadores utilizando los mismos métodos. Esto no solo fortalece la validez de los hallazgos, sino que también asegura que el conocimiento científico se basa en evidencias sólidas y verificables.

La reproducibilidad es esencial para la credibilidad de la ciencia y se convierte en una medida del rigor y la fiabilidad de los estudios realizados. Sin reproducibilidad, los hallazgos pueden ser considerados anecdóticos y su impacto en la ciencia puede ser severamente cuestionado. No obstante, no es una práctica común y varios medios han reportado una [crisis en la reproducibilidad](#).

La **crisis actual de la reproducibilidad** en la ciencia se refiere a la creciente preocupación sobre la capacidad de replicar resultados científicos. Estudios han demostrado que un número significativo de resultados en diversas disciplinas no puede ser replicado, lo que plantea interrogantes sobre la validez de esos hallazgos. Por ejemplo, [un artículo de la revista Nature](#) encontró que tan solo para una treintena de 100 experimentos de psicología publicados en las mejores revistas científicas del campo se habían podido reproducir sus resultados. También es posible encontrar esta controversia en ciencias [de la salud, económicas y otras disciplinas](#)

11.2 Pruebas de hipótesis

11.2.1 Objetivo

El objetivo de una prueba de hipótesis es establecer si existe **suficiente evidencia** en una muestra aleatoria para **rechazar o no rechazar** la **hipótesis nula** a nivel poblacional. Esto busca determinar cuál hipótesis explica mejor los datos observados en la población.

11.2.2 Arquitectura de las pruebas de hipótesis

En el ámbito de la estadística y la investigación científica, la comprensión y aplicación de las pruebas de hipótesis es fundamental para validar teorías y conclusiones basadas en datos. Estas pruebas se estructuran de manera que permiten a los investigadores tomar decisiones informadas acerca de la relación entre variables y la existencia de efectos en estudios empíricos. Un buen punto de partida para ilustrar la lógica subyacente en las pruebas de hipótesis es la famosa analogía de la *tetera de Russell*, la cual ejemplifica la importancia de la carga de la prueba y su relación con la validación de afirmaciones complejas.

Bertrand Russell, filósofo y matemático británico, introdujo la analogía de una pequeña tetera de porcelana que orbita el Sol entre la Tierra y Marte, tan diminuta que ningún telescopio podría detectarla. La premisa de Russell es que, si alguien afirmara la existencia de esta tetera, la responsabilidad de demostrar su existencia recaería sobre esa persona y no sobre los escépticos, quienes no tendrían que probar la inexistencia de la misma. Este argumento sirve para destacar un principio esencial en la lógica y la ciencia: la carga de la prueba recae en quienes hacen afirmaciones poco usuales.

Russell empleó esta metáfora en el contexto de la religión, pero su aplicación es igualmente poderosa en la ciencia y la estadística. En el campo de las pruebas de hipótesis, se establece que la evidencia es la herramienta clave para sostener o rechazar afirmaciones. Esta carga de la prueba se traduce en un proceso metódico y riguroso que permite a los investigadores evaluar si los datos apoyan una hipótesis específica.

En estadística, la arquitectura de las pruebas de hipótesis propone la conformación en cada caso de dos hipótesis principales: la **hipótesis nula (H_0)** y la **hipótesis alternativa (H_A)**.

- **Hipótesis nula (H_0):** Es la suposición inicial que niega la existencia de un efecto o relación en la población de estudio. Es un punto de partida que establece que cualquier efecto observado es producto de la variabilidad natural o de un azar inherente. La hipótesis nula se formula de manera que, para rechazarla, se debe contar con evidencia suficiente que contradiga su planteamiento. No obstante, debido a su enunciado, su verificación resulta muy costosa.
- **Hipótesis alternativa (H_A):** Esta hipótesis propone la existencia de un efecto o relación y es la contraparte de la hipótesis nula. Si los datos recolectados ofrecen pruebas suficientes, se puede rechazar la hipótesis nula en favor de la hipótesis alternativa.

Este enfoque dual asegura que los investigadores se acerquen al análisis de manera objetiva, comenzando con la suposición de que no hay un efecto y buscando evidencia que justifique su rechazo.

Tip

Ejemplo aplicado a las ciencias sociales: Considere el siguiente problema de investigación: **¿Los videojuegos violentos causan comportamientos violentos?**. La prueba de hipótesis en este caso se separa en la existencia de la relación causal mencionada frente a su inexistencia. Debido a que es imposible demostrar la inexistencia de la relación, el sistema de hipótesis se estructuraría de la siguiente manera:

- **Hipótesis nula (H_0):** Los videojuegos violentos no causan un aumento en los comportamientos violentos.
- **Hipótesis alternativa (H_1):** Los videojuegos violentos causan un aumento en los comportamientos violentos.

El propósito de la prueba de hipótesis es analizar los datos recolectados en estudios experimentales u observacionales para determinar si hay suficiente evidencia empírica para rechazar la hipótesis nula y aceptar la hipótesis alternativa. Aquí, la prueba recae en la demostración de H_1 : si los datos muestran una relación estadísticamente significativa entre la exposición a videojuegos violentos y comportamientos agresivos, entonces la hipótesis nula puede ser rechazada razonablemente.

11.2.3 Reflexiones sobre la evidencia y la carga de la prueba

La analogía de la tetera de Russell es particularmente relevante al considerar la **evidencia necesaria para sostener o rechazar una hipótesis**. Así como Russell enfatizaba que es quien afirma la existencia de la tetera quien debe probar su existencia, en las pruebas de hipótesis, los investigadores deben demostrar que los datos apoyan la hipótesis alternativa y no asumir la verdad de H_0 sin evidencia adecuada. De lo contrario, el rigor científico y la validez de las conclusiones estarían en entredicho.

Este enfoque protege a la ciencia de afirmaciones infundadas y promueve una práctica investigativa basada en pruebas y datos sólidos. Al entender la arquitectura de las pruebas de hipótesis, los investigadores pueden abordar preguntas complejas con un marco metodológico que garantiza que sus conclusiones estén respaldadas por evidencia empírica y análisis crítico.

11.3 Terminología

La comprensión profunda de la terminología asociada con las pruebas de hipótesis es esencial para el análisis y la interpretación de datos en la estadística. A continuación, se presentan definiciones y explicaciones detalladas de los conceptos clave que constituyen la base de cualquier prueba de hipótesis.

11.3.1 Hipótesis estadística

Una **hipótesis estadística** es una afirmación sobre un parámetro poblacional que se somete a prueba mediante datos muestrales. Este tipo de hipótesis se formula con el fin de validar o refutar una suposición sobre la población a partir de la evidencia obtenida en la muestra. Dependiendo de la naturaleza de la afirmación, una hipótesis puede clasificarse en:

- **Hipótesis simple:** Es aquella que especifica un valor único y preciso para el parámetro de la población. Por ejemplo, si se formula la hipótesis $H_0 : \mu = \mu_0$, se está afirmando que la media poblacional es exactamente igual a un valor conocido μ_0 .
- **Hipótesis compuesta:** Esta hipótesis especifica un rango de valores para el parámetro poblacional en lugar de un único valor. Ejemplos de hipótesis compuestas incluyen $H : \mu \geq \mu_0$, $H : \mu \leq \mu_0$, $H : \mu > \mu_0$, $H : \mu < \mu_0$, y $H : \mu \neq \mu_0$.

En estas hipótesis, el valor μ_0 se conoce como el **valor hipotético**, que es el punto de referencia contra el cual se compara la estimación muestral para determinar si la hipótesis debe ser aceptada o rechazada.

11.3.2 Sistema de hipótesis

El **sistema de hipótesis** es el conjunto de hipótesis contrapuestas que se comparan en el proceso de la prueba de hipótesis. Este sistema incluye dos componentes principales:

- **Hipótesis nula (H_0):** Es la hipótesis de partida que se presume cierta y que no se rechaza a menos que los datos muestren una evidencia fuerte en su contra. La hipótesis nula se formula generalmente como una afirmación de igualdad o de ausencia de efecto. Ejemplos de hipótesis nulas pueden ser:
 - $H_0 : \mu \leq \mu_0$, que implica que la media poblacional es menor o igual al valor hipotético.
 - $H_0 : \mu \geq \mu_0$, que sugiere que la media es mayor o igual al valor hipotético.
 - $H_0 : \mu = \mu_0$, que postula que la media es exactamente igual al valor hipotético.
- **Hipótesis alternativa (H_1):** Representa la afirmación que se acepta si los datos muestrales proporcionan suficiente evidencia en contra de H_0 . Es la hipótesis que postula la existencia de un efecto, una diferencia o una relación significativa. Algunos ejemplos incluyen:
 - $H_1 : \mu > \mu_0$, que sostiene que la media poblacional es mayor que el valor hipotético.
 - $H_1 : \mu < \mu_0$, que indica que la media es menor que el valor hipotético.
 - $H_1 : \mu \neq \mu_0$, que señala que la media es diferente al valor hipotético, sin especificar si es mayor o menor.

Este sistema de hipótesis es el núcleo de la prueba estadística y establece un marco para decidir si los datos muestrales respaldan o refutan la hipótesis nula.

11.3.3 Tipos de error

En el proceso de tomar decisiones basadas en pruebas de hipótesis, es posible cometer errores. Estos errores se clasifican en dos tipos principales:

- **Error tipo I:** Ocurre cuando se rechaza la hipótesis nula siendo esta verdadera. Es decir, se concluye incorrectamente que hay un efecto o diferencia cuando en realidad no lo hay. La probabilidad de cometer un error tipo I se denota por α , que también se conoce como el **nivel de significancia** de la prueba. Este es un parámetro que se establece de antemano y refleja el nivel de tolerancia al riesgo de rechazar una hipótesis verdadera.
- **Error tipo II:** Se produce cuando no se rechaza la hipótesis nula cuando esta es falsa. En otras palabras, se falla en detectar un efecto o diferencia que realmente existe. La probabilidad de cometer un error tipo II se denota por β . El complemento de β se llama **potencia de la prueba** y representa la probabilidad de rechazar correctamente una hipótesis nula falsa.

La relación entre los tipos de error y la potencia de la prueba es fundamental para comprender la eficacia y precisión de una prueba estadística. Un investigador debe equilibrar estos errores al diseñar una prueba, ya que reducir la probabilidad de un error tipo I puede incrementar la probabilidad de un error tipo II, y viceversa.

11.3.4 effect sizes

11.3.5 Nivel de significancia

El **nivel de significancia** (α) es un umbral predefinido que establece la probabilidad máxima aceptable de cometer un error tipo I. Comúnmente, los niveles de significancia utilizados son 0.05, 0.01, o 0.10. Este valor define el criterio para decidir si los resultados de una prueba son estadísticamente significativos. Si el valor p obtenido de la prueba es menor o igual a α , se rechaza la hipótesis nula en favor de la hipótesis alternativa, indicando que los resultados observados son lo suficientemente raros como para no atribuirse al azar.

La elección del nivel de significancia depende del contexto y las consecuencias de cometer un error tipo I. En estudios donde el costo de un error tipo I es alto, se elige un α más bajo (e.g., 0.01). En otros casos, donde la tolerancia al riesgo es mayor, se podría optar por un α más alto (e.g., 0.10).

11.3.6 Integrando los conceptos en la práctica

La correcta formulación de hipótesis y la comprensión de los tipos de error y del nivel de significancia permiten a los investigadores tomar decisiones informadas basadas en los datos muestrales. En un estudio, el análisis de hipótesis proporciona un camino claro para evaluar

si una afirmación sobre la población es plausible o si debe ser rechazada en función de la evidencia empírica. Este enfoque estructurado es la base para el análisis crítico y la validación de resultados en investigación científica y en aplicaciones prácticas en diversos campos.

11.4 Tipos de error

En una prueba de hipótesis, pueden ocurrir dos tipos de errores.

- **error tipo 1:** Rechazar la hipótesis nula cuando esta es verdadera. La probabilidad de cometer este error es el nivel de significancia α .
- **error tipo 2:** No rechazar la hipótesis nula cuando esta es falsa. La probabilidad de cometer este error se denota como β .

En una prueba de hipótesis, pueden ocurrir dos tipos de errores.

11.5 Nivel de significancia

El **nivel de significancia** (α) es la probabilidad de cometer un error tipo 1, es decir, rechazar la hipótesis nula cuando en realidad es cierta. Este nivel se establece antes de realizar la prueba y comúnmente se fija en 0.05 o 0.01.

•

$$\alpha = P(\text{error tipo 1}) = P(\text{rechazar } H_0 \mid H_0)$$

11.6 Rechazar la hipótesis nula

Rechazar H_0 implica que se ha encontrado algo en la muestra tan improbable bajo la hipótesis nula, que lleva al investigador a favorecer la hipótesis alternativa H_1 . Sin embargo, siempre existe la posibilidad de cometer un error tipo 1 al hacer esta decisión.

En estadística, se prefiere no rechazar H_0 erróneamente a rechazarla sin suficiente evidencia. Por esto, H_0 se mantiene a menos que haya **evidencia contundente** que obligue a revocarla. Este enfoque refleja un principio conservador en la ciencia, donde se requiere una alta carga de prueba para cambiar el estado actual del conocimiento.

11.7 Valor p

El **valor p** es la probabilidad de observar un estadístico de prueba tan extremo o más extremo que el observado, bajo la suposición de que la hipótesis nula es cierta.

- Si $p < \alpha$, se rechaza H_0 , lo que sugiere que la evidencia muestral no es compatible con H_0 .
- Si $p \geq \alpha$, no se rechaza H_0 , indicando que los datos son consistentes con H_0 .

Es importante recordar que el valor p no mide la probabilidad de que H_0 sea verdadera, sino la probabilidad de los datos observados bajo H_0 .

11.8 Decisión

La decisión en una prueba de hipótesis se basa en comparar el valor p con el nivel de significancia α :

- Si $p < \alpha$, se **rechaza H_0** .
- Si $p \geq \alpha$, **no se rechaza H_0** .

Esta decisión refleja si la evidencia contra H_0 es lo suficientemente fuerte para considerarla improbable bajo su supuesta veracidad.

11.9 Prueba

El proceso para realizar una prueba de hipótesis incluye los siguientes pasos:

1. **Establecer las hipótesis:** Definir H_0 y H_1 basándose en el problema de investigación.
2. **Formular el sistema de hipótesis** y seleccionar el nivel de significancia α .
3. **Calcular el valor p :** Utilizar los datos muestrales para calcular el estadístico de prueba y el correspondiente valor p .
4. **Tomar la decisión:** Rechazar H_0 si $p < \alpha$ o no rechazar H_0 si $p \geq \alpha$.
5. **Interpretar los resultados:** Explicar el resultado en el contexto del problema de investigación, indicando si hay evidencia suficiente para apoyar H_1 .

11.9.1 El papel de la significancia estadística y el error

El proceso de las pruebas de hipótesis incluye la definición de un nivel de significancia (α), que es la probabilidad de rechazar la hipótesis nula cuando es verdadera (error tipo I). Comúnmente, se utiliza un nivel de significancia de 0.05, lo que implica que hay un 5% de probabilidad de cometer un error al rechazar H_0 incorrectamente.

El resultado de una prueba estadística produce un valor p , que representa la probabilidad de observar los datos obtenidos, o más extremos, bajo la suposición de que H_0 es cierta. Si el valor p es menor que el nivel de significancia, se rechaza H_0 en favor de H_1 . Sin embargo, si el valor p es mayor, no se rechaza H_0 , lo que sugiere que no hay suficiente evidencia para afirmar un efecto significativo.

12 Pruebas y tipos de pruebas

Para probar una hipótesis los procedimientos se dividen en cuatro tipos

- ...

12.1 Pruebas paramétricas

Las **pruebas paramétricas** estudian un parámetro de dimensión finita (una colección finita de parámetros), por esta razón presentan supuestos específicos sobre la distribución de los datos.

Las **pruebas paramétricas** estudian un parámetro de dimensión infinita (funciones de densidad).

Analíticas: Hacen uso de propiedades generales de las distribuciones.

Simulación estocástica: Hacen uso de simulación computacional para obtener el valor-p.

Asumen que los datos siguen una distribución conocida, usualmente normal. Estas pruebas requieren que se cumplan ciertos supuestos, como la homogeneidad de varianzas y la linealidad.

Estas pruebas son más potentes cuando los datos cumplen estos supuestos, ya que utilizan toda la información disponible en los datos.

Cuando los datos no cumplen los supuestos, las pruebas pierden validez y los estudios rigor científico.

- Prueba t de Student (para la comparación de medias)
- ANOVA (para la comparación de medias entre múltiples grupos)

12.2 Pruebas no paramétricas analíticas

Las **pruebas no paramétricas analíticas** hacen uso de propiedades matemáticas generales de las distribuciones continuas. Por lo tanto, no requieren supuestos tan fuertes sobre la distribución de los datos.

Son útiles cuando los datos no cumplen los supuestos necesarios para las pruebas paramétricas, como en casos de datos con distribuciones no normales o escalas de medición ordinales.

Son menos potentes que las pruebas paramétricas en los casos paramétricos. No obstante, son más flexibles y aplicables a una mayor variedad de situaciones.

- Prueba de Mann-Whitney (para la comparación de dos grupos independientes)
- Prueba de Wilcoxon (para la comparación de dos grupos pareados)
- Prueba de Kruskal-Wallis (para la comparación de múltiples grupos)

12.3 Pruebas no paramétricas de simulación estocástica

Las **pruebas de permutaciones** son métodos estadísticos no paramétricos que evalúan la significancia de un estadístico de prueba al permutar, simular o remuestrear los datos observados con el fin de obtener una muestra de estadísticos bajo H_0 .

Al comparar el estadístico observado con la muestra de los estadísticos obtenidos, se puede determinar si el efecto observado es significativo.

- **Permutación:** Se basa en la idea de que si no hay efecto, todas las permutaciones de los datos son igualmente probables.
- **Simulación:** Se basa en la idea de que es posible simular la hipótesis nula y encontrar una muestra para el estimador bajo estas condiciones.
- **Remuestreo:** Se basa en la idea de que una muestra aleatoria de una muestra aleatoria es una muestra aleatoria.

Al comparar el estadístico observado con la distribución de los estadísticos obtenidos de las permutaciones, se puede determinar si el efecto observado es significativo.

Calculo del valor p: Se calcula como la proporción de permutaciones en las que el estadístico de prueba es al menos tan extremo como el observado.

Estas pruebas no dependen de supuestos sobre la distribución de los datos, lo que las hace muy flexibles y robustas frente a diversas condiciones de los datos.

12.4 Cuándo usar cada tipo de prueba

Dependiendo de la cantidad de conocimiento que tenemos sobre los datos podemos elegir cuándo aplicar cada tipo de prueba.

- **Pruebas paramétricas:** cuando los datos cumplen con los supuestos de normalidad y homogeneidad de varianzas, y se requiere mayor potencia estadística.
- **Pruebas no paramétricas:** cuando los datos no cumplen con los supuestos paramétricos o cuando se trabaja con datos ordinales o no numéricos. Son útiles sean analíticas o de simulación estocástica.

12.5 Pruebas de hipótesis más usadas

12.5.1 Test t de Student para una muestra

En la familia normal, una muestra aleatoria $X = \{X_1, \dots, X_n\}$ especificamos las hipótesis

$$\begin{aligned} H_0 &: \mu = \mu_0 \\ H_A &: \mu \neq \mu_0 \end{aligned}$$

12.5.2 Test de signos para una muestra

En la familia de distribuciones continuas, siendo θ la mediana, una muestra aleatoria $X = \{X_1, \dots, X_n\}$ especificamos las hipótesis.

$$\begin{aligned} H_0 &: \theta = \theta_0 \\ H_A &: \theta \neq \theta_0 \end{aligned}$$

12.5.3 Test t de Student para dos muestras independientes

En la familia normal, dos muestras aleatorias $X = \{X_1, \dots, X_m\}$ y $Y = \{Y_1, \dots, Y_n\}$, bajo homogeneidad ($\sigma_x^2 = \sigma_y^2$), especificamos las hipótesis

$$\begin{aligned} H_0 &: \mu_X = \mu_Y \\ H_A &: \mu_X \neq \mu_Y \end{aligned}$$

12.5.4 Test t de Student para dos muestras independientes

En la familia normal, dos muestras aleatorias $X = \{X_1, \dots, X_m\}$ y $Y = \{Y_1, \dots, Y_n\}$, bajo heterogeneidad ($\sigma_x^2 \neq \sigma_y^2$), especificamos las hipótesis

$$\begin{aligned} H_0 &: \mu_X = \mu_Y \\ H_A &: \mu_X \neq \mu_Y \end{aligned}$$

12.5.5 Test Wilcoxon - Mann - Whitney

En la familia de las distribuciones continuas, siendo θ la mediana, sean dos muestras aleatorias $X = \{X_1, \dots, X_m\}$ y $Y = \{Y_1, \dots, Y_n\}$, especificamos las hipótesis

$$\begin{aligned} H_0 &: \theta_X = \theta_Y \\ H_A &: \theta_X \neq \theta_Y \end{aligned}$$

12.5.6 Test t de Student para dos muestras pareadas

En la familia normal, dos muestras aleatorias pareadas $X = \{X_1, \dots, X_n\}$ y $Y = \{Y_1, \dots, Y_n\}$, bajo heterogeneidad ($\sigma_x^2 \neq \sigma_y^2$), especificamos las hipótesis

$$\begin{aligned} H_0 &: \mu_X = \mu_Y \\ H_A &: \mu_X \neq \mu_Y \end{aligned}$$

Es suficiente ver que si $D = X - Y$ entonces podemos probar

$$\begin{aligned} H_0 &: \mu_D = 0 \\ H_A &: \mu_D \neq 0 \end{aligned}$$

12.5.7 Prueba de una sola proporción

En una distribución Bernoulli(π), sea una muestra $X = \{X_1, \dots, X_n\}$, especificamos las hipótesis

$$\begin{aligned} H_0 &: \pi_X = \pi_0 \\ H_A &: \pi_X \neq \pi_0 \end{aligned}$$

12.5.8 Prueba de dos proporciones

En una distribución Bernoulli(π), sean dos muestras $X = \{X_1, \dots, X_n\}$ y $Y = \{Y_1, \dots, Y_n\}$, especificamos las hipótesis

$$\begin{aligned} H_0 &: \pi_X = \pi_y \\ H_A &: \pi_X \neq \pi_y \end{aligned}$$

12.5.9 Test de correlación de Pearson

En la familia normal, sea una muestra aleatoria de dos variables $X = \{X_1, \dots, X_n\}$ y $Y = \{Y_1, \dots, Y_n\}$ especificamos las hipótesis

$$\begin{aligned} H_0 &: \rho = \rho_0 \\ H_A &: \rho \neq \rho_0 \end{aligned}$$

12.5.10 Test de correlación de Spearman

En la familia de distribuciones continuas, sea una muestra aleatoria de dos variables $X = \{X_1, \dots, X_n\}$ y $Y = \{Y_1, \dots, Y_n\}$ especificamos las hipótesis

$$\begin{aligned} H_0 &: \rho_s = \rho_{s0} \\ H_A &: \rho_s \neq \rho_{s0} \end{aligned}$$

Part III

Modelamiento lineal

Introducción

Modelamiento

Correlaciones

Relación

Regresión lineal

Regresión logística

Medición

Componentes principales

Modelos de ecuaciones estructurales

13 Abordaje

13.1 Qué es un modelo estadístico

Un modelo estadístico es un conjunto de supuestos matemáticos que se realizan sobre la distribución asociada a un conjunto de datos.

13.1.1 Se ve así

$$y = \beta_0 + X_1\beta_1 + X_2\beta_2 + \dots + X_k\beta_k + \varepsilon$$

Pero...

Cada número β_i tiene unas propiedades. Por eso, el reporte de un modelo se vuelve un poco complejo de interpretar.

13.2 Actividad en clase

$$[realrinc] = \beta_0 + [hrs1] \cdot \beta_1 + \varepsilon$$

Revisemos las partes de un modelo

A continuación se presentan los resultados de un análisis realizado a partir de una encuesta estadounidense realizada en 2018. La variable dependiente es cuánto gana el encuestado en un año, en dólares estadounidenses. La variable independiente es cuántas horas trabajó el encuestado la semana pasada. En la encuesta real hay miles de respuestas, pero aquí se seleccionaron 46 de ellas al azar para facilitar la presentación de los resultados.

13.3 Justificación

¿Por qué hacemos modelos?

To explain or to predict

13.4 Modelamiento

El modelamiento es una técnica esencial en la investigación científica, que permite representar y analizar fenómenos complejos del mundo real. Los modelos son simplificaciones que ayudan a entender, predecir y, en algunos casos, controlar estos fenómenos.

13.4.1 De la realidad a la teoría

El proceso de modelamiento inicia con la observación de la realidad. A partir de estas observaciones, se desarrollan teorías que intentan explicar el comportamiento observado. Los modelos son representaciones de estas teorías, diseñadas para ser más manejables y comprensibles.

13.4.2 Modelamiento estadístico

El modelamiento estadístico utiliza datos para construir modelos que describen y analizan relaciones entre variables. Estos modelos son fundamentales en diversas disciplinas científicas, como la economía, la psicología, la biología y la ingeniería, entre otras.

13.5 Tipos de modelos

Existen diferentes tipos de modelos que se utilizan dependiendo de los objetivos de la investigación. Los principales son:

13.5.1 Descripción

Modelos descriptivos que buscan representar las características básicas de los datos sin hacer suposiciones sobre la estructura subyacente.

13.5.2 Explicación

Modelos explicativos que buscan identificar y entender las relaciones causales entre variables.

13.5.3 Pronóstico

Modelos predictivos que se utilizan para hacer predicciones sobre futuros eventos o comportamientos basados en datos actuales o pasados.

14 Modelamiento

14.1 Modelamiento descriptivo

El modelamiento descriptivo se centra en resumir y visualizar los datos, proporcionando una imagen clara de lo que los datos muestran. Es el primer paso en cualquier análisis de datos, ya que ayuda a entender el contexto y las características básicas del conjunto de datos.

14.2 Herramientas del modelamiento descriptivo

Las herramientas más comunes para el modelamiento descriptivo incluyen:

- **Tablas de frecuencia:** que muestran cómo se distribuyen los valores de una variable.
- **Medidas de tendencia central:** como la media, mediana y moda, que resumen el valor típico de los datos.
- **Medidas de dispersión:** como la varianza y la desviación estándar, que indican cuánta variación hay en los datos.
- **Gráficos:** como histogramas, diagramas de dispersión y gráficos de caja, que ayudan a visualizar la distribución y las relaciones entre variables.

14.3 Ejemplos del modelamiento descriptivo

- **Análisis de la distribución de la edad en una población:** utilizando histogramas y medidas de tendencia central para resumir los datos.
- **Estudio de la dispersión de precios en diferentes mercados:** utilizando gráficos de caja para comparar la variabilidad entre diferentes ubicaciones.

14.4 Modelamiento explicativo

El modelamiento explicativo busca entender las causas y efectos dentro de un conjunto de datos. Este tipo de modelamiento es fundamental para probar hipótesis y teorías científicas, ya que permite establecer relaciones causales entre variables.

14.5 Herramientas del modelamiento explicativo

Las herramientas más comunes para el modelamiento explicativo incluyen:

- **Regresión lineal:** que permite examinar la relación entre una variable dependiente y una o más variables independientes.
- **Análisis de varianza (ANOVA):** que se utiliza para comparar las medias de diferentes grupos y determinar si las diferencias observadas son estadísticamente significativas.
- **Modelos estructurales:** que permiten analizar relaciones complejas entre múltiples variables, incluyendo efectos directos e indirectos.

14.6 Ejemplos del modelamiento explicativo

- **Estudio de los factores que afectan el rendimiento académico:** utilizando regresión lineal para examinar el impacto de variables como el tiempo de estudio, el apoyo familiar y las características socioeconómicas.
- **Investigación sobre los determinantes de la satisfacción laboral:** utilizando ANOVA para comparar diferentes grupos de empleados y entender cómo factores como el salario, las condiciones de trabajo y el liderazgo influyen en la satisfacción.

14.7 Modelamiento predictivo

El modelamiento predictivo se utiliza para hacer predicciones sobre eventos futuros basados en datos históricos. Este tipo de modelamiento es clave en áreas como el pronóstico del tiempo, la predicción de ventas, y la identificación de riesgos en finanzas.

14.8 Herramientas del modelamiento predictivo

Las herramientas más comunes para el modelamiento predictivo incluyen:

- **Regresión logística:** que se utiliza para predecir una variable categórica, como el resultado de una elección o la probabilidad de que ocurra un evento.
- **Árboles de decisión:** que dividen los datos en ramas para tomar decisiones basadas en reglas simples.
- **Modelos de series temporales:** que analizan datos secuenciales en el tiempo para hacer predicciones sobre futuros puntos en la serie.

14.9 Ejemplos del modelamiento predictivo

- **Predicción del comportamiento del cliente en una tienda en línea:** utilizando regresión logística para determinar la probabilidad de que un cliente compre un producto basado en su historial de navegación.
- **Pronóstico de la demanda de energía:** utilizando modelos de series temporales para predecir el consumo de energía en diferentes estaciones del año.

14.10 Diferencias clave entre describir, explicar y pronosticar

Es fundamental distinguir entre los objetivos del modelamiento descriptivo, explicativo y predictivo:

- **Describir** se enfoca en resumir y visualizar los datos existentes.
- **Explicar** busca entender las relaciones causales y los mecanismos subyacentes en los datos.
- **Pronosticar** se orienta hacia la predicción de futuros eventos o comportamientos basados en patrones observados en los datos.

14.11 Etapas del modelamiento

El modelamiento es un proceso complejo que involucra varias etapas clave, desde la definición del problema hasta la aplicación del modelo para realizar predicciones o comprender un fenómeno. Cada etapa es esencial para garantizar que el modelo sea preciso, interpretable y útil.

Definición del problema: establecer el objetivo del modelamiento.

Recolección de datos: recopilar y preparar los datos que se utilizarán en el modelamiento.

Exploración y preparación: entender la naturaleza y características de los datos disponibles.

Formulación del modelo: plantear el modelo más adecuado según los objetivos. Debe existir una coincidencia entre los conceptos del contexto y las variables del modelo.

Estimación del modelo: ajustar el modelo a los datos para obtener los parámetros que mejor representen las relaciones subyacentes.

Evaluación del modelo: verificar la calidad del modelo utilizando medidas de ajuste y validación cruzada.

Interpretación y presentación de resultados: analizar los resultados del modelo y presentarlos de manera comprensible para el público objetivo.

Aplicación del modelo: utilizar el modelo para hacer predicciones o para comprender mejor el fenómeno en estudio.

14.11.1 Definición del problema

La definición del problema es la primera y más crucial etapa en el proceso de modelamiento. Aquí se establece el objetivo del estudio, las preguntas de investigación que se desean responder y las hipótesis que se pretenden probar. Una clara definición del problema orienta todo el proceso de modelamiento, asegurando que los esfuerzos se centren en las preguntas más relevantes y que los resultados sean útiles para la toma de decisiones.

En esta etapa, es importante:

- **Identificar el fenómeno de interés:** ¿Qué es lo que se desea entender, explicar o predecir?
- **Delimitar el alcance del estudio:** ¿Cuáles son los límites del problema? ¿Qué variables serán incluidas o excluidas?
- **Establecer los objetivos del modelamiento:** ¿Qué se espera lograr con el modelo? ¿Se busca una descripción, una explicación o una predicción?

14.11.2 Recolección de datos

La recolección de datos es el proceso de obtener la información necesaria para desarrollar y ajustar el modelo. Los datos pueden provenir de diversas fuentes, como encuestas, experimentos, registros históricos o bases de datos públicas. La calidad y la relevancia de los datos son fundamentales para el éxito del modelamiento.

Durante esta etapa se deben considerar los siguientes aspectos:

- **Selección de fuentes de datos:** ¿De dónde se obtendrán los datos? ¿Son fiables y relevantes para el problema definido?
- **Preparación de los datos:** ¿Cómo se limpiarán, transformarán y organizarán los datos para que sean adecuados para el análisis? Esto puede incluir la eliminación de valores atípicos, el manejo de datos faltantes y la normalización de variables.
- **Validación de datos:** ¿Cómo se asegurará la calidad y precisión de los datos recolectados?

14.11.3 Preparación y exploración de los datos

La **preparación y exploración de los datos** es una fase crucial en cualquier proceso de modelamiento, ya que los datos en bruto generalmente no están listos para ser utilizados

directamente en un modelo. Esta fase implica una serie de actividades destinadas a comprender, limpiar, y transformar los datos para que sean adecuados para el análisis.

14.12 Formulación del modelo

La selección del modelo es la etapa en la que se elige el tipo de modelo más adecuado para los datos y los objetivos de la investigación. Dependiendo del tipo de problema, se pueden considerar diferentes enfoques de modelamiento, como modelos descriptivos, explicativos o predictivos.

Consideraciones clave durante esta etapa incluyen:

- **Naturaleza del fenómeno:** ¿Qué tipo de relación existe entre las variables? ¿Es lineal, no lineal, categórica, etc.?
- **Complejidad del modelo:** ¿Se necesita un modelo simple y fácil de interpretar, o es preferible un modelo complejo que capture más detalles?
- **Disponibilidad de herramientas:** ¿Qué herramientas de software y métodos estadísticos están disponibles para ajustar el modelo?
- **Soporte teórico del modelo:** ¿Qué supuestos tiene el modelo? ¿Cuáles son relacionales? ¿Cuáles son distribucionales? ¿Qué hipótesis resuelve?

14.13 Estimación del modelo

La estimación del modelo implica ajustar el modelo seleccionado a los datos, es decir, encontrar los parámetros que mejor representan la relación entre las variables. Esta etapa es crucial para garantizar que el modelo sea una representación precisa y válida del fenómeno en estudio.

Pasos en la estimación del modelo:

- **Ajuste del modelo:** Utilización de métodos estadísticos para estimar los parámetros del modelo, como la regresión lineal, máxima verosimilitud, o técnicas de machine learning.
- **Pruebas de significancia:** Evaluación de la significancia estadística de los parámetros estimados para determinar si tienen un impacto real en las variables dependientes.
- **Verificación de supuestos:** Comprobación de que los supuestos del modelo se cumplen, como la normalidad de los errores, la homocedasticidad y la independencia de las observaciones.

14.14 Evaluación del modelo

La evaluación del modelo es una etapa crítica donde se examina la precisión y la validez del modelo ajustado. Aquí se utilizan diversas métricas y pruebas para determinar si el modelo es adecuado y si puede generalizarse a otros datos.

Aspectos a considerar durante la evaluación:

- **Medidas de ajuste:** ¿Qué tan bien se ajusta el modelo a los datos observados? Medidas como el R^2 , el error cuadrático medio (RMSE) y la log-verosimilitud se utilizan para evaluar el ajuste.
- **Validación cruzada:** ¿Cómo se desempeña el modelo cuando se aplica a nuevos datos no utilizados en la estimación? La validación cruzada y la prueba en conjuntos de datos separados son técnicas comunes.
- **Análisis de residuos:** ¿Los residuos del modelo son aleatorios y no muestran patrones sistemáticos? Este análisis ayuda a verificar la adecuación del modelo.

14.15 Interpretación y presentación de resultados

Una vez que el modelo ha sido estimado y evaluado, la siguiente etapa es interpretar los resultados y presentarlos de manera que sean comprensibles y útiles para los tomadores de decisiones. La claridad en la interpretación es crucial para que los resultados del modelamiento tengan un impacto significativo.

Puntos clave en esta etapa:

- **Interpretación de los parámetros:** ¿Qué significan los coeficientes estimados en el contexto del problema? ¿Cómo se relacionan las variables independientes con la variable dependiente?
- **Visualización de resultados:** ¿Cómo se pueden presentar los resultados de manera visual, utilizando gráficos y tablas para facilitar su comprensión?
- **Conclusiones y recomendaciones:** ¿Qué conclusiones se pueden extraer del análisis? ¿Qué recomendaciones pueden hacerse en base a los resultados del modelo?

14.16 Aplicación del modelo

La aplicación del modelo es la fase final, donde los resultados obtenidos del modelamiento se utilizan para tomar decisiones, hacer predicciones, o profundizar el entendimiento del fenómeno en estudio. Esta etapa puede incluir la implementación del modelo en sistemas de apoyo a la decisión, el uso del modelo para la planificación estratégica, o la publicación de los hallazgos en un contexto académico.

Consideraciones en la aplicación del modelo:

- **Implementación:** ¿Cómo se utilizará el modelo en la práctica? ¿Qué sistemas o procesos se verán afectados por la implementación del modelo?
- **Monitoreo y actualización:** ¿Cómo se monitoreará el desempeño del modelo a lo largo del tiempo? ¿Qué mecanismos se establecerán para actualizar el modelo con nuevos datos?
- **Evaluación del impacto:** ¿Qué impacto tiene la aplicación del modelo en los resultados esperados? ¿Se cumplen los objetivos iniciales del modelamiento?

14.17 Selección de datos

- **Selección de características:** Identificación de variables irrelevantes o redundantes para simplificar el modelo y mejorar su interpretabilidad.
- **Partición en conjuntos de entrenamiento y prueba:** Separación de los datos en conjuntos de entrenamiento y validación para evaluar el rendimiento del modelo de manera más robusta.

14.18 Análisis descriptivo

El análisis descriptivo permite generar un diagnóstico sobre el contexto y apoya la selección de los modelos a ajustar.

14.19 Análisis descriptivo univariado

- **Media:** Es el promedio de los valores de la variable. Proporciona una medida central de la distribución.
- **Mediana:** Es el valor que divide la distribución en dos partes iguales. Útil para datos sesgados.
- **Desviación estándar:** Mide la dispersión de los datos en relación con la media. Indica qué tan dispersos están los valores.
- **Moda:** El valor que aparece con mayor frecuencia en el conjunto de datos.
- **Rango:** Diferencia entre el valor máximo y el mínimo de la distribución.

14.20 Generación de visualizaciones

- **Gráficos de dispersión:** Utilizados para examinar la relación entre dos variables numéricas. Pueden ayudar a detectar correlaciones o patrones.
- **Histogramas:** Representaciones gráficas que muestran la distribución de una variable continua. Ayudan a visualizar la frecuencia de los valores en diferentes intervalos.
- **Diagramas de caja (boxplots):** Herramientas gráficas que muestran la mediana, los cuartiles y los posibles valores atípicos de una variable. Útiles para identificar la dispersión y la simetría de la distribución.
- **Diagramas de violín:** Combinan un diagrama de caja con un gráfico de densidad, proporcionando una visión más detallada de la distribución de la variable.

14.21 Análisis correlacional

- **Correlación de Pearson:** Mide la fuerza y dirección de la relación lineal entre dos variables numéricas.
- **Correlación de Spearman:** Mide la fuerza y dirección de la relación monótona entre dos variables, sin requerir que la relación sea lineal.
- **Correlación de Kendall:** Mide la concordancia entre dos variables ordinales, útil para datos con rangos.
- **Matriz de correlación:** Tabla que muestra las correlaciones entre múltiples variables a la vez. Es útil para identificar rápidamente relaciones fuertes o débiles entre varias variables.

14.22 Análisis de desagregación

- **Desagregación de datos:** Separar los datos en subgrupos basados en categorías de una variable para examinar patrones o tendencias dentro de cada subgrupo.
- **Exploración de la estructura de los datos:** Identificar patrones claros en los datos, como tendencias o ciclos, que puedan indicar la necesidad de una transformación.

15 Correlación, desagregación y causalidad

15.1 Correlación numérica - numérica

La asociación de variables es la herramienta que nos permite explorar y entender las relaciones entre diferentes conjuntos de datos. La correlación mide la fuerza y la dirección de la relación entre dos variables.

15.2 Dependencia e independencia lineal:

- **Positiva:** La relación es tal que a medida que una variable aumenta, la otra también tiende a aumentar. Ejemplo: La relación entre la altura y el peso de una persona.
- **Negativa:** La relación es tal que a medida que una variable aumenta, la otra tiende a disminuir. Ejemplo: La relación entre el precio de un producto y la cantidad demandada.
- **Independiente:** No hay una relación aparente entre las dos variables. Ejemplo: La relación entre el color de los ojos y el salario de una persona.

15.3 Regresión

$$y = \beta_0 + X_1\beta_1 + X_2\beta_2 + \dots + X_k\beta_k + \varepsilon$$

Técnica estadística utilizada para modelar y analizar la relación entre una variable dependiente y una o más variables independientes.

15.3.1 Componentes:

- β_0 : Intersección (constante).
- X_i : Variables independientes.
- β_i : Coeficientes de las variables independientes.
- ε : Error aleatorio.

15.4 Causalidad

La manera óptima de comprobar causalidad es mediante un experimento.

- **Definición:** Método para establecer relaciones causales entre variables mediante la manipulación controlada de una o más variables independientes y la observación del efecto en una o más variables dependientes.
- **Importancia:** Permite inferir causalidad en lugar de solo correlación, lo cual es crucial para la validez de los resultados.
- **Ejemplo:** Un experimento clínico donde se prueba el efecto de un nuevo medicamento en la presión arterial de los pacientes.

15.5 Causalidad

15.5.1 Actividad en clase

En parejas, generar un escrito sobre la causalidad desde la perspectiva de un autor teórico que elijan. Extensión máxima de cuartilla.

16 Modelamiento estadístico

16.1 Qué es un modelo estadístico

Un modelo estadístico es una representación matemática que describe cómo una o más variables aleatorias se relacionan entre sí.

Tiene como propósito simplificar la realidad para entender las relaciones entre variables y hacer predicciones o inferencias.

16.2 Proceso de modelamiento estadístico

- **Formulación:** Revisar la literatura existente. Formular hipótesis claras. Definir el modelo teórico con base en conceptos y teorías previas.
- **Estimación y ajuste:** Implica el uso de métodos estadísticos para estimar los parámetros del modelo, como los coeficientes en una regresión. Una vez estimados los parámetros, se ajusta el modelo para que mejor represente los datos observados.
- **Validación y evaluación:** La validación se refiere a la comprobación de la generalizabilidad del modelo y de sus supuestos. La evaluación se refiere a la bondad de ajuste, qué tanto reflejan los datos.

16.3 Formulación

16.3.1 Partes de un modelo

- **Variables dependientes e independientes:** Identificación de las variables que serán explicadas y las que se usarán como predictores.
- **Relación funcional:** La forma en que las variables independientes se combinan para influir en la variable dependiente.
- **Término de error:** Captura la variabilidad no explicada por las variables independientes.

16.4 Formulación

16.4.1 Especificación matemática

La especificación matemática de un modelo implica:

- **Formulación de ecuaciones:** Definir cómo las variables independientes afectan a la variable dependiente.
- **Definición de supuestos:** Establecer los supuestos subyacentes (como la linealidad, independencia, homocedasticidad, etc.).
- **Notación y simbolismo:** Uso de notación matemática clara para representar las relaciones y supuestos.

16.5 Formulación

16.5.1 Supuestos teóricos

Los modelos estadísticos se basan en varios supuestos teóricos:

- **Linealidad:** Relación lineal entre variables independientes y dependientes.
- **Independencia de errores:** Los errores no están correlacionados entre sí.
- **Homoscedasticidad:** La varianza de los errores es constante.
- **Normalidad:** Los errores siguen una distribución normal.

16.6 Estimación y ajuste

16.6.1 Parámetros y estimadores

Los conceptos clave son:

- **Parámetros:** Valores desconocidos en el modelo que describen la relación entre variables.
- **Estimadores:** Funciones que proporcionan valores aproximados de los parámetros basados en los datos.
- **Significancia:** Métodos para generalizar el conocimiento subyacente de la muestra hacia la población.

16.7 Estimación y ajuste

El proceso de estimación involucra:

- **Selección del método de estimación:** Métodos como Mínimos Cuadrados Ordinarios (OLS), Máxima Verosimilitud, etc.
- **Cálculo de estimadores:** Determinar los valores que minimizan o maximizan una función objetivo.
- **Evaluación de los estimadores:** Análisis de la eficiencia, sesgo, y consistencia de los estimadores.

16.8 Estimación y ajuste

16.8.1 Estimación puntual

Encontrar los valores de β y σ^2 para reproducir y tan precisamente como sea posible.

- Máxima verosimilitud
- OLS
- PLS
- LOESS

16.9 Estimación y ajuste

16.9.1 Intervalos de confianza analíticos

Los intervalos de confianza teóricos proporcionan un rango de valores dentro del cual se espera que se encuentre el verdadero valor de un coeficiente de regresión con un cierto nivel de confianza (generalmente 95%).

16.9.2 Bootstrap

El bootstrap es un método no paramétrico que permite estimar la distribución de un estimador mediante simulación. Al generar múltiples muestras de los datos originales mediante resampling con reemplazo, es posible recalcular varias observaciones del estimador y tener una muestra aleatoria de este.

16.10 Estimación y ajuste

La prueba de hipótesis global en un modelo de regresión evalúa si al menos una de las variables independientes tiene un efecto significativo sobre la variable dependiente. Esto se realiza mediante la siguiente hipótesis:

- **Hipótesis nula (H_0)**: Todos los coeficientes de regresión son iguales a cero, es decir, las variables independientes no tienen efecto sobre la variable dependiente.
- **Hipótesis alternativa (H_a)**: Al menos un coeficiente de regresión es diferente de cero, es decir, al menos una variable independiente tiene un efecto significativo.

16.10.1 Procedimiento:

1. **Cálculo del estadístico F**: Se utiliza para comparar el modelo ajustado con un modelo nulo (sin variables predictoras).
2. **Determinación del p-valor**: El p-valor asociado con el estadístico F indica la probabilidad de observar un valor tan extremo como el calculado, bajo la hipótesis nula.
3. **Decisión**: Si el p-valor es menor que el nivel de significancia (, comúnmente 0.05), se rechaza la hipótesis nula, concluyendo que el modelo tiene al menos un predictor significativo.

16.11 Validación y evaluación

16.11.1 Métricas de evaluación

Para evaluar un modelo se utilizan:

- **Coeficiente de determinación (R^2)**: Medida de la proporción de la varianza explicada.
- **Error cuadrático medio (MSE)**: Promedio de los cuadrados de los errores.
- **AIC/BIC**: Criterios de información para comparar modelos.
- **Pruebas de significancia**: p-valores, pruebas F, t-pruebas para evaluar la relevancia de los parámetros.
- **Exactitud (accuracy) y precisión**: métricas para evaluar modelos de respuesta categórica, sensibilidad y especificidad.
- **Curva ROC, AUC y matriz de confusión**: estadígrafos asociados a los modelos de respuesta categórica.
- **Validación cruzada**: uso de datos de ajuste y prueba para el cálculo de las métricas.

16.12 Modelos

16.12.1 Regresión (aprendizaje supervisado)

Modelos donde se predice o explica una variable dependiente a partir de una o más variables independientes.

16.12.2 Ejemplos

Regresión lineal, regresión logística, regresión Poisson.

16.12.3 Métodos multivariados (aprendizaje no supervisado)

Técnicas para descubrir estructuras subyacentes en los datos sin necesidad de una variable dependiente.

16.12.4 Ejemplos

Análisis de componentes principales (PCA), análisis de conglomerados, análisis factorial.

16.13 Modelos de regresión explicativos

El centro de nuestro aprendizaje en ciencias sociales es el modelamiento explicativo.

16.14 Modelos de regresión explicativos

16.14.1 Lineal normal

- **Descripción:** Modelo que asume una relación lineal entre las variables y que los errores son normalmente distribuidos.
- **Aplicaciones:** Estimación de relaciones entre variables cuantitativas.

16.14.2 Logit

- **Descripción:** Modelo utilizado para predecir probabilidades de eventos binarios (0 o 1).
- **Aplicaciones:** Modelos de decisión, análisis de comportamiento.

16.15 Modelos de regresión explicativos

16.15.1 Poisson

- **Descripción:** Modelo para contar eventos que ocurren en un intervalo fijo.
- **Aplicaciones:** Modelado de tasas de ocurrencia, como incidentes de accidentes.

16.15.2 Series de tiempo, Datos panel

- **Descripción:** Modelos que consideran la dependencia temporal o la estructura de panel en los datos.
- **Aplicaciones:** Pronósticos, análisis longitudinal.

16.16 Modelos de regresión explicativos

16.16.1 Espaciales (krigging)

- **Descripción:** Modelos que incorporan la correlación espacial entre observaciones.
- **Aplicaciones:** Geostatística, análisis de datos georreferenciados.

16.16.2 De efectos fijos y aleatorios

- **Descripción:** Modelos que permiten controlar por variables no observadas que varían entre entidades.
- **Aplicaciones:** Análisis de datos donde existen diferencias individuales inobservables.

16.17 Modelos de regresión explicativos

16.17.1 Modelos de supervivencia

- **Descripción:** Modelos que analizan el tiempo hasta un evento de interés.
- **Aplicaciones:** Análisis de tiempo hasta la muerte, recurrencia de enfermedades.

17 Modelo de regresión lineal

17.1 Modelo de regresión lineal

La regresión lineal múltiple es un método estadístico que permite modelar la relación entre una variable dependiente continua y dos o más variables independientes (predictoras). Se utiliza para explicar el valor de la variable dependiente basado en los valores conocidos de las variables independientes.

17.2 Formulación

17.2.1 Especificación matemática

$$y = \beta_0 + X_1\beta_1 + X_2\beta_2 + \cdots + X_k\beta_k + \varepsilon$$

17.2.2 Terminología

- X : variables independientes/explícitas.
- y : variable dependiente - explicada - respuesta.
- β_0 es la intersección o término constante.
- $\beta_1, \beta_2, \dots, \beta_n$: coeficientes de regresión.
- ε : errores/perturbaciones aleatorias.

17.3 Formulación

17.3.1 Parámetros

- **Coeficientes de regresión β :** Indican el cambio esperado en la variable dependiente Y por cada unidad de cambio en una variable independiente X , manteniendo las demás constantes.
- **Error estándar:** Medida de la precisión de los coeficientes estimados.
- **Término de error ε :** Captura la variabilidad en Y que no es explicada por las variables independientes.

- **Estadísticos (t) y (p)-valor:** Utilizados para probar la significancia de cada coeficiente.

17.3.2 Supuestos teóricos

- **Linealidad:** La relación entre las variables dependientes e independientes es lineal.
- **Independencia de los errores:** Los errores ε son independientes entre sí.
- **Homoscedasticidad:** La varianza de los errores es constante en todos los niveles de las variables independientes.
- **Normalidad de los errores:** Los errores ε se distribuyen normalmente.
- **No multicolinealidad:** Las variables independientes no están altamente correlacionadas entre sí.

17.4 Covariables

17.4.1 Covariables numéricas

- **Definición:** Variables independientes que son numéricas y se utilizan en modelos de regresión para explicar la variación en la variable dependiente.
- **Ejemplo:** Edad, ingresos, puntuación en una prueba.

17.4.2 Covariables categóricas

- Requieren un procesamiento previo. Se convierten en variables dummy.
- **Definición:** Variables independientes que son categóricas y se utilizan en modelos de regresión para explorar diferencias entre grupos o categorías.
- **Ejemplo:** Género, tipo de tratamiento, región geográfica.

17.5 Respuesta

17.5.1 Respuesta numérica

- **Definición:** Variable dependiente en modelos de regresión que es numérica.
- **Ejemplo:** Precio de una vivienda, número de ventas.

17.5.2 Respuesta categórica

- El trabajo con respuestas categóricas se sitúa por fuera del modelo de regresión lineal.
- **Definición:** Variable dependiente en modelos de regresión que es categórica.
- **Ejemplo:** Aprobado/No aprobado, compra/no compra.

17.6 Comprobación de hipótesis

La evaluación de hipótesis mediante modelos de regresión implica determinar si los efectos de las variables independientes sobre la variable dependiente son significativos y en qué dirección se manifiestan. Este proceso se basa en la prueba de hipótesis para los coeficientes del modelo.

17.6.1 Planteamiento de hipótesis

- **Hipótesis nula ((H_0)):** Establece que no hay efecto o relación significativa entre la variable independiente y la variable dependiente. En términos de regresión, esto significa que el coeficiente de la variable independiente es igual a cero ($(\beta_i = 0)$).
- **Hipótesis alternativa ((H_A)):** Sugiere que hay un efecto significativo. En regresión, esto implica que el coeficiente no es cero ($(\beta_i \neq 0)$).

17.7 Proceso de estimación

17.7.1 Intervalos de confianza analíticos

- **Cálculo:**
 - Se basa en los supuestos de normalidad de los errores y en la distribución de t .
 - Los límites del intervalo de confianza se calculan como: $\hat{\beta} \pm t_{\alpha/2} \cdot SE(\hat{\beta})$, donde $\hat{\beta}$ es el coeficiente estimado y $SE(\hat{\beta})$ es su error estándar.
- **Importancia:**
 - Proporciona una medida de la precisión de los estimadores.
 - Ayuda a evaluar la significancia de los coeficientes: si el intervalo no incluye cero, el coeficiente es significativo.

17.8 Proceso de estimación

17.8.1 Bootstrap

- **Proceso:**

- Generar un gran número de muestras bootstrap (por ejemplo, 1,000).
- Calcular los coeficientes de regresión para cada muestra.
- Obtener la distribución empírica de los coeficientes y derivar intervalos de confianza a partir de ella.

- **Ventajas:**

- No depende de los supuestos de normalidad de los errores.
- Es útil en situaciones donde los supuestos teóricos pueden no cumplirse o en modelos complejos.

- **Limitaciones:**

- Requiere un número elevado de simulaciones, lo que puede ser computacionalmente intensivo.
- La precisión de los intervalos bootstrap depende del tamaño de la muestra original.

17.9 Inferencia del modelo

Es necesario estudiar si las relaciones mostradas en el modelo son o no estadísticamente significativas.

17.9.1 Significancia global

¿Existe una relación estadísticamente significativa entre la variable respuesta y las variables explicativas en general?

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_p = 0 \quad \text{frente a} \quad H_1 : \beta_j \neq 0 \text{ para algún } j$$

17.10 Inferencia del modelo

Es necesario estudiar si las relaciones mostradas en el modelo son o no estadísticamente significativas.

17.10.1 Significancia particular

¿Existe una relación estadísticamente significativa entre la variable respuesta y una variable explicativa en particular?

$$H_0 : \beta_i = 0 \quad \text{frente a} \quad H_1 : \beta_i \neq 0$$

17.11 Proceso de estimación

17.11.1 Valores ajustados/predichos

$$\hat{y} = X\hat{\beta} + \hat{\beta}_0$$

17.11.2 Residuales

$$r = y - \hat{y}$$

17.12 Validación de supuestos

Para que los resultados de la regresión lineal múltiple sean válidos, deben cumplirse ciertos supuestos. A continuación se presentan los métodos de evaluación para cada uno:

- **Linealidad:**
 - **Método de evaluación:** Se evalúa mediante la observación de posibles patrones en los residuos. Puedes utilizar gráficos de residuos frente a valores ajustados para verificar si los residuos están distribuidos aleatoriamente sin patrones evidentes.
 - **Gráfico recomendado:** Gráfico de dispersión de residuos versus valores ajustados.
- **Independencia de los errores:**
 - **Método de evaluación:** Se verifica mediante pruebas estadísticas como la prueba de Durbin-Watson para detectar autocorrelación en los residuos. Un valor cercano a 2 sugiere que no hay autocorrelación.
 - **Prueba recomendada:** Prueba de Durbin-Watson.

17.13 Validación de supuestos

- **Homoscedasticidad:**
 - **Método de evaluación:** Se evalúa observando si la varianza de los residuos es constante a lo largo de todos los valores de las variables independientes. Se puede usar el gráfico de residuos estandarizados frente a valores ajustados.
 - **Gráfico recomendado:** Gráfico de residuos estandarizados versus valores ajustados.
- **Normalidad de los errores:**
 - **Método de evaluación:** Se verifica utilizando gráficos y pruebas estadísticas. Un gráfico de Q-Q (cuantil-cuantil) puede mostrar si los residuos siguen una distribución normal. Además, se pueden realizar pruebas de normalidad como la prueba de Shapiro-Wilk.
 - **Gráficos y pruebas recomendadas:** Gráfico Q-Q y prueba de Shapiro-Wilk.

17.14 Validación de supuestos

- **No multicolinealidad:**
 - **Método de evaluación:** Se evalúa mediante el cálculo del Factor de Inflación de la Varianza (VIF) para cada variable independiente. Un VIF superior a 10 indica una alta multicolinealidad.
 - **Métrica recomendada:** Factor de Inflación de la Varianza (VIF).

17.15 Métricas de evaluación

- **R-cuadrado R^2 :** Mide la proporción de la varianza en la variable dependiente que es explicada por las variables independientes. Un R^2 alto indica un buen ajuste del modelo.
- **R-cuadrado ajustado:** Similar al R^2 , pero ajustado por el número de variables en el modelo, lo que lo hace más adecuado para comparaciones entre modelos con diferentes números de predictores.
- **Error estándar de la estimación:** Mide la precisión de las predicciones del modelo.
- **Estadístico F:** Evalúa la significancia global del modelo; es decir, si al menos una de las variables independientes tiene un efecto sobre la variable dependiente. A partir de este se obtiene un p-valor global.
- **p-valor:** Para cada coeficiente, indica si la variable independiente asociada tiene un efecto significativo en la variable dependiente.

17.16 Coeficiente de determinación

Permite establecer el porcentaje de información explicada por el modelo. Un valor cercano a 1 (100%) hace referencia a un modelo de ajuste alto.

17.16.1 Coeficiente de determinación

$$R^2 = \frac{SCR}{SCT} = 1 - \frac{SCE}{SCT}$$

17.16.2 Coeficiente de determinación ajustado

$$R_a^2 = 1 - \frac{n-1}{n-p-1}(1-R^2)$$

17.17 Práctica

[Análisis de regresión](#)

18 Modelo de regresión logit

18.1 Modelo de regresión logit

El modelo de regresión logit es utilizado para modelar una variable dependiente categórica, generalmente binaria, como una función de variables independientes. Es una forma de regresión no lineal que se usa ampliamente en análisis de datos donde el resultado es dicotómico.

18.2 Formulación

18.2.1 Especificación matemática

La especificación matemática del modelo logit se basa en la función logística. La función de probabilidad para una variable dependiente binaria y puede expresarse como:

$$P(y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + X_1\beta_1 + X_2\beta_2 + \dots + X_k\beta_k)}}$$

Donde:

- $P(y = 1 | X)$ es la probabilidad de que la variable dependiente sea igual a 1 dado el conjunto de variables independientes X .
- β_0 es el término constante o intercepto.
- X_1, X_2, \dots, X_k son las variables independientes.
- $\beta_1, \beta_2, \dots, \beta_k$ son los coeficientes asociados con cada variable independiente.

18.3 Formulación

18.3.1 Terminología

- X : variables independientes/explicativas.
- y : variable dependiente, categórica, que toma valores 0 o 1.
- β_0 : intersección o término constante.

- $\beta_1, \beta_2, \dots, \beta_n$: coeficientes de regresión que indican la relación entre las variables independientes y la probabilidad de que $y = 1$.
- ε : errores o perturbaciones aleatorias (aunque en el modelo logit, la relación es probabilística y no se modelan errores de la misma forma que en la regresión lineal).

18.4 Parámetros del modelo

18.4.1 Parámetros

En el modelo logit, los parámetros β se estiman mediante el método de máxima verosimilitud. Cada parámetro β_j representa el cambio en el logaritmo de las probabilidades ($\log \frac{P(y=1)}{P(y=0)}$) asociado con una unidad de cambio en la variable independiente X_j , manteniendo constantes las otras variables.

18.4.2 Supuestos teóricos

- **Independencia de las observaciones:** Las observaciones deben ser independientes entre sí.
- **Linealidad en el logit:** La relación entre las variables independientes y el logit de la probabilidad es lineal.
- **Ausencia de multicolinealidad:** Las variables independientes no deben estar fuertemente correlacionadas entre sí.

18.5 Covariables

18.5.1 Covariables numéricas

Las covariables numéricas son aquellas que se pueden medir cuantitativamente y se introducen directamente en el modelo como X_j .

18.5.2 Covariables categóricas

Las covariables categóricas, al ser cualitativas, se deben convertir en variables dummies (0 o 1) antes de incluirlas en el modelo.

18.6 Respuesta

18.6.1 Respuesta categórica

La variable respuesta en un modelo logit es categórica, usualmente binaria, y toma valores como 0 y 1.

18.7 Comprobación de hipótesis

Se formulan las hipótesis coherentes con la teoría. Se busca comprobar si las hipótesis son ciertas en la población.

18.7.1 Planteamiento de hipótesis

En un modelo logit, se pueden formular hipótesis sobre los coeficientes β_j (la covariable j tiene un impacto positivo o negativo en la variable respuesta):

- **Hipótesis nula (H_0):** $\beta_j = 0$, es decir, la variable independiente X_j no tiene efecto sobre la probabilidad de que $y = 1$.
- **Hipótesis alternativa (H_1):** $\beta_j \neq 0$, es decir, la variable independiente X_j tiene un efecto significativo.

18.8 Proceso de estimación

18.8.1 Intervalos de confianza analíticos para los parámetros

Los intervalos de confianza para los coeficientes β_j se calculan bajo el supuesto de normalidad asintótica de las estimaciones de máxima verosimilitud. Estos intervalos permiten evaluar la precisión de las estimaciones.

18.8.2 Bootstrap

El bootstrap es un método no paramétrico que se utiliza para estimar la distribución de los coeficientes β_j y sus intervalos de confianza, generando múltiples muestras de la base de datos original.

18.9 Inferencia del modelo

18.9.1 Significancia global

La significancia global del modelo se evalúa utilizando pruebas como la prueba de razón de verosimilitud (Likelihood Ratio Test), que compara la bondad de ajuste del modelo completo con un modelo reducido.

18.9.2 Significancia particular

Se evalúa la significancia individual de cada coeficiente β_j mediante pruebas t . Un valor p bajo indica que la variable correspondiente tiene un efecto significativo sobre la probabilidad de que $y = 1$.

18.10 Proceso de estimación

18.10.1 Probabilidades predichas

Los valores ajustados \hat{p} son las probabilidades predichas de que $y = 1$:

$$\hat{p} = \frac{1}{1 + e^{-(\hat{\beta}_0 + X_1 \hat{\beta}_1 + X_2 \hat{\beta}_2 + \dots + X_k \hat{\beta}_k)}}$$

18.10.2 Valores predichos

Los valores ajustados \hat{y} se obtienen mediante un umbral U que se encuentra entre 0 y 1:

$$\hat{y} = I(\hat{p} < U)$$

18.10.3 Residuales

Los residuales en un modelo logit no se calculan de la misma manera que en un modelo de regresión lineal, pero se pueden evaluar las diferencias entre los valores observados y las probabilidades predichas.

$$[y \cdot \log(\hat{p}) + (1 - y) \cdot \log(1 - \hat{p})]$$

18.11 Validación de supuestos

18.11.1 Linealidad en el logit

Se puede evaluar gráficamente o mediante pruebas específicas que verifican si la relación entre las variables independientes y el logit es lineal.

18.11.2 Independencia de los errores

Se verifica si las observaciones son independientes, usualmente mediante análisis de autocorrelación.

18.11.3 Ausencia de multicolinealidad

La multicolinealidad se evalúa mediante el cálculo de los factores de inflación de la varianza (VIF).

18.12 Métricas de evaluación

18.12.1 Curva ROC

La curva ROC es una herramienta gráfica que evalúa la capacidad del modelo para discriminar entre las clases.

18.12.2 AUC

El área bajo la curva (AUC) cuantifica la capacidad del modelo para distinguir entre las clases. Un AUC de 0.5 indica un modelo sin capacidad predictiva, mientras que un AUC cercano a 1 indica un excelente modelo.

18.13 Métricas de evaluación

La matriz de confusión es una herramienta que permite evaluar el rendimiento de un modelo de clasificación al resumir las predicciones realizadas frente a los resultados reales. Está compuesta por cuatro elementos:

- **Verdaderos Positivos (TP):** El modelo predice la clase positiva correctamente.
- **Falsos Positivos (FP):** El modelo predice la clase positiva incorrectamente.

- **Verdaderos Negativos (TN)**: El modelo predice la clase negativa correctamente.
- **Falsos Negativos (FN)**: El modelo predice la clase negativa incorrectamente.

	Predicción Positiva	Predicción Negativa
Clase Positiva	Verdaderos Positivos (TP)	Falsos Negativos (FN)
Clase Negativa	Falsos Positivos (FP)	Verdaderos Negativos (TN)

18.14 Métricas de evaluación

18.14.1 Exactitud

La exactitud es la proporción de predicciones correctas sobre el total de predicciones realizadas por el modelo $\frac{TP+TN}{TOTAL}$.

18.14.2 Sensibilidad

La sensibilidad mide la proporción de verdaderos positivos correctamente identificados por el modelo: $\frac{TP}{TP+FN}$. Indica la capacidad del modelo para identificar correctamente los casos positivos, es decir, cuántos de los casos positivos reales fueron detectados por el modelo.

18.14.3 Especificidad

La especificidad mide la proporción de verdaderos negativos correctamente identificados por el modelo: Especificidad = $\frac{TN}{TN+FP}$. Refleja la capacidad del modelo para identificar correctamente los casos negativos, es decir, cuántos de los casos negativos reales fueron detectados por el modelo.

19 Medición

19.1 Indicadores y métricas

Los indicadores son herramientas cuantitativas utilizadas para medir, monitorear y evaluar un fenómeno o proceso específico. Un indicador generalmente se compone de un numerador y un denominador, lo que permite contextualizar la medición y compararla en diferentes situaciones. Por ejemplo, un indicador común en economía es la tasa de desempleo, que se calcula dividiendo el número de personas desempleadas (numerador) por la población activa total (denominador), y se expresa como un porcentaje.

Las métricas, aunque también son números que sirven para evaluar aspectos de un fenómeno, suelen referirse a medidas directas que no necesariamente requieren un numerador y un denominador. Son herramientas clave en la evaluación del rendimiento y pueden incluir una amplia gama de datos, desde cifras de ventas hasta tiempos de respuesta en un sistema. Por ejemplo, en un sitio web, una métrica común es el tiempo promedio que un usuario pasa en una página.

19.2 Puedes medir usando un indicador: ¿pero quieres?

19.2.1 ¿Por qué no puedo ver a mi médico la otra semana?

En Gran Bretaña, se propuso medir la calidad de la salud con un indicador: que cuando un paciente llamara a su médico, le dieran cita en menos de cuarenta y ocho horas. Spoiler: (no funcionó, sólo se atendían llamadas para atención inmediata y se prohibieron las citas por adelantado).

19.2.2 Aquí las ambulancias no llegan

En Gran Bretaña, se propuso medir la calidad de la salud con un indicador: que cuando había una llamada de emergencia desde una zona urbana, y se consideraba que el caso *ponía en peligro una vida humana de forma inmediata* el servicio de ambulancias tenía ocho minutos para llegar al lugar. Spoiler: no funcionó, las ambulancias sólo iban a lugares cercanos. Cancelaban servicios y reiniciaban rutas..

19.3 Constructos

19.3.1 Definición

Un constructo es un aspecto medible relacionado con el fenómeno o sistema que se investiga. Un constructo puede ser unidimensional (linealidad) o multidimensional (complejidad). Generalmente, la medición de un constructo no se puede realizar de manera directa. Este concepto es usado en economía, psicometría, marketing, etc.

Según Gras (1980) un constructo es la representación sobre algún aspecto sobre el objeto que será observado, medido y relacionado con otros constructos.

19.4 Tipos de constructos

19.4.1 Constructos formativos

Se miden a partir de sus causas.

- Calidad.
- Estrato.
- Score de crédito.

19.4.2 Constructos reflexivos

Se miden a partir de sus consecuencias.

- Logro académico.
- Riesgo psicosocial.
- Desempeño laboral.

19.5 Medición de constructos

La medición de un constructo es una variable latente. Las variables latentes requieren una medición indirecta, que se realiza a partir de variables observables.

Briones (1998) establece que los constructos son medibles a través de sus manifestaciones externas, es decir, sus indicadores. Los constructos pueden ser definidos como propiedad subyacente medida solamente en forma indirecta, son definiciones mentales de los eventos de objetos los cuales pueden variar.

Los constructos se miden mediante instrumentos. Los instrumentos pasan por un proceso de validación.

19.6 Validación

Validar un instrumento requiere la realización de un proceso de recolección de datos.

19.6.1 Validez

Que el instrumento concuerde con el constructo que dice medir.

- Según algunos, la sección de matemáticas en la prueba Saber 11 depende demasiado de la comprensión de lectura.

19.6.2 Confiabilidad

Al repetir la medición, los resultados se mantienen.

- Según algunos, los resultados de matemáticas de años distintos de la prueba Saber 11, no son comparables entre sí.

19.7 Validez de contenido

Los ítems agotan el constructo.

Un cuestionario se evalúa solicitando a un grupo de expertos que puntúen los ítems en varios aspectos. Generalmente, los aspectos a evaluar son:

- Duración: cuánto toma responder el cuestionario.
- Claridad: que la persona logre comprender las preguntas.
- Completitud: que las respuestas agoten las posibles opciones a las preguntas.
- Pertinencia: que las respuestas sean pertinentes.

La concordancia entre expertos se mide utilizando un procedimiento, como el Kappa de Cohen o el Kappa de Fleiss.

19.8 Validez convergente y discriminante

Son dos tipos de validez complementarios.

19.8.1 Convergente

Que los ítems que están relacionados con el constructo en la teoría lo estén en la realidad.

19.8.2 Discriminante

Que los ítems que no están relacionados con el constructo en la teoría no lo estén en la realidad.

19.9 Consistencia interna

La consistencia interna es la propiedad de los ítems de estar altamente correlacionadas entre sí, lo que indica que están asociadas a un trazo latente. Dado que esta consistencia interna se encuentra reflejada en la estructura de correlación de las variables es posible medirla y analizarla.

19.9.1 Medidas

Algunas de las medidas más usadas para analizar la consistencia entre variables.

- [Alfa de Cronbach](#)
- Lambda de Guttman.
- Inter Item Correlation (Cohen & Swerdlik, 2005).

19.10 Consistencia externa

La medición que hacemos es consistente con la obtenida mediante otros instrumentos.

19.11 Alpha de Cronbach

19.11.1 Consistencia interna

En los casos donde todas las variables son mediciones indirectas distintas de un mismo aspecto no medible, se hace referencia a la propiedad denominada consistencia interna. La consistencia interna consiste en la propiedad de las variables en estar altamente correlacionadas entre sí, lo que indica que están asociadas a un trazo latente. Dado que esta consistencia interna se encuentra reflejada en la estructura de correlación de las variables es posible medirla y analizarla.

19.12 Alpha de Cronbach

El Alfa de Cronbach (Cronbach, 1951) es una de las medidas más usadas para analizar la consistencia entre variables.

Dados K variables Y_1, Y_2, \dots, Y_K y su suma $X = Y_1 + Y_2 + \dots + Y_K$, el Alfa de Cronbach está dado por la expresión

$$\alpha = \frac{K}{K - 1} \left(1 - \frac{\sum_{i=1}^K \sigma_{Y_i}^2}{\sigma_X^2} \right)$$

19.13 Alfa de Cronbach

El valor mínimo aceptable para el coeficiente alfa de Cronbach es 0,70; por debajo de ese valor la consistencia interna de la escala utilizada es baja. Por su parte, el valor máximo esperado es 0,90; por encima de este valor se considera que hay redundancia o duplicación.

[Aproximación al uso del coeficiente alfa de Cronbach](#)

19.14 Instrumentos

Un instrumento de medida es una técnica o conjunto de técnicas que permitirán una asignación numérica que cuantifique las manifestaciones de un constructo que es medible solo de manera indirecta. (Herrera, 1998)

19.15 Cuestionarios

Un cuestionario es un conjunto de preguntas que indagan por aspectos concernientes al constructo.

Las preguntas o ítems tienen un valor particular en la construcción de un cuestionario.

19.16 Construcción

La construcción de un cuestionario, es decir, de definición de las preguntas que lleva, no ocurre de manera subjetiva.

Es preferible tomar como base cuestionarios previos o estudios detallados anteriores o partir de una investigación cualitativa anterior.

19.17 La pregunta

- Qué se pregunta. Debe estar relacionado con lo que se quiere medir.
- Cada pregunta es atómica. No indaga por diferentes aspectos al mismo tiempo.

19.18 Tipos de preguntas

Las preguntas que se realizan pueden ser:

19.18.1 Abiertas

- El usuario responde un párrafo con sus apreciaciones.
- En general no se incluyen por no tener un abordaje desde la estadística clásica.
- Pueden ser analizadas con minería de texto y procesamiento del lenguaje natural.

19.18.2 Cerradas

- Numéricas
- Opción múltiple con única respuesta.
- Opción múltiple con múltiple respuesta (el análisis no es tan fácil).

19.19 Estructuras de preguntas

Algunos mecanismos de indagación más compleja.

- Votos múltiples.
- Ranking.
- Likert.

19.20 Votos múltiples

Es una estructura de votación, cada integrante del grupo tiene un número de votos con respecto a un conjunto de alternativas. A diferencia de una votación única, donde se selecciona solo una opción, la votación múltiple permite elegir varias opciones, ofreciendo una visión más completa de las preferencias del grupo.

Ejemplo: Imagina que tienes una lista de marcas de automóviles: Tesla, BMW, Mercedes, Audi, Toyota, Ford, Honda, Volvo. Se te pide que votes por las tres marcas que más te gusten.

¿Cómo crees que se analiza?

19.21 Ranking

Se solicita a los participantes que organicen de mayor a menor una lista según un criterio definido. Este proceso permite capturar las preferencias relativas entre las diferentes opciones.

Ejemplo: Imagina que tienes una lista de postres: tiramisú, helado de vainilla, cheesecake, brownie, mousse de chocolate, flan, macarrones, crème brûlée. Se te pide que los organices de mayor a menor según lo deliciosos que te parezcan.

¿Cómo crees que se analiza?

19.22 Likert

Se solicita a los participantes que puntúen una lista de afirmaciones según una escala definida.

Ejemplo: Imagina que se les pide a los participantes que expresen su nivel de acuerdo con las siguientes afirmaciones sobre ética en el lugar de trabajo:

“Es aceptable que los empleados reporten irregularidades de manera anónima.”

“Las empresas deben ser transparentes sobre sus prácticas ambientales.”

“Es importante que las decisiones corporativas se basen en principios éticos, incluso si afecta la rentabilidad.”

Los participantes deben calificar cada afirmación en una escala que va desde “totalmente en desacuerdo”, “en desacuerdo”, “neutral”, “de acuerdo” hasta “totalmente de acuerdo”.

¿Cómo crees que se analiza?

19.23 Buenas prácticas

En los procesos de diseño de instrumentos hay una serie de buenas prácticas:

- No usar filtros en las encuestas.
- Nunca ponerle número a las categorías ni a la no respuesta.
- No hacer preguntas tendenciosas.
- Usar palabras claras.
- No dar alternativas implícitas.
- No hacer suposiciones tácitas.
- No usar dobles negaciones.
- Mejor preguntar la fecha de nacimiento que la edad.
- Preguntar como numéricos los datos numéricos siempre que sea posible.

20 Referencias

Cohen, R. J., Swerdlik, M. E., & Phillips, S. M. (1996). Psychological testing and assessment: An introduction to tests and measurement. Mayfield Publishing Co.

21 Análisis de Componentes Principales

21.1 Reducción de dimensiones

Necesitamos reducir las dimensiones de un conjunto de datos por varias razones:

- Visualización: poder observar los datos en 2 o 3 dimensiones.
- Resumen: poder resumir indicadores (mediciones directas) en índices (mediciones indirectas).
- Modelaje: poder disminuir la cantidad de variables que entran en un modelo.

21.2 ACP

El análisis de componentes principales es un método de reducción de dimensiones basado en proyecciones de espacios vectoriales.

21.2.1 Definición matemática

Dado un conjunto de variables X el procedimiento encuentra coeficientes α que maximizan la información explicada en su combinación lineal Z , así:

$$Z = X\alpha = \sum_{i=1}^k \alpha_i X_i$$

21.2.2 Significado matemático

Esto significa una rotación en el espacio, cambiando los ejes previos por ejes nuevos.

21.3 ACP

21.3.1 Características

- Es lineal: las transformaciones que contempla son lineales.
- Es interpretable: es posible establecer cuál variable es más o menos importante.
- Los ejes son interpretables a posteriori.

21.3.2 Ejemplo

- [setosa.io](#)

21.4 ACP

21.4.1 Evaluación

El procedimiento produce:

- Un círculo de correlaciones: Deben estar las flechas apuntando todas en la misma dirección.
- Un gráfico de sedimentación: El primer componente debe tener un valor alto y los demás deben ser bajos.

Part IV

Modelamiento de sistemas complejos

Introducción

Modelamiento

Redes, asociaciones y distancias

Redes

Asociaciones

Distancias

Algoritmos

Apriori

t-SNE

Cluster jerárquico

k-means

22 Enfoque

22.0.1 Linealidad

- PCA
- Análisis factorial
- SEM

22.0.2 Complejidad

- Distancias
- t-Sne
- Clustering

La medición clásica se sitúa en el paradigma lineal.

23 Estadística IV

Estadística multivariada

24 Antecedentes

24.1 Introducción

En investigación social, el uso adecuado de métodos estadísticos para comprender la estructura y operatividad de un fenómeno determinado, constituye una ventaja del investigador en un entorno competitivo de alto desempeño. Una gran variedad de procesos de planeación y evaluación de actividades gubernamentales, administrativas, económicas y financieras, se basan en resultados obtenidos mediante el análisis estadístico de los fenómenos en ellos involucrados.

Además, dado el crecimiento exponencial de las fuentes de información y el desarrollo acelerado de las herramientas tecnológicas, es apropiado disponer de una sólida fundamentación conceptual y práctica que le permita transformar y comprender grandes cantidades de información.

24.2 Presentación

24.2.1 Descripción del Curso

Estadística IV: Estadística multivariada es un curso avanzado que capacita a los estudiantes en el diseño y evaluación de herramientas de medición en investigaciones sociales. El contenido abarca la conceptualización de constructos formativos y reflexivos, así como la creación de instrumentos como cuestionarios y formularios. Los estudiantes aprenderán a definir, construir y evaluar estos instrumentos, asegurando consistencia, validez y generalización de los resultados. Se abordarán diferentes escalas de medición (binaria, Likert, ordinal y numérica), además de preguntas cerradas y abiertas.

24.2.2 Justificación

Estadística IV: Estadística multivariada es una asignatura fundamental dentro del ciclo formativo en técnicas especiales de investigación, enfocada en fortalecer las competencias de los estudiantes en la creación y validación de instrumentos de medición. Este curso cubre áreas clave como el diseño de cuestionarios, la evaluación de constructos formativos y reflexivos, y la implementación de algoritmos de agrupación y segmentación, esenciales para la investigación social.

24.3 Consideraciones

Sobre los contenidos teóricos y/o conceptuales básicos del programa.

Es curso está lleno de contenidos prácticos y ligeros que no exigen a los estudiantes mayores conocimientos o destrezas sobre los temas, ni la realización de tareas o trabajos profundos por fuera del aula. Lo que se busca es impartir conocimiento y entregar herramientas básicas de estadística como apoyo a las investigaciones y documentos exigidos como proyectos de investigación.

24.4 Objetivo

Examinar cómo ocurre la recolección de datos en una investigación de tipo cuantitativo.

24.5 Metodología

Curso magistral con talleres prácticos en donde se involucren todos los asistentes mediante el desarrollo de un taller y exposición de resultados.

24.6 Docente

24.6.1 Julián Cruz

Soy científico de datos, profesional en estadística y magíster en ciencias. Cuento con más de 12 años de experiencia demostrada en analítica y ciencia de datos. Mi perfil contempla desde liderazgo de programas de capacitación y gestión del cambio, hasta ejecución proyectos de base tecnológica. Esta experiencia me ha permitido desarrollar diferentes competencias, como la orientación al valor en toma de decisiones, la conformación y desarrollo de equipos de alto desempeño y la negociación integradora.

24.7 Material

[Handbook on Constructing Composite Indicators: Methodology and User Guide](#)

[Diseño y validación de instrumentos de medición](#)

[Principal Component Analysis](#)

24.8 Narrativa

24.8.1 Creadores

Los creadores de herramientas, productos, servicios y experiencias deben tener un conocimiento profundo sobre el campo en el que actúan.

24.8.2 Usuarios

Los usuarios de herramientas, productos, servicios y experiencias deben tener claridad sobre su finalidad y el modo de uso.

25 Acercamiento epistemológico

25.1 Cambio en el paradigma

En este momento se está llevando a cabo un cambio profundo en los enfoques del análisis de datos y la modelización, que reflejan la evolución de la metodología estadística hacia la ciencia de datos.

25.1.1 Paradigma clásico

Se basa en modelos estadísticos tradicionales con supuestos de linealidad y trabaja con conjuntos de datos pequeños. El enfoque está en la inferencia y la explicación basada en muestras limitadas.

25.1.2 Paradigma emergente

Utiliza técnicas de aprendizaje automático e inteligencia artificial para analizar grandes volúmenes de datos. Se enfoca en la eficiencia computacional y en manejar la complejidad de relaciones no lineales, con un fuerte énfasis en la precisión predictiva y en la capacidad de trabajar con datos masivos.

25.2 Paradigma clásico

- Conjuntos pequeños de datos. Datos caros. Eficiencia = uso de menos datos.
- Problema población - muestra. Inferencia estadística. Supuestos distribucionales.
- Relaciones lineales.
- Explicación = Predicción. Hipótesis y pronóstico.

25.3 Paradigma emergente

- Conjuntos grandes de datos. Datos baratos. Eficiencia = Eficiencia computacional.
- Problema sesgo - varianza. Sobreajuste. Validación cruzada.
- Relaciones no lineales.
- Explicar o predecir.
- Explicaciones complejas.
- Pronósticos precisos. Inteligencia artificial.

25.4 Ejemplo

Algunos ejemplos del paradigma clásico y del paradigma emergente

25.5 Tipo de estudio

De acuerdo a la pregunta el estudio puede ser:

- Descriptivo.
- Predictivo.
- Explicativo.
- Inferencial.
- Correlacional.
- Experimental.
- Longitudinal.
- Exploratorio.
- Confirmatorio.

25.6 Epistemología de la ciencia

Un repaso

- Positivismo: Enfoque en la observación empírica y datos objetivos.
- Verificacionismo: Teorías deben ser verificables empíricamente.
- Falsacionismo: Enfoque en la refutación y la prueba de teorías.

- Paradigmas Científicos: El conocimiento avanza a través de cambios en los paradigmas científicos.

25.7 Metodología

- Planeación.
- Diseño.
- Muestreo.
- Implementación.
- Análisis.
- Socialización.

26 Taller

26.1 Taller

Vamos a revisar la validación de un instrumento.

26.1.1 Contexto

Propósito – Este artículo informa sobre el desarrollo y validación de un índice de medición de soborno para el sector empresarial, que, basado en la teoría institucional, busca superar las limitaciones de las mediciones tradicionales, reconociendo las dinámicas que originan el fenómeno e identificando los componentes del proceso.

Diseño/metodología/enfoque – Para la construcción del índice se utilizaron técnicas de análisis correlacional y de componentes principales, así como rigurosas pruebas estadísticas, validando el instrumento en una muestra de 2.963 empresas de América Latina, entre ellas Argentina, Colombia, Chile, Ecuador, Guatemala, México y Perú.

Hallazgos – El resultado fue un instrumento compuesto por dos dimensiones: (1) reglas de juego antisoborno, que incluyen conocimiento normativo y esfuerzo antisoborno, y (2) soborno como hábito percibido, permitiendo una representación objetiva de la realidad debido a su consistencia interna, validez concurrente y discriminante.

Originalidad/Valor – Este artículo pone en evidencia empírica diferentes variables que hacen posible el soborno. Los resultados pueden ser útiles en el diseño de estrategias para prevenir este tipo de comportamiento. También destaca la importancia de diseñar mecanismos para registrar la información relacionada con la lucha contra el soborno.

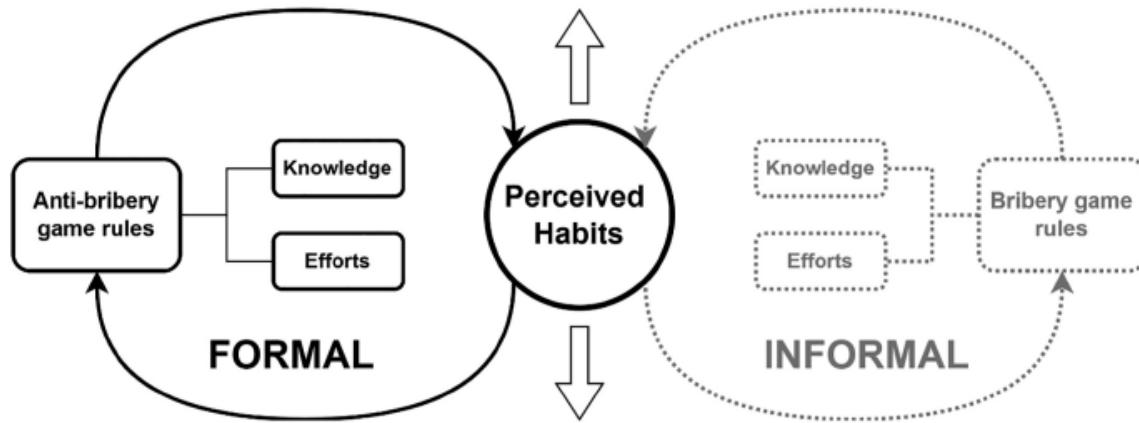
Implicaciones prácticas – Este instrumento es uno de los pocos que se enfoca en medir el soborno en el sector empresarial en términos de prácticas de corrupción, siendo útil para instituciones tanto públicas como privadas para promover mejores reglas de juego en contra del soborno. Adicionalmente, el modelo teórico propuesto puede ser utilizado para medir otros fenómenos con características similares.

Palabras clave – Soborno, Corrupción, Índice, Empresas latinoamericanas, Teoría institucional

Tipo de paper – Trabajo de investigación

H1. Como componentes de las reglas de juego antisoborno, se espera que la correlación entre el conocimiento de las regulaciones y los esfuerzos antisoborno sea significativamente positiva.

H2. Dado que son indicadores de la institucionalización de fuerzas opuestas, las reglas de juego antisoborno y el soborno como hábito percibido deben tener una correlación negativa.



26.1.2 Papers

Institutionalization of corporate bribery: a measurement proposal with evidence from a Latin American sample

4. Is corporate bribery institutionalized in Latin America? Evidence from a comparative study in seven countries

26.1.3

Ejemplo de medición

1. Escudriñar el documento.
2. Tomar nota a cerca de todas las inquietudes que este documento genera.
3. Intentar responderlas por cuenta propia.
4. Compartirlas en el documento del grupo.
5. Responda unas preguntas:
 - ¿Alguna de las dimensiones del índice es inconsistente?
 - ¿Qué dimensión es más consistente?
 - ¿Qué dimensión presenta una mayor redundancia?

- ¿Cómo se evalúa la consistencia externa?

Cronbach, L. J. (1951). Coefficient alpha and the internal structure of tests. *Psychometrika*, 16(3), 297–334. <http://doi.org/10.1007/BF02310555>